

석사학위논문

배틀로얄 장르의 단계 조건부 생존 분석
프레임워크

A Phase-Conditioned Survival Analysis Framework for the Battle
Royale Genre

학과명

작성자명

2026년 월 일

배틀로얄 장르의 단계 조건부 생존 분석 프레임워크

이 논문을 석사 학위논문으로 제출함

지 도 교 수 지도교수명

작성자명의 석사 학위논문을 인준함

2026년 월 일

위원장 인

위 원 인

위 원 인

Contents

요약	vii
1 서론	1
1.1 연구의 배경	1
1.2 연구의 필요성	2
1.3 연구 문제	3
1.4 주요 기여	4
1.5 논문의 구성	4
2 관련 연구	5
2.1 온라인 게임 결과 예측 연구	5
2.2 배틀로얄 장르의 예측 및 순위 연구	6
2.3 PUBG 대상 결과 예측 연구	7
2.4 Sagong 등의 경기 단계 기반 PUBG 생존 연구	9
2.5 생존 분석 관점의 예측 연구	9
2.6 본 연구의 위치	10
3 배틀로얄 생존 과정의 정식화	11
3.1 연구 문제 1과 정식화의 목적	11
3.2 대표 배틀로얄 게임군과 공통 구조	12
3.3 경기, 팀, 경기 단계	13
3.4 다음 단계 탈락 여부	13
3.5 예측 시점에서 사용할 수 있는 정보	14
3.6 주요 생존 요인과 게임별 관측 방식	15
3.7 다음 단계 탈락 위험	17
3.8 탈락 위험의 누적과 생존 점수	18
3.9 탈락 위험 순위와 누적 생존 점수 순위	19
3.10 PUBG 사례로의 연결	19
3.11 연구 문제 1에 대한 이론적 답변과 적용 범위	20

4	PUBG 공식 경기 기록과 분석 자료의 구성	21
4.1	연구 문제 2와 자료의 범위	21
4.2	공식 기록의 구성과 저장	21
4.3	분석 단위의 재구성	22
4.4	전처리 절차	23
4.5	분석 집단의 구성	23
4.6	입력 변수와 목표값의 구분	24
4.7	실제 경기 상황과 수학적 표현의 대응	25
4.8	연구 문제 2에 대한 자료 구성 결과	26
5	생존 과정의 자료 표현과 예측 모형	28
5.1	연구 문제 2와 자료 표현의 원칙	28
5.2	모형이 사용하는 자료	28
5.3	단계별 입력 변수	30
5.4	10초 단위 시계열 변수	30
5.5	팀 간 관계와 그래프 구성	31
5.6	변수 묶음과 추가 순서	33
5.7	비교 모형의 기본 원리와 사용 목적	34
5.7.1	단계별 요약값을 사용하는 모형	35
5.7.2	10초 기록을 사용하는 시계열 모형	35
5.7.3	팀 관계를 사용하는 그래프 모형	36
5.8	제안 모형의 구성	37
5.9	자료 표현과 검증의 연결	39
6	연구 문제별 검증 설계	40
6.1	연구 문제와 세부 실험의 대응	40
6.2	연구 문제 1: 장르 정식화의 적용 범위(E1)	41
6.3	연구 문제 2: 공식 기록을 이용한 자료 표현(E2)	42
6.4	연구 문제 3과 4의 공통 평가 조건	42
6.4.1	분석 집단과 평가 절차	42
6.4.2	예측 시점과 자료 제한	43
6.4.3	학습 목표와 손실함수	44
6.5	연구 문제 3: 자료 표현의 타당성과 모형의 적합성	44
6.5.1	생존 요인의 표현이 더하는 정보(E3)	44
6.5.2	선행 방식과 일반 기준선의 비교(E4)	45
6.5.3	이전 시점의 기록에 적합한 모형의 비교(E5)	45
6.5.4	팀 관계에 적합한 모형의 비교(E6)	46

6.5.5	세부 실험별 모형과 실제 입력	46
6.5.6	모형 학습과 구현 설정	47
6.6	연구 문제 4: 단계별 위험의 경기 중 활용(E7)	48
7	연구 문제별 결과와 해석	49
7.1	연구 문제와 결과의 연결	49
7.2	연구 문제 1: 생존 과정 정식화의 적용 범위(E1)	49
7.3	연구 문제 2: PUBG 기록에서의 자료 표현(E2)	51
7.4	연구 문제 3: 자료 표현의 타당성과 모형의 적합성	52
7.4.1	생존 요인의 표현이 더하는 정보(E3)	52
7.4.2	선행 방식과 일반 기준선의 비교(E4)	53
7.4.3	이전 시점의 기록에 적합한 모형(E5)	54
7.4.4	팀 관계에 적합한 모형(E6)	56
7.5	연구 문제 4: 단계별 위험의 경기 중 활용(E7)	57
7.6	연구 문제별 답변	60
7.6.1	연구 문제 1에 대한 답변	60
7.6.2	연구 문제 2에 대한 답변	60
7.6.3	연구 문제 3에 대한 답변	60
7.6.4	연구 문제 4에 대한 답변	61
8	연구 문제별 논의와 한계	62
8.1	연구 문제별 종합 해석	62
8.2	생존 과정 정식화의 의미(연구 문제 1)	62
8.3	자료 표현의 의미(연구 문제 2)	63
8.4	표현의 타당성과 모형의 적합성(연구 문제 3)	63
8.5	경기 중 상대적 생존 평가(연구 문제 4)	64
8.6	자료와 평가의 한계	64
8.7	향후 연구	65
9	결론	66
9.1	연구 문제별 결론	66
9.1.1	생존 과정의 정식화(연구 문제 1)	66
9.1.2	PUBG 기록에서의 자료 표현(연구 문제 2)	66
9.1.3	표현의 타당성과 모형의 적합성(연구 문제 3)	67
9.1.4	경기 중 상대적 생존 평가(연구 문제 4)	67
9.2	종합 결론과 기여	67

A 부록	73
A.1 부록의 구성	73
A.2 대표 게임의 사례 분류	73
A.3 입력 변수의 정의와 산출 방법	73
A.4 분석 집단별 주요 결과	78
A.4.1 안전 영역과 주변 상황 변수를 추가한 결과	78
A.4.2 10초 기록을 사용한 모형 비교	79
A.4.3 단계별 순위 비교	79
A.5 보충 분석	80
A.5.1 팀 관계를 바꾼 대조 실험	80
A.5.2 고도 관련 변수	80
Abstract	81

List of Tables

3.1	본 논문에서 참조하는 대표 배틀로얄 게임군	12
3.2	단계 k 에서의 주요 생존 요인과 게임별 관측 예	16
4.1	주요 실험에 사용한 13개 분석 집단	24
4.2	공식 기록의 활용 구분	25
4.3	실제 PUBG 사례에서 생존 요인과 경기 기록의 대응	26
5.1	모형에 입력되는 네 가지 자료	29
5.2	생존 요인과 PUBG 입력 변수의 대응	31
5.3	10초 단위 입력 변수의 정의와 정규화 기준	32
5.4	OM0-OM6에서 새로 추가한 변수와 누적 변수 수	34
6.1	연구 문제별 세부 실험과 판단 근거	41
6.2	비교 실험별 모형과 실제 입력	47
7.1	연구 문제별 실험과 결과의 의미	50
7.2	대표 게임 사례의 검토 결과	51
7.3	분석 집단별 단계 예측 자료의 구성	51
7.4	대표 집단과 전체 집단을 요약한 입력 변수 추가 결과	52
7.5	선행 방식 및 요약 통계 기반 기준선 비교	54
7.6	같은 관측 변수와 예측 시점을 사용한 시계열 모형 비교	55
7.7	Erangel TPP 스쿼드의 단계별 및 10초 단위 자료 결합 모형 비교	56
7.8	대표 집단의 세 난수 시드 반복 결과 (평균과 표준편차)	57
7.9	탈락 위험 순위와 생존에 유리한 팀의 순위 비교: 13개 집단의 중앙값	59
A.1	대표 배틀로얄 및 배틀로얄형 게임 15종의 분류 결과	74
A.2	단계별 입력 변수 150개의 산출 방법	75
A.3	분석 집단별 OM2와 OM3의 다음 단계 탈락 예측 AUC	78
A.4	분석 집단별 10초 기록 모형의 다음 단계 탈락 예측 AUC	79
A.5	분석 집단별 다음 단계 탈락 팀의 상위 1팀 적중률	79
A.6	실제 팀 관계와 연결 상대를 바꾼 대조 실험의 비교	80

List of Figures

5.1	1- k 단계의 기록으로 $k + 1$ 단계 탈락 위험을 예측하는 과정	38
6.1	연구 문제와 세부 실험의 대응 관계	41
7.1	13개 분석 집단의 OM2 대비 OM3 다음 단계 탈락 예측 AUC 변화	53
7.2	10초 기록을 이용한 다음 단계 탈락 예측의 13개 집단 AUC 분포 .	55
7.3	한 경기에서 단계별로 갱신된 팀별 생존 점수 비율의 예	58
7.4	순위 구성 방법별 상위 1팀 적중률의 13개 집단 범위, 중앙값 및 대표 집단	59

요약

배틀로얄의 최종 순위는 안전 영역이 축소되고 남은 팀의 수와 배치가 달라지는 동안, 이동과 교전 및 자원 상태가 함께 변한 결과가 누적되어 형성된다. 본 연구는 이러한 특성을 반영하여 배틀로얄을 경기 단계마다 생존 조건이 갱신되는 다중 에이전트 생존 과정으로 정식화한다. 각 단계에서 아직 탈락하지 않은 팀의 다음 단계 탈락 위험을 추정하고, 이를 누적 생존 점수와 경기 내 순위로 연결하는 것이 연구의 목적이다.

정식화의 적용 범위는 규칙과 전투 방식이 다른 대표 게임 15종에서 검토하였다. 이어 2026년 3월 26일부터 6월 2일까지 수집한 PUBG 공식 경기 기록으로 경기 단계별 팀 자료와 10초 간격의 시계열 자료를 구성하였다. 지도, 시점과 팀 규모로 구분한 13개 분석 집단의 17,943경기에서 1,033,471개의 단계별 예측 사례를 만들었으며, 입력은 예측 시점까지 관측된 정보로 제한하였다.

실험은 개념의 적용 범위, 자료 구성, 입력 변수의 기여, 시간 이력과 팀 관계, 단계별 순위의 순서로 수행하였다. 이동 변수에 안전 영역의 변화와 현재 위치 및 주변 상황을 추가했을 때 대표 집단의 다음 단계 탈락 AUC는 0.7836에서 0.7937로 증가했고, 같은 방향이 나머지 12개 집단에서도 유지되었다. 이 변수 구성은 선행 연구의 행동 점수와 공식 원자료 요약보다 대체로 높은 결과를 보였다. 과거 10초 기록을 사용한 모형도 최근 상태만 사용한 모형보다 높은 성능을 보였다. 그래프 모형 사이의 차이와 팀 관계의 추가 효과는 작아 보충적인 근거로 해석하였다.

학습된 위험 순위는 규칙기반 순위보다 다음 단계 탈락 팀을 더 잘 식별했으며, 누적 생존 점수의 선두 팀도 단계가 바뀌면서 교체되었다. 누적 생존 점수는 우승 팀을 일찍 확정하는 값보다, 현재 관측을 반영하여 팀 사이의 상대적인 생존 여건을 갱신하는 지표로 의미가 있었다. 이 결과는 PUBG에서 배틀로얄의 결과를 단계별 생존 조건과 탈락 위험의 누적으로 분석할 수 있음을 보여준다. 다른 게임에서의 직접적인 예측 검증은 후속 연구로 남는다.

주요어: 배틀로얄, 생존 분석, PUBG, 공식 경기 기록, 탈락 위험, 시계열, 다중 에이전트

Chapter 1

서론

1.1 연구의 배경

배틀로얄 장르는 다수의 플레이어 또는 팀이 하나의 경기 안에서 경쟁하고, 시간이 지나면서 달라지는 생존 조건에 적응하며, 탈락과 최종 순위에 의해 결과가 결정되는 경쟁 게임 장르이다. 이 장르의 결과를 이해하려면 누가 마지막까지 살아남았는지뿐만 아니라, 경기 도중 안전한 공간이 줄어들고, 남은 인원과 팀의 배치가 바뀌며, 각 팀이 이동과 교전, 자원 확보를 통해 변화한 조건에 어떻게 대응했는지를 함께 고려해야 한다.

배틀로얄 경기의 생존 조건은 경기 진행에 따라 계속 갱신된다. 안전 영역은 여러 차례 축소되고, 가용 공간은 점차 줄어들며, 남아 있는 팀 수와 팀 간 거리는 계속 달라진다. 어떤 팀에게 유리했던 위치도 다음 단계에서는 위험한 위치가 될 수 있고, 초반에는 피할 수 있었던 접촉도 후반에는 피하기 어려워질 수 있다. 따라서 배틀로얄의 최종 순위는 경기 종료 시점의 통계만으로 설명되는 결과라기보다, 경기 단계마다 달라진 생존 조건과 그 조건에 대한 팀의 반응이 누적된 결과로 이해할 필요가 있다.

온라인 게임의 결과를 예측하려는 연구는 이미 여러 장르에서 진행되어 왔다. MOBA 장르에서는 경기 중 상태와 팀 구성을 바탕으로 승리 가능성을 예측하는 연구가 수행되었고 [18, 39], *Counter-Strike: Global Offensive*에서는 경기 중 발생한 사건을 이용해 개별 행동이 승리 가능성에 미치는 영향을 추정하는 연구가 제안되었다 [38]. *PUBG: Battlegrounds*(이하 PUBG)를 대상으로도 Kaggle 자료를 이용한 최종 순위 예측 연구와, 경기 중 상태를 활용한 생존 예측 연구가 수행되었다 [21, 28, 32, 30].

이 중 Sagong 등의 연구는 본 연구와 특히 밀접하다. 해당 연구는 PUBG 경기를 여러 단계로 나누고, 각 단계에서 관측된 플레이어의 행동을 바탕으로 생존 전략과 이후 생존 가능성을 분석하였다. 특히 공격성과 활동성을 점수화하여 플레이어의

전략 유형을 구분하고, 이후 생존 및 승리 가능성을 예측하였다 [30]. 이 연구는 배틀로얄 경기에서 단계별 상태가 생존 예측에 중요하다는 점을 보여주는 중요한 선행연구이다.

1.2 연구의 필요성

기존의 최종 순위 예측은 경기 결과를 요약하고 팀 간 성과를 비교하는 데 유용하다. 그러나 하나의 최종 순위에는 서로 다른 경기 과정이 같은 값으로 압축된다. 초반부터 유리한 위치를 유지한 팀과 여러 차례 위험을 벗어난 팀이 같은 순위를 기록할 수 있으며, 경기 종료 후 집계값은 어느 시점에 위험이 커졌는지를 보여주지 못한다. 경기 도중의 분석을 목적으로 할 때에는 아직 관측되지 않은 경기 후반의 통계도 사용할 수 없다. 따라서 최종 결과를 맞히는 문제와 경기 중 생존 조건의 변화를 설명하는 문제를 구분할 필요가 있다.

이 구분은 배틀로얄에서 특히 중요하다. 안전 영역이 축소될 때마다 이동 가능한 공간과 경로가 바뀌고, 탈락한 팀은 이후의 경쟁에서 제외되며, 남은 팀들의 거리와 접촉 가능성도 다시 형성된다. 같은 체력과 이동량을 가진 팀이라도 현재 안전 영역과 주변 팀의 배치에 따라 다음 단계의 위험은 달라질 수 있다. 이러한 구조를 반영하려면 각 단계에서 아직 탈락하지 않은 팀들만 비교하고, 그 시점까지 관측된 조건으로 다음 단계의 탈락 가능성을 추정해야 한다. 단계별 위험을 이어서 보면 최종 순위만으로 사라졌던 생존 과정도 경기 진행에 따라 추적할 수 있다. 이때 경기 단계, 아직 생존한 팀의 집합, 다음 단계에서의 탈락 위험이 어떤 관계를 이루는지 먼저 분명히 해야 한다. 이러한 관계를 정리해야 여러 배틀로얄 게임에서 반복되는 구조와 개별 게임의 규칙에 따른 요소를 구분하고, 실제 경기 기록을 같은 기준에 따라 분석할 수 있다.

따라서 본 연구는 배틀로얄 경기를 단계가 전환될 때마다 생존 팀의 구성과 탈락 위험이 달라지는 과정으로 먼저 정식화하고, 이를 실제 경기 기록에서 검토한다. 이 작업에는 장르의 핵심 규칙을 대표하면서 경기 전개를 세밀하게 관측할 수 있는 사례가 필요하다. PUBG는 현대적 배틀로얄을 대중화하고 그 형식을 정착시키는 데 선구적 역할을 한 게임으로 평가된다 [37, 35]. 안전 영역의 수축, 자원 확보, 이동과 교전, 다수 팀의 경쟁과 순차적인 탈락이라는 장르의 주요 특성도 뚜렷하게 나타난다. 동시에 공식 경기 기록은 안전 영역의 변화, 플레이어와 팀의 위치 및 상태, 피해와 교전 및 탈락 사건을 시간 순서대로 제공한다. 이러한 장르적 대표성과 자료의 세밀함을 바탕으로, 본 연구는 PUBG를 배틀로얄의 생존 조건이 시간에 따라 갱신되는 과정을 정식화하고 검토하기 위한 실증적 출발점으로 삼는다.

정식화한 생존 과정을 실제 자료에서 분석하려면, 이를 관측 가능한 형태로 표현하는 방법이 마련되어야 한다. 이 표현은 한 시점의 상태뿐 아니라 안전 영역의

수축과 팀 상태의 변화, 이동과 교전의 순서, 남은 팀들과의 관계를 함께 담아야 한다. 이어 이렇게 구성한 자료가 실제 다음 단계의 생존과 탈락을 구분하는지 검증하고, 단계별 요약과 이전 시점의 기록 및 팀 관계로 이루어진 자료를 어떤 모형이 적절하게 학습할 수 있는지도 확인할 필요가 있다. 본 연구는 장르의 생존 요인을 단계별 자료, 10초 단위 기록과 팀 관계로 구성한 뒤, 여러 입력 구성과 예측 모형을 비교하여 자료 표현의 타당성과 모형의 적합성을 평가한다. 이렇게 산출한 단계별 위험은 경기 중 갱신되는 생존 점수와 팀 순위로 연결한다.

PUBG를 이용한 실증은 장르 수준에서 정의한 구성 요소를 실제 경기 기록으로 표현하고, 그 자료가 다음 단계의 생존과 탈락을 설명하는 데 유용한지 확인하는데 목적이 있다. 따라서 실증 결과의 직접적인 적용 범위는 PUBG이며, 다른 배틀로얄 게임으로의 일반화 가능성은 해당 게임의 단계, 탈락 규칙과 기록 체계에 맞춘 추가 검증을 통해 확인해야 한다.

1.3 연구 문제

앞의 필요성은 네 가지 연구 문제로 이어진다. 첫째, 여러 배틀로얄 게임에서 반복되는 생존 구조를 하나의 과정으로 정식화해야 한다. 둘째, 그 과정의 구성 요소를 PUBG 공식 경기 기록에서 단계별 상태, 시간에 따른 변화와 팀 간 관계를 담은 자료로 표현해야 한다. 셋째, 이렇게 구성한 자료가 실제 생존과 탈락을 구분하는지 검증하고 각 자료 구조에 적합한 모형을 확인해야 한다. 넷째, 모형이 산출한 결과가 경기 진행에 따라 달라지는 팀들의 상대적 생존 여건을 나타내는지 평가해야 한다. 이에 따라 다음 연구 문제를 설정한다.

1. 배틀로얄 장르는 경기 진행에 따라 생존 조건이 갱신되는 다중 에이전트 생존 과정으로 어떻게 정식화할 수 있는가?
2. 이 생존 과정은 PUBG 공식 경기 기록에서 단계별 상태, 시간에 따른 변화와 팀 간 관계를 포함하는 자료로 어떻게 표현할 수 있는가?
3. 이렇게 구성한 자료는 다음 단계의 생존과 탈락을 얼마나 잘 구분하며, 단계별 상태, 이전 시점의 기록과 팀 관계를 학습하는 데 어떤 모형이 적합한가?
4. 단계별 탈락 위험과 이를 누적한 생존 점수는 경기 진행에 따른 팀들의 상대적 생존 여건을 나타내며, 각 단계에서 유리한 팀과 탈락 위험이 높은 팀을 식별할 수 있는가?

각 연구 문제에 필요한 세부 수식, 변수, 목표값 정의, 평가 지표는 이후 장에서 순차적으로 정의한다.

1.4 주요 기여

본 논문의 주요 기여는 다음과 같다.

1. 여러 배틀로얄 게임에서 반복되는 생존 조건을 정리하고, 경기 단계와 다음 단계 탈락 위험을 중심으로 장르의 생존 과정을 정식화하였다.
2. PUBG 공식 경기 기록을 단계별 상태, 예측 시점 이전의 10초 간격 기록과 팀 관계로 구성하여, 정식화한 생존 과정을 실제 자료에서 측정하는 방법을 제시하였다.
3. 생존 요인을 차례로 추가하고 통계 모형, 시계열 모형과 그래프 모형을 비교하여, 다음 단계 탈락 예측에 유용한 정보와 자료 구성에 적합한 모형을 확인하였다.
4. 단계별 탈락 위험을 누적 생존 점수와 경기 내 순위로 연결하여, 경기 중 팀들의 상대적인 생존 여건을 나타내는 방법을 제시하였다.

1.5 논문의 구성

본 논문은 연구 문제에 답하는 순서로 구성된다. 2장은 온라인 게임, 배틀로얄 및 PUBG 예측과 생존 분석에 관한 선행연구를 검토한다. 3장은 배틀로얄의 생존 과정을 경기 단계와 탈락 위험의 관계로 정식화한다. 4장은 PUBG 공식 경기 기록의 수집과 전처리 및 분석 집단의 구성을 설명하고, 5장은 예측에 사용한 변수와 비교 모형을 제시한다.

6장은 연구 문제를 검증하기 위한 실험 조건과 평가 방법을 설명한다. 7장은 입력 변수와 모형의 비교 결과 및 경기 중 생존 순위의 평가 결과를 제시한다. 8장은 결과의 의미와 적용 범위 및 한계를 논의하며, 9장은 연구 문제에 대한 답변과 기여를 종합한다.

Chapter 2

관련 연구

2.1 온라인 게임 결과 예측 연구

온라인 게임에서 경기 기록을 이용해 승패와 최종 결과를 예측하려는 연구는 여러 장르에서 진행되어 왔다. 여기서 결과 예측은 경기 시작 전 승자 예측을 포함해, 경기 도중 관측된 상태를 이용해 현재 어느 팀이 유리한지, 특정 플레이어가 가까운 시간 안에 탈락하거나 사망할 가능성이 있는지, 또는 특정 행동이 승리 가능성을 얼마나 바꾸는지를 추정하는 문제까지 포괄한다. 이러한 연구들은 게임 로그가 경기 후 요약 기록을 넘어, 경기 상태와 결과 사이의 관계를 분석할 수 있는 자료라는 점을 보여준다.

먼저 MOBA(Multiplayer Online Battle Arena)라고 불리는 팀 기반 대전 게임에서 관련 연구가 활발히 진행되었다. MOBA는 여러 플레이어가 두 팀으로 나뉘어 캐릭터를 선택하고, 경기 중 성장과 전투를 반복하며, 상대 진영의 목표물을 파괴하는 방식의 장르이다. 이 장르에서는 경기 전 팀 구성, 플레이어의 숙련도, 경기 중 자원과 처치 현황, 리그 안에서 팀들이 맺는 관계 등이 승패 예측에 활용된다. Hodge 등은 Dota 2를 대상으로 실력대가 서로 다른 일반 경기 자료가 프로 경기의 승패 예측에 활용될 수 있는지를 분석하였다 [18]. *League of Legends*를 대상으로 한 연구에서는 챔피언 선택 이후 플레이어가 해당 챔피언을 얼마나 익숙하게 사용해 왔는지를 이용해 경기 결과를 예측하거나 [13], 경기 진행 단계별 변수를 사용해 실시간으로 승패를 예측하였다 [20]. 또한 LoL e스포츠 리그의 팀과 경기 관계를 그래프 구조로 표현해 승패를 예측한 연구도 있으며 [5], *Honor of Kings*를 대상으로 시간 순서가 있는 경기 기록을 사용해 경기 중 승리 가능성을 해석 가능한 방식으로 예측하려는 연구도 제안되었다 [39].

같은 팀 기반 대전 장르인 Dota 2에서도 경기 결과와 경기 내부 사건을 예측하려는 연구가 진행되었다. Akhmedov와 Phan은 Dota 2 경기의 승패를 예측하기 위해 통계적 모형과 신경망 모형을 비교하였다 [2]. Katona 등은 최종 승패 대신

특정 영웅이 가까운 시간 안에 사망할지를 예측하는 문제를 다루었다 [22]. 이는 온라인 게임 예측 연구가 최종 결과만을 대상으로 하지 않고, 경기 중 발생하는 세부 사건까지 분석 대상으로 삼을 수 있음을 보여준다.

FPS, 즉 일인칭 시점 슈팅 게임에서도 경기 기록을 이용한 예측 연구가 이루어졌다. Xenopoulos 등은 *Counter-Strike: Global Offensive*의 대규모 경기 사건 기록을 이용해 플레이어의 개별 행동이 팀의 승리 가능성을 어떻게 변화시키는지 추정하였다 [38]. 이 연구는 단순히 최종 승패를 맞히는 것을 넘어, 경기 중 어떤 행동이 팀을 더 유리하거나 불리하게 만드는지를 해석하려는 방향을 제시한다.

실시간 공간 이동이 없는 온라인 카드 게임에서도 유사한 문제의식이 나타난다. 예를 들어 *Hearthstone*과 같은 턴제 카드 게임에서는 플레이어가 차례마다 카드를 선택하고, 그 선택이 이후 승리 가능성에 영향을 준다. Janusz 등은 *Hearthstone* 자료를 이용한 인공지능 도전 과제를 정리하면서, 게임 상태와 행동 선택을 바탕으로 플레이어의 승리 가능성을 평가할 수 있음을 보였다 [19]. 이는 공간 이동보다 선택 순서가 중요한 장르에서도 경기 상태를 결과 가능성과 연결하는 예측 문제가 성립할 수 있음을 보여준다.

이러한 선행연구는 본 논문의 출발점과 구분점을 동시에 제공한다. 여러 온라인 게임 장르에서 경기 기록과 경기 중 상태는 결과 예측에 유용한 자료로 사용되어 왔다. 이와 달리 배틀로얄 장르는 하나의 경기 안에 여러 팀이 동시에 존재하고, 아직 탈락하지 않은 팀들의 집합이 계속 바뀌며, 안전 영역의 수축에 따라 생존 조건 자체가 달라진다는 점에서 구분된다. 따라서 본 논문은 배틀로얄 예측을 경기 단계마다 생존 조건이 갱신되는 다중 에이전트 생존 과정의 예측 문제로 다룬다.

2.2 배틀로얄 장르의 예측 및 순위 연구

배틀로얄 장르는 다수의 플레이어 또는 팀이 제한된 공간에서 경쟁하고, 시간이 지나면서 점차 불리해지는 조건 속에서 마지막까지 살아남거나 높은 순위를 얻는 것을 목표로 하는 장르이다. 이 장르의 예측 문제는 일반적인 팀 대전 게임의 승패 예측과 다르다. 일반적인 팀 대전 게임에서는 두 팀 중 어느 쪽이 이기는지가 핵심 결과가 되는 경우가 많지만, 배틀로얄에서는 한 경기 안에 여러 팀이 동시에 존재하고, 각 팀은 서로 다른 시점에 탈락하며, 최종 결과도 승패와 순위로 나타난다.

또한 배틀로얄에서는 경기 조건이 시간에 따라 크게 달라진다. 안전 영역은 줄어들고, 남아 있는 팀의 수는 감소하며, 자원 분포와 이동 경로, 교전 가능성도 계속 바뀐다. 따라서 배틀로얄 예측은 크게 두 가지 문제로 나눌 수 있다. 첫째는 경기가 끝난 뒤 정리된 통계를 바탕으로 최종 순위를 예측하는 문제이다. 둘째는 경기 도중 특정 시점까지 관측된 정보만을 사용하여 이후의 생존 가능성이나 탈락 위험을 예측하는 문제이다. 전자는 전체 경기 결과를 설명하는 데 유용하지만,

경기 중 어느 시점에 어떤 팀이 위험해지지는 설명하기 어렵다. 후자는 경기의 시간적 흐름을 보존하지만, 예측 시점 이후에 발생한 정보가 입력에 섞이지 않도록 주의해야 한다.

본 논문은 두 번째 문제 설정에 초점을 둔다. 이를 위해 본 논문은 경기의 각 단계에서 아직 탈락하지 않은 팀들의 집합을 중요한 분석 단위로 본다. 이 집합은 시간이 지나며 계속 줄어들고, 안전 영역의 변화와 함께 각 팀이 처한 생존 조건도 달라진다. 따라서 본 논문에서 배틀로얄 예측은 최종 순위의 일괄 추정보다, 경기 단계마다 갱신되는 생존 조건 아래에서 다음 단계의 탈락 위험을 추정하는 문제에 초점을 둔다.

배틀로얄 장르를 직접 다룬 선행연구는 주로 순위 예측과 실력 점수 체계의 평가에서 출발하였다. 여기서 실력 점수 체계는 여러 경기 결과를 바탕으로 플레이어어나 팀의 상대적 실력을 숫자로 표현하는 방법을 의미한다. Dehpanah 등은 여러 명이 동시에 경쟁하는 온라인 게임에서 Elo, Glicko, TrueSkill과 같은 대표적인 실력 점수 체계가 순위를 얼마나 잘 예측하는지 평가하였다 [10]. 이 연구는 단순 정확도나 평균 오차보다, 예측한 순서가 실제 순서와 얼마나 잘 맞는지를 보는 순위 평가 지표가 다수 참가자의 결과를 평가하는 데 더 적합할 수 있음을 보였다. 이후 Dehpanah 등은 팀 단위 배틀로얄 게임으로 평가 범위를 확장하여, 여러 팀이 동시에 경쟁하는 환경에서는 예측 순위와 실제 순위의 차이를 어떻게 평가할지 자체가 중요한 문제가 됨을 보였다 [12].

또한 Dehpanah 등은 75,000개 이상의 배틀로얄 경기에서 추출한 행동 기록을 이용해 플레이어의 성향을 분석하고, 이를 순위 예측에 활용하였다 [11]. 이 연구에서 중요한 점은 처치와 사망, 생존 시간, 이동 거리와 같은 행동 기록이 단순한 승패 기록보다 플레이어의 전략과 성향을 더 직접적으로 보여줄 수 있다는 것이다. 이러한 연구들은 배틀로얄 장르에서 최종 순위와 플레이어 행동을 예측 대상으로 삼았다는 점에서 중요하다. 본 연구는 이 흐름을 이어받되, 각 경기 단계에서 아직 탈락하지 않은 팀을 다시 구분하고 다음 단계의 탈락 위험을 반복해서 추정하는 문제를 별도의 분석 대상으로 삼는다. 이는 경기 중 예측의 존재 여부를 구분하려는 것이 아니라, 예측 대상을 단계별 생존 과정으로 구성한다는 점에서 선행연구와 구별된다.

2.3 PUBG 대상 결과 예측 연구

PUBG: Battlegrounds(이하 PUBG)는 크래프톤(KRAFTON, Inc.)의 대표 게임이자 KRAFTON 산하 PUBG Studios가 개발한 온라인 배틀로얄 슈터이다. 2017년 독립 타이틀로 출시된 뒤, PUBG는 현대적 배틀로얄 장르의 대중화와 장르 형식의 정착에서 선구적 역할을 한 대표 사례로 평가된다 [37, 35]. PUBG에서는 다수의

플레이어가 하나의 전장에 투입되어 장비와 자원을 확보하고, 시간이 지날수록 축소되는 안전 영역 안에서 이동과 교전을 반복한다. 그 과정에서 플레이어 또는 팀이 차례로 탈락하고, 최종적으로 개인 또는 팀의 순위가 결정된다.

본 논문은 PUBG를 다중 에이전트가 하나의 경기 안에서 동시에 경쟁하고, 안전 영역의 변화에 따라 가용 공간과 생존 조건이 갱신되며, 안전 영역의 축소와 교전에 따라 탈락이 누적되는 배틀로얄 게임의 대표 사례로 다룬다. PUBG는 안전 영역 수축, 다중 에이전트 경쟁, 자원 확보, 이동, 교전, 탈락, 최종 순위라는 배틀로얄의 핵심 구조를 명확히 포함한다. 또한 공개 자료와 공식 경기 기록을 통해 경기 상태와 결과를 비교적 구체적으로 관측할 수 있기 때문에, 장르 차원의 문제 정의를 관측 가능한 입력 변수로 연결하기에 적합한 사례이다.

공개 PUBG 예측 연구의 대표적인 출발점은 Kaggle의 “PUBG Finish Placement Prediction” 대회 자료이다 [21]. Kaggle은 공개 자료 분석 대회를 제공하는 플랫폼이며, 이 대회 자료는 PUBG 경기 후에 정리된 통계를 사용해 최종 순위에 가까운 지표를 예측하도록 구성되어 있다. 예를 들어 개인 또는 그룹 단위의 처치 수, 피해량, 이동 거리, 회복 및 부스트 사용량, 경기 유형과 같은 값이 입력으로 사용된다. 예측 대상은 경기 내 최종 순위를 0과 1 사이의 상대적 위치로 정규화한 지표이다.

Rokad 등은 이 Kaggle 자료에서 추출한 29개 경기 후 집계 변수를 사용해 PUBG의 최종 순위를 예측하였다 [28]. 이들은 여러 기계학습 모형을 비교하며, 경기 후 집계된 통계가 최종 순위와 강하게 연결될 수 있음을 보였다. Sen 등도 같은 계열의 PUBG 자료에서 최종 순위를 예측하였고, 사용하는 변수의 수를 조절하면서 성능과 실행 시간을 비교하였다 [32]. 이 연구들은 PUBG의 최종 결과가 자료 기반 모형으로 예측 가능하다는 점을 보여준다.

그러나 이러한 연구들은 본 논문의 문제와 구분된다. 이들이 사용하는 입력 변수는 대부분 경기가 끝난 뒤에야 완성되는 집계 통계량이다. 최종 처치 수, 총 피해량, 전체 이동 거리, 총 회복 사용량은 최종 순위와 관련이 있을 수 있지만, 경기 도중 특정 시점에서는 아직 완전히 알 수 없는 값이다. 따라서 이러한 변수로 최종 순위를 예측하는 연구와, 경기 중 특정 단계까지 관측된 정보만으로 다음 단계의 탈락 위험을 예측하는 연구는 서로 다른 문제 설정에 속한다.

PUBG의 공식 경기 기록이 시간에 따라 변하는 상태를 분석하는 데 사용될 수 있음을 보여주는 연구도 있다. Melhart 등은 Twitch 방송에서 수집한 PUBG 시청 자료와 게임 내 사건 기록을 사용하여 시청자 반응을 순간별로 예측하였다 [25]. 이 연구의 목표는 시청자 반응 예측에 있지만, PUBG의 경기 기록을 경기 전체의 요약 통계와 함께 시간에 따라 변하는 사건과 상태로 구성할 수 있음을 보여준다. 본 연구는 이러한 가능성을 팀 단위 생존 예측 문제로 연결한다.

2.4 Sagong 등의 경기 단계 기반 PUBG 생존 연구

본 연구와 가장 가까운 직접 선행연구는 Sagong, Woo, Kim의 *Are You a Hunter or Camper?*이다 [30]. 이 연구는 PUBG 경기가 안전 영역의 축소에 따라 여러 단계로 나뉜다는 점을 명시적으로 사용하였다. 그리고 각 단계에서 관측된 플레이어의 행동을 바탕으로 플레이어가 어떤 생존 전략을 보이는지, 이후에도 살아남을 가능성이 어느 정도인지를 분석하였다.

Sagong 등은 플레이어의 공격성(Aggressiveness)과 활동성(Activeness)을 각각 “FightScore”와 “ActiveScore”라는 점수로 요약하였다. 공격성 점수는 얼마나 적극적으로 전투에 참여하는지를 나타내고, 활동성 점수는 얼마나 활발하게 이동하고 행동하는지를 나타낸다. 이 연구는 이러한 점수를 바탕으로 플레이어를 공격적으로 싸우는 유형(Hunter), 먼 거리에서 교전하는 유형(Sniper), 이동을 많이 하는 유형(Traveler), 전투를 피하며 버티는 유형(Camper)의 네 가지로 구분하였다. 이후 여러 예측 모형을 사용해 다음 단계까지 생존할 수 있는지와 최종적으로 승리할 가능성이 있는지를 예측하였다. 이 연구는 PUBG의 생존 예측이 경기 종료 후 통계에만 의존하지 않고, 경기 단계별 상태와 행동 특성을 이용해 수행될 수 있음을 보여준다는 점에서 중요하다.

본 논문은 Sagong 등의 연구를 출발점으로 삼아 세 측면에서 확장한다. 첫째, Sagong 등의 연구는 주로 개인 플레이어를 중심으로 진행되었지만, 본 연구는 팀을 기본 분석 단위로 삼는다. 배틀로얄의 듀오 또는 스쿼드 경기에서는 팀 전체의 생존 여부가 탈락 위험과 최종 순위로 연결되기 때문이다. 둘째, Sagong 등의 연구는 플레이어의 행동 성향을 요약한 점수를 중심으로 한다. 본 연구는 이러한 점수 기반 접근을 중요한 선행 기준으로 인정하되, 공식 경기 기록에서 팀의 현재 상태, 이동 방식, 안전 영역의 변화, 교전, 자원 상태와 주변 팀과의 관계를 경기 단계별로 다시 구성한다.

셋째, 본 연구는 경기 단계별 예측을 수행하는 데서 더 나아가, 배틀로얄 장르의 생존 구조를 먼저 정식화한다. 즉, 각 단계에서 어떤 팀이 아직 탈락하지 않고 남아 있는지, 안전 영역의 변화와 가용 공간의 감소가 각 팀의 생존 환경을 어떻게 바꾸는지, 주변 팀과의 거리와 교전 접촉이 다음 단계의 탈락 위험을 어떻게 형성하는지를 하나의 생존 과정으로 표현한다. 이 점에서 Sagong 등의 연구는 본 논문의 가장 가까운 출발점이지만, 본 논문은 이를 팀 단위 탈락 위험, 누적 생존 점수, 같은 경기 안에서 남은 팀들의 상대적 생존 조건 비교로 확장한다.

2.5 생존 분석 관점의 예측 연구

생존 분석은 관심 사건이 발생할 때까지의 시간을 다루는 통계적 방법론이다. 연속 시간에서는 Cox의 비례위험모형이 대표적이며 [9], 관측이 구간 단위로 이루어지

는 경우에는 이산시간 생존 분석이 사용된다 [3, 33]. 이산시간 생존 분석은 각 구간에서 아직 사건이 발생하지 않은 대상들의 집합을 위험 집합으로 정의하고, 그 구간 안에서 사건이 발생할 조건부 확률을 위험으로 추정한다. 이 틀에서 전체 생존 확률은 구간별 위험의 누적으로 표현된다.

게임 연구에서도 생존 분석의 문제 설정이 사용되어 왔다. Periañez 등은 모바일 게임에서 플레이어의 이탈 시점을 생존 분석과 앙상블 모형으로 예측하였다 [1]. 앞서 살펴본 Dota 2의 사망 예측 연구 [22]도 가까운 시간 안에 사건이 발생할 가능성을 추정한다는 점에서 같은 계열에 속한다. 배틀로얄 장르는 안전 영역의 축소가 경기를 자연스러운 구간으로 나누기 때문에, 구간마다 위험 집합을 다시 구성하는 이산시간 생존 분석의 구조와 잘 맞는다.

본 논문은 이 어휘를 채택하여, 경기 단계를 이산 구간으로, 아직 탈락하지 않은 팀들의 집합을 위험 집합으로, 다음 단계 탈락 여부를 구간 내 사건으로 대응시킨다. 다만 고전적 생존 분석의 모수적 추정 대신, 단계별 위험을 기계학습 모형으로 추정하고 그 위험의 누적으로 팀의 누적 생존 점수를 표현한다. 이 대응은 3장의 문제 정식화에서 형식적으로 정의된다.

2.6 본 연구의 위치

정리하면, 온라인 게임 결과 예측 연구는 경기 중 상태와 사건이 결과 예측에 유용한 자료가 될 수 있음을 보여주었다. 배틀로얄 예측 연구는 이 기반 위에서 여러 팀이 동시에 경쟁하고, 탈락과 최종 순위가 결과로 나타나며, 안전 영역 수축에 따라 생존 조건이 바뀐다는 장르적 특성을 다룬다. PUBG 대상 연구들은 경기 후 집계 통계만으로도 최종 순위가 어느 정도 예측 가능하다는 점을 보였고, Sagong 등의 연구는 PUBG 생존 예측을 경기 단계별 문제로 다루는 중요한 전환점을 제공하였다.

본 논문은 이 흐름을 이어받아, 배틀로얄을 경기 단계마다 생존 조건이 갱신되는 다중 에이전트 생존 과정으로 정식화한다. 그리고 PUBG의 공식 경기 기록을 이용해 팀 단위의 관측 시점과 아직 탈락하지 않은 팀들의 집합을 정의하고, 이를 다음 단계 탈락 위험, 누적 생존 점수, 같은 경기 안에서 남은 팀들 사이의 상대적 생존 가능성 비교로 구체화한다.

이러한 선행연구의 범위는 본 논문의 네 연구 문제로 이어진다. 먼저 장르의 생존 과정을 정식화하고, 이를 PUBG 공식 기록에서 단계별 상태, 이전 시점의 기록과 팀 관계로 표현한다. 이어 그 표현이 실제 생존과 탈락을 구분하는지와 자료 구조에 적합한 모형을 검토하고, 마지막으로 단계별 위험을 경기 중 상대적 생존 평가로 확장한다. 다음 장은 이 가운데 연구 문제 1인 배틀로얄 생존 과정의 정식화부터 시작한다.

Chapter 3

배틀로얄 생존 과정의 정식화

3.1 연구 문제 1과 정식화의 목적

앞 장에서는 온라인 게임 결과 예측 연구, 배틀로얄 장르의 순위 및 예측 연구, PUBG 대상 예측 연구, 그리고 Sagong 등의 경기 단계 기반 생존 연구를 검토하였다. 이 장은 연구 문제 1에 답하기 위해, 그 흐름을 바탕으로 배틀로얄의 생존 과정을 구성하는 단위와 이들 사이의 관계를 정의한다.

본 논문은 배틀로얄의 결과를 경기 종료 후의 최종 순위와 함께, 경기 단계별 생존 조건과 팀의 반응이 누적되는 과정으로 해석한다. 배틀로얄 경기에서는 시간이 지날수록 안전 영역, 생존 팀 수, 가용 공간, 이동 경로, 교전 가능성이 함께 변한다. 따라서 어느 팀이 최종적으로 높은 순위를 기록했는지는, 각 경기 단계에서 달라진 생존 조건과 그 조건에 대한 팀의 반응이 누적된 결과로 이해할 필요가 있다.

본 장의 핵심 질문은 다음과 같다.

배틀로얄 장르는 경기 진행에 따라 생존 조건이 갱신되는 다중 에이전트 생존 과정으로 어떻게 정식화할 수 있는가?

이에 답하기 위해 본 장은 경기, 팀, 경기 단계, 아직 탈락하지 않은 팀들의 집합, 다음 단계 탈락 여부, 탈락 위험, 누적 생존 점수, 같은 경기 안에서 남은 팀들의 상대적 생존 조건 비교를 차례로 정의한다. PUBG의 구체적인 공식 경기 기록 구조와 전처리 절차는 다음 장에서 다루며, 본 장에서는 대표적인 배틀로얄 게임에서 반복되는 생존 구조를 예측 문제로 옮기기 위해 필요한 기본 단위를 정의한다. 본 논문은 이와 같이 경기 단계를 조건으로 생존 과정을 다루는 정식화를 단계 조건부 생존 분석이라 부른다.

Table 3.1: 본 논문에서 참조하는 대표 배틀로얄 게임군

구분	대표 사례	논문 내 역할
전형적 전투 중심 배틀로얄	PUBG, Fortnite, Apex Legends, Call of Duty: Warzone, Garena Free Fire	축소 구역, 무장, 이동, 교전, 최종 생존 구조가 결합된 중심 사례
능력 및 시스템 변형 사례	NARAKA: BLADEPOINT, Eternal Return, Super Animal Royale	전투 방식, 시점, 캐릭터 능력, 자원 체계가 달라도 생존 및 탈락 구조가 유지되는 변형 사례
충격전 없는 탈락형 게임	Fall Guys, Tetris 99, F-ZERO 99	충격전 없이도 단계별 생존 조건, 탈락, 최종 순위가 나타나는 사례

3.2 대표 배틀로얄 게임군과 공통 구조

배틀로얄 장르의 여러 게임 유형을 포함한다. 본 논문은 PUBG를 주요 실증 사례로 사용하면서, 먼저 대표적인 배틀로얄 및 배틀로얄형 게임들을 살펴보고 그 사이에서 반복되는 생존 구조를 정리한다. 대표 게임군은 배틀로얄 장르를 설명하는 공개 문서와 배틀로얄 게임 목록 문서를 참고하되 [35, 36], 장르 전체의 고정된 분류표보다 공통 구조를 확인하기 위한 참고 목록으로 사용한다.

이 사례들은 전투 방식, 시점, 조작 체계, 자원 시스템, 공간 구조가 서로 다르다. 그러나 생존 예측의 관점에서는 몇 가지 공통 구조를 공유한다. 첫째, 하나의 경기 안에 여러 플레이어 또는 팀이 동시에 존재한다. 둘째, 각 플레이어 또는 팀은 능력, 생존 인원, 보유 자원, 이동 수단, 장비, 능력과 같은 생존 상태를 가진다. 셋째, 안전 영역, 폭풍, 링, 안개, 단계별 통과 기준처럼 시간이 지남에 따라 생존 조건을 바꾸는 규칙이 존재한다. 넷째, 플레이어 또는 팀은 이동, 회피, 공격, 자원 확보, 경로 선택, 대상 선택을 통해 변화하는 조건에 반응한다. 다섯째, 최종 결과는 단순 점수와 함께 생존, 탈락, 최종 순위, 승리와 같은 생존 결과로 표현된다.

따라서 본 논문에서 배틀로얄의 공통점은 특정 무기, 특정 지도, 특정 안전 영역 규칙보다 하나의 경기 안에서 다중 에이전트가 경쟁하고, 시간이 지나면서 생존 가능한 조건이 갱신되며, 그 갱신된 조건 속에서 탈락과 순위가 결정된다는 구조에 있다. 각 게임은 고유한 규칙과 기록 체계를 가지므로, 본 장의 정식화는 공통적인 질문의 형태를 제시하고 구체적인 변수 구성은 게임별로 달라질 수 있음을 전제로 한다.

반대로 이 공통 구조가 성립하지 않는 게임은 본 논문의 정식화 대상이 아니다. 예를 들어 탈락한 플레이어가 계속 다시 투입되는 팀 전투 모드나 정해진 시간 동안 점수를 겨루는 대전 방식에서는 시간에 따라 생존 조건이 달라지고 참가자가 순차

적으로 탈락하는 구조가 성립하지 않는다. 따라서 본 장의 요인 구분은 배틀로얄 여부를 판별하는 분류 체계가 아니라, 위 공통 구조를 만족하는 게임의 생존 과정을 나누어 살펴보기 위한 분석 기준이다. 이 공통 구조가 대표 사례들에서 실제로 확인되는지는 6장의 사례 검토에서 다룬다.

3.3 경기, 팀, 경기 단계

먼저 하나의 배틀로얄 경기를 m 으로 표기한다. 경기 m 에 참여한 팀들의 집합은 $\mathcal{I}_m$ 으로 둔다. 솔로 경기에서는 한 명의 플레이어를 하나의 팀으로 볼 수 있고, 듀오 또는 스쿼드 경기에서는 여러 플레이어가 하나의 팀을 구성한다. 본 논문의 기본 분석 단위는 팀이다.

배틀로얄 경기는 시간에 따라 여러 단계로 나뉜다. 이를 다음과 같이 표기한다.

$$k = 0, 1, \dots, K_m \quad (3.1)$$

여기서 k 는 경기 단계의 번호이다. 본 논문에서 경기 단계는 같은 길이로 자른 시간 구간보다, 안전 영역 갱신, 가용 공간 변화, 생존 팀 수 변화, 탈락 조건 변화처럼 생존 조건이 구조적으로 달라지는 분석 단위에 가깝다. 따라서 단계 k 의 예측 시점은 팀의 상태와 경기 환경을 관측하고, 이후 구간의 탈락 위험을 예측하는 시점이 된다.

단계 k 에서 아직 탈락하지 않은 팀들의 집합을 다음과 같이 정의한다.

$$\mathcal{R}_m(k) = \{i \in \mathcal{I}_m : \text{팀 } i \text{가 단계 } k \text{에서 생존}\}. \quad (3.2)$$

$\mathcal{R}_m(k)$ 는 경기 m 의 단계 k 에서 여전히 생존해 있어 다음 단계의 탈락 위험을 논할 수 있는 팀들의 집합이다. 이는 2장에서 살펴본 이산시간 생존 분석의 위험 집합에 대응한다. 이미 탈락한 팀은 더 이상 다음 단계의 생존 여부를 예측할 대상이 아니므로 평가에서 제외된다.

여기서 팀의 생존은 팀원 중 최소 한 명이 아직 탈락하지 않은 상태를 의미하고, 팀의 탈락은 마지막 생존 팀원이 제거되어 팀 전체가 더 이상 경기에 참여할 수 없게 된 시점을 의미한다. 기절과 부활처럼 게임 규칙에 따라 달라지는 세부 판정은 4장의 자료 정의에서 다룬다.

3.4 다음 단계 탈락 여부

배틀로얄의 최종 순위는 중요한 결과이지만, 본 논문은 최종 순위의 직접 예측에 앞서 특정 단계까지 살아남은 팀이 다음 단계에서 탈락하는지를 우선적으로 예측

한다. 단계 k 에서 팀 i 가 아직 생존해 있다고 할 때, 다음 단계 구간에서 팀 i 가 탈락하는지를 다음과 같이 표시한다.

$$Y_i^m(k+1) = \begin{cases} 1, & \text{다음 단계에서 탈락,} \\ 0, & \text{그렇지 않음.} \end{cases} \quad (3.3)$$

이 값은 단계 k 까지 관측한 정보로 $k+1$ 구간의 탈락 여부를 예측하기 위한 목표값이다. $Y_i^m(k+1)$ 을 만들 때는 실제 탈락 시점과 단계 경계를 사용한다. 입력에는 1단계가 시작된 뒤 단계 k 가 끝날 때까지 관측한 기록을 포함하며, $k+1$ 단계가 시작된 뒤의 정보는 포함하지 않는다.

이 정의에서 최종 순위는 각 단계의 탈락 위험이 누적되어 나타나는 결과로 해석한다. 즉, 본 논문은 최종 결과를 하나의 고정된 값으로 바로 예측하기보다, 단계마다 갱신되는 탈락 위험을 먼저 예측하고, 그 위험의 누적이 누적 생존 점수와 최종 순위 관련 평가로 이어지는 구조를 취한다.

한편 예측은 다음 단계가 존재하는 $k < K_m$ 의 단계에서만 수행한다. 마지막까지 생존한 팀은 탈락 사건 없이 관측이 종료되며, 이는 생존 분석의 중도절단에 대응한다. 단계 번호의 구체적인 범위와 착륙 구간의 처리는 4장에서 정의한다.

3.5 예측 시점에서 사용할 수 있는 정보

단계 k 에서 다음 단계의 탈락 위험을 예측하려면, 그 시점까지 실제로 확인할 수 있는 정보만 입력으로 사용해야 한다. 본 논문은 단계 k 까지 팀 i 에 대해 사용 가능한 정보, 즉 관측 이력을 $\mathcal{F}_i^m(k)$ 로 표기한다. 여기에는 경기 맥락, 팀 상태, 이동 기록, 안전 영역 상태, 교전 사건, 자원 상태, 주변 팀과의 관계처럼 단계 k 까지 확인된 정보가 포함된다. 이는 단계 k 의 상태 한 번만을 뜻하지 않는다. 1단계부터 k 단계까지의 단계별 상태와 관계, 경기 시작 이후 k 단계 종료 시점까지의 세부 기록을 모두 포함한다. $\mathcal{F}_i^m(k)$ 는 경기 m 에서 관측 가능한 전체 이력 가운데 팀 i 를 중심으로 정리한 것이며, 본 논문은 개별 플레이어의 제한된 시야가 아니라 공식 경기 기록이 제공하는 관전자 관점을 취한다.

$$\mathcal{F}_i^m(k) = \{\text{1단계 시작부터 단계 } k \text{ 종료까지 확인된 상태, 사건과 팀 관계}\}. \quad (3.4)$$

단계 k 이후에 발생한 피해량, 이동 거리, 탈락 사건, 최종 순위, 승리 여부는 해당 시점의 입력에서 제외한다. 이러한 값은 목표값을 만들거나 사후 평가에 사용하는 항목이다.

이 제한은 모형이 실제 경기 진행 중에는 알 수 없는 사후 정보를 학습하지 않

도록 하기 위한 것이다. 예를 들어 경기 종료 후 집계된 총 처치 수, 총 피해량, 전체 이동 거리와 같은 변수는 최종 순위와 관련이 있을 수 있다. 그러나 단계 k 에서 아직 확인되지 않은 값이라면, 그 단계의 탈락 위험을 예측하는 입력에서 제외한다.

3.6 주요 생존 요인과 게임별 관측 방식

본 논문은 대표적인 배틀로얄 게임에서 반복적으로 나타나는 생존 조건을 주요 생존 요인으로 정리한다. 각 요인은 게임별 원자료 항목을 공통된 분석 질문에 대응시키는 범주이며, 실제 관측값은 게임의 규칙과 기록 방식에 따라 달라진다.

실제 모형 변수는 두 부분으로 구성된다. 첫째는 여러 배틀로얄 게임에서 반복되는 생존 요인을 측정한 값이다. 둘째는 특정 게임의 규칙, 기록 방식, 아이템 체계와 사건 정의에 따라 추가되는 값이다. 이를 개념적으로 쓰면 다음과 같다.

$$\mathbf{x}_i^m(k) = [\mathbf{x}_{i,\text{공통}}^m(k), \mathbf{x}_{i,\text{고유}}^m(k)]. \quad (3.5)$$

여기서 $\mathbf{x}_{i,\text{공통}}^m(k)$ 는 여러 배틀로얄 게임에서 반복되는 생존 요인을 측정한 값이고, $\mathbf{x}_{i,\text{고유}}^m(k)$ 는 PUBG처럼 특정 게임의 규칙과 기록 체계에 따라 추가되는 값이다. 이 구분을 통해 장르 수준의 생존 요인과 PUBG 공식 경기 기록에서 계산한 값을 구별하여 해석한다.

표 3.2는 여러 게임의 생존 조건을 같은 기준으로 살펴보기 위한 분석 범주를 제시한다. 전형적인 전투 중심 배틀로얄에서는 대부분의 항목을 직접 관측할 수 있다. 총격전이 없는 탈락형 게임에서는 게임의 규칙에 맞는 값이 각 범주에 대응한다. 예를 들어 PUBG의 장비, 회복 아이템과 차량은 생존 자원에 해당하며, 다른 게임에서는 캐릭터 능력, 단계 통과 기회와 배치상의 이점이 같은 범주에 해당할 수 있다. 장르 수준의 공통성은 이처럼 시간에 따라 달라지는 생존 조건을 같은 질문으로 구분하고 비교할 수 있다는 데 있다.

표의 괄호 표기와 같이, 이후 장에서는 이 요인 구분을 00–07 번호로도 참조한다. $H_i^m(k)$ 는 $Z_m(k)$, $G_i^m(k)$ 와 남은 팀의 배치를 결합한 값이므로 별도의 번호 없이 표기한다. 생존, 탈락, 최종 순위와 같은 결과는 08에 해당하며, 목표값과 평가에 사용한다. 또한 이후 장에서 경기와 단계가 문맥상 자명한 경우에는 U , Z , H 처럼 위첨자와 아래첨자를 생략하여 적는다.

각 기호는 해당 요인을 구성하는 여러 관측값을 묶은 벡터다. 예를 들어 $C_i^m(k)$ 에는 생존 인원과 체력처럼 팀 자체의 상태가, $Z_m(k)$ 에는 안전 영역의 크기와 남은 팀 수처럼 같은 단계의 모든 팀에 공통인 값이 들어갈 수 있다. 게임 g 에서 실제로 관측 가능한 성분의 수를 $d_U^{(g)}, \dots, d_H^{(g)}$ 로 두면, 단계 k 의 전체 요인 벡터는 다음과 같이 쓸 수 있다.

Table 3.2: 단계 k 에서의 주요 생존 요인과 게임별 관측 예

기호	주요 생존 요인	게임에서 관측되는 예
$U_m(k)$ (O0)	경기 규칙과 환경	경기장 또는 지도 유형, 모드, 팀 규모, 단계 번호, 경과 시간
$C_i^m(k)$ (O1)	생존 단위의 상태	생존 인원, 체력 또는 목숨, 개인 또는 팀 구성, 행동 가능한 상태
$Z_m(k)$ (O2)	단계별 생존 조건	안전 영역, 폭풍, 링, 안개, 통과 기준, 남은 시간, 남은 팀 수
$B_i^m(k)$ (O3)	이동과 위치 변화	이동량, 속도, 경로 전환, 안전한 공간으로 들어가거나 위험 지역을 피하는 행동
$E_i^m(k)$ (O4)	위험 노출	피해, 교전, 접촉, 가까운 팀이나 플레이어, 혼잡도, 주변 경쟁 정도
$R_i^m(k)$ (O5)	생존 자원	회복, 방어, 장비, 이동 수단, 캐릭터 능력처럼 생존을 돕거나 선택지를 넓히는 요소
$G_i^m(k)$ (O6)	공간 조건	현재 위치, 안전한 공간까지의 거리, 이동 가능한 경로, 유리하거나 불리한 지형과 공간
$Q_i^m(k)$ (O7)	주변 경쟁자와의 관계	근처 팀 또는 플레이어, 교전 관계, 같은 공간으로 몰리는 경쟁자, 지역 밀도
$H_i^m(k)$	현재 위치와 주변 상황	단계별 생존 조건, 현재 위치, 가용 공간과 남은 경쟁자 배치를 함께 고려한 조건

$$\Phi_i^m(k) = [U_m(k) \parallel C_i^m(k) \parallel Z_m(k) \parallel B_i^m(k) \parallel E_i^m(k) \parallel R_i^m(k) \parallel G_i^m(k) \parallel Q_i^m(k) \parallel H_i^m(k)]. \quad (3.6)$$

여기서 $\parallel$ 는 각 벡터를 순서대로 결합하는 연산을 뜻한다. 각 게임은 실제로 관측할 수 있는 성분을 사용하며, 필요한 경우 같은 생존 요인을 나타내는 다른 관측값을 대응시킨다. PUBG에서 사용한 각 성분의 변수명, 계산 방법, 단위와 정규화 기준값은 5장과 부록에 제시한다.

$\Phi_i^m(k)$ 는 단계 k 하나에서 관측한 요인을 모은 값이다. 시간의 흐름을 사용하는 모형에는 현재 단계의 값만 넘기지 않고, 1단계부터 k 단계까지의 값을 순서대로 제공한다. 이 순서를 다음과 같이 표기한다.

$$\Phi_i^m(1:k) = (\Phi_i^m(1), \Phi_i^m(2), \dots, \Phi_i^m(k)). \quad (3.7)$$

단계 k 의 요약값 한 행만 사용하는 기준선과 예측 직전의 10초 기록만 사용하는 기준선은 6장의 비교 실험에서 따로 구분한다.

이 중 $H_i^m(k)$ 는 여러 조건을 함께 고려한 팀의 현재 위치와 주변 상황을 나타낸다. 구체적으로 단계별 생존 조건, 팀의 위치, 이용할 수 있는 공간과 아직 남아 있는 팀의 배치가 결합된 상태를 의미한다. 이를 개념적으로 쓰기 위해, 위험

집합에 남은 팀들의 상태와 공간 배치를 다음과 같이 둔다.

$$\mathcal{P}_m(k) = \{(C_j^m(k), G_j^m(k), Q_j^m(k)) : j \in \mathcal{R}_m(k)\}. \quad (3.8)$$

그러면 팀의 현재 위치와 주변 상황은 다음과 같이 나타낼 수 있다.

$$H_i^m(k) = h(Z_m(k), G_i^m(k), \mathcal{P}_m(k)). \quad (3.9)$$

예를 들어 같은 위치라도 사용할 수 있는 공간이 넓은 초반 단계와 공간이 급격히 줄어든 후반 단계에서는 그 위치의 의미가 달라진다. 같은 공간 크기라도 남아 있는 팀 수가 많으면 공간 밀도가 커지고, 주변 팀이 밀집해 있으면 이동 경로와 교전 가능성이 달라진다. 따라서 $H_i^m(k)$ 는 현재 단계의 생존 조건과 주변 팀의 배치를 고려하여 해당 위치의 상대적인 유리함을 나타낸다.

위험 노출 $E_i^m(k)$ 은 특정 게임의 교전 횟수에 더해, 팀의 이동이 주변 팀이나 플레이어의 배치와 겹치고 그 결과 실제 접촉, 피해, 경쟁으로 이어지는 과정을 함께 반영한다. 이를 개념적으로 쓰면 다음과 같다.

$$E_i^m(k) = e(B_i^m(k), Q_i^m(k), A_i^m(k)). \quad (3.10)$$

여기서 $A_i^m(k)$ 는 단계 k 까지 기록된 사건의 종류, 횟수와 강도를 모은 사건 벡터다. 어떤 게임에서는 총격과 피해가 중심 사건이 될 수 있고, 다른 게임에서는 충돌, 탈락 판정, 단계 통과 실패가 중심 사건이 될 수 있다. 핵심은 위험 노출이 팀의 이동, 주변 팀과의 관계, 그리고 게임이 기록하는 사건의 결합으로 형성된다는 점이다.

3.7 다음 단계 탈락 위험

본 논문의 핵심 예측량은 단계 k 에서 팀 i 가 다음 단계에 탈락할 가능성이다. 이를 탈락 위험이라고 부르고, 다음과 같이 표기한다.

$$\lambda_i^m(k) = \Pr(Y_i^m(k+1) = 1 \mid \mathcal{F}_i^m(k)). \quad (3.11)$$

위 식은 단계 k 까지 관측된 정보가 주어졌을 때, 팀 i 가 $k+1$ 구간에서 탈락할 확률을 의미한다. 이때 조건으로 주어지는 $\mathcal{F}_i^m(k)$ 는 단계 k 의 값 하나가 아니라 $\Phi_i^m(1:k)$, 단계 k 종료까지의 10초 기록과 같은 기간에 관측한 팀 관계를 함께 포함한다. 이 확률을 예측 함수로 나타내면 다음과 같다.

$$\lambda_i^m(k) = F_\theta(\mathcal{F}_i^m(k)). \quad (3.12)$$

여기서 F_θ 는 주요 생존 요인으로부터 다음 단계의 탈락 위험을 추정하는 매개변수

θ 의 예측 함수다. 앞 절에서 정의한 모형 변수 $\mathbf{x}_i^m(k)$ 는 $\Phi_i^m(k)$ 의 각 요인을 게임에서 관측 가능한 값으로 옮긴 한 단계의 변수다. 모형은 이를 1단계부터 현재 단계까지 순서대로 읽어 관측 이력을 요약한다. $H_i^m(k)$ 는 $Z_m(k)$, $G_i^m(k)$ 와 남은 팀의 배치를 함께 반영하므로, 모형에 따라 개별 요인과 현재 위치 및 주변 상황을 함께 사용하거나 일부 요인만 선택할 수 있다. 실제 PUBG 분석에서는 각 요인을 공식 경기 기록에서 계산할 수 있는 변수로 옮긴다. PUBG의 기절, 부활, 차량, 회복 및 부스트처럼 특정 게임의 규칙에 의해 의미가 정해지는 값은 게임 고유 요소로 별도로 해석한다. 따라서 본 정식화의 핵심은 모형 종류보다, 배틀로얄 결과를 단계별 탈락 위험의 흐름으로 보고 모형 변수를 반복되는 생존 요인과 게임 고유 요소로 나누어 해석하는 데 있다.

이 관점은 경기 종료 후 통계를 사용해 최종 순위를 예측하는 접근과 다르다. 경기 종료 후 접근은 이미 완성된 경기 요약과 최종 결과 사이의 관계를 학습할 수 있다. 반면 본 논문의 정식화는 경기가 아직 진행 중인 단계 k 에서, 팀이 다음 단계까지 살아남을 수 있는지를 묻는다. 따라서 예측의 기본 단위는 다음과 같다.

$$(m, i, k), \quad i \in \mathcal{R}_m(k). \quad (3.13)$$

이는 경기 m , 팀 i , 경기 단계 k 의 조합을 하나의 예측 사례로 본다는 뜻이다.

같은 경기 안의 탈락 사건들은 서로 독립이 아니다. 한 팀의 처치는 다른 팀의 탈락을 의미하고, 안전 영역의 축소는 남은 팀들에게 공통 충격으로 작용하며, 단계별 탈락 수에는 경기 구조가 부여하는 제약이 있다. 본 정식화는 이러한 팀 간 결합 분포 전체를 모형화하기보다, 주변 팀의 상태와 배치를 조건부 정보에 포함한 개별 팀의 조건부 탈락 위험을 예측 대상으로 삼는다. 같은 경기에서 나온 예측 사례들 사이의 의존성은 실험 설계에서 경기를 기준으로 군집화하여 처리하며, 이는 6장에서 설명한다.

3.8 탈락 위험의 누적과 생존 점수

단계별 탈락 위험을 연속해서 결합하면, 경기 진행 과정에서 각 팀이 받아 온 위험을 하나의 값으로 요약할 수 있다. 초기값을 $S_i^m(0) = 1$ 로 두고, 누적 생존 점수를 다음과 같이 갱신한다.

$$S_i^m(k+1) = S_i^m(k) (1 - \lambda_i^m(k)). \quad (3.14)$$

이 값은 미래의 생존을 직접 전망하는 확률이 아니라, 단계별 탈락 위험 아래에서 팀 i 가 지금까지 지나온 경로를 모형의 관점에서 누적인 점수이다. 각 $\lambda_i^m(j)$ 는 서로 다른 시점의 관측 이력에 조건부이므로, 이 곱을 하나의 결합 확률로 해석하지

않는다. 따라서 이 식은 탈락 사건들 사이의 독립성을 가정하기 위한 것이 아니라, 시점마다 달라지는 탈락 위험을 비교 가능한 누적값으로 요약하기 위해 사용한다.

같은 경기에서 남아 있는 팀들을 비교하기 위해, 누적 생존 점수를 해당 단계의 위험 집합 안에서 정규화한다.

$$\pi_i^m(k) = \frac{S_i^m(k)}{\sum_{j \in \mathcal{R}_m(k)} S_j^m(k)}. \quad (3.15)$$

$\pi_i^m(k)$ 는 실제 승률이나 최종 우승 확률이 아니라, 같은 경기와 같은 단계에서 남아 있는 팀들의 누적 생존 점수 합을 1로 맞춘 값이다. 이 값은 현재 조건에서 상대적으로 유리한 팀을 식별하고, 이후의 최종 상위권 결과와 어떤 관련이 있는지를 평가하는 데 사용한다.

3.9 탈락 위험 순위와 누적 생존 점수 순위

위 정식화는 경기 단계가 바뀔 때마다 두 가지 순위를 산출한다. 첫째는 다음 단계에 탈락할 가능성이 높은 팀을 높은 순서대로 정렬한 탈락 위험 순위이다.

$$\mathcal{B}_m^{\text{risk}}(k) = \text{rank}_{i \in \mathcal{R}_m(k)}^{\downarrow} \lambda_i^m(k). \quad (3.16)$$

이 순위는 다음 단계에서 가장 탈락 가능성이 높은 팀을 식별하는 데 사용된다.

둘째는 경기 내 생존 점수 비율이 높은 팀을 먼저 놓는 누적 생존 점수 순위이다.

$$\mathcal{B}_m^{\text{surv}}(k) = \text{rank}_{i \in \mathcal{R}_m(k)}^{\downarrow} \pi_i^m(k). \quad (3.17)$$

이 순위는 현재 단계에서 상대적으로 유리한 팀을 식별하는 데 사용된다. 본 논문의 후반부 실험은 이 두 순위가 실제 다음 단계 탈락과 최종 결과를 얼마나 잘 반영하는지를 평가한다.

3.10 PUBG 사례로의 연결

지금까지의 정식화는 대표적인 배틀로얄 게임에서 반복되는 생존 구조를 예측 문제로 옮기기 위한 분석 관점을 제시한다. 실증 분석에서는 각 항을 실제 경기 기록의 관측 단위와 대응시켜야 한다. PUBG는 안전 영역의 진행, 팀 구성, 시간 순서가 있는 위치 기록, 교전 사건, 탈락 여부와 최종 순위를 공식 경기 기록으로 제공한다. 따라서 위 정식화를 팀과 경기 단계의 조합으로 구체화할 수 있는 대표적인 사례이다.

이 기록에서 경기와 팀의 식별자는 각각 m 과 i 에, 안전 영역의 진행 단계는 k 에 대응한다. 각 단계까지 생존한 팀으로 $\mathcal{R}_m(k)$ 를 구성하고, 탈락 사건으로 $Y_i^m(k+1)$

를 정하며, 해당 단계까지 기록된 위치와 사건을 $\mathcal{F}_i^m(k)$ 에 포함할 수 있다. 이와 같이 정식화의 기본 단위는 PUBG 공식 기록에서 직접 구성할 수 있다.

다만 모든 생존 조건이 같은 정밀도로 기록되는 것은 아니다. 안전 영역, 팀 상태, 이동과 교전은 공식 기록에서 직접 확인하거나 계산할 수 있지만, 지형의 의미, 건물에 의한 시야 차단, 장애물과 실제 시야선은 직접 관측되지 않아 관련된 간접 지표를 사용해야 한다. 기절, 부활, 차량, 회복 및 부스트는 PUBG의 규칙과 기록 체계에 따라 의미가 정해지는 값이므로 장르에서 반복되는 생존 요인과 구분할 필요가 있다. 다음 장에서는 이러한 대응 관계를 바탕으로 관측 단위와 전처리 절차를 설명하고, 모형 변수를 여러 배틀로얄 게임에서 공통으로 관찰되는 요인과 PUBG의 고유 규칙을 반영한 요인으로 나누어 제시한다.

3.11 연구 문제 1에 대한 이론적 답변과 적용 범위

본 장의 정식화가 갖는 의미는 세 가지로 정리된다. 첫째, 배틀로얄은 경기 단계마다 생존 조건이 갱신되는 다중 에이전트 생존 과정으로 분석될 수 있다. 둘째, 다음 단계 탈락 위험은 최종 순위를 바로 예측하는 것보다 경기 중 생존 과정을 더 직접적으로 표현하는 예측 대상이다. 셋째, 단계별 탈락 위험은 누적 생존 점수로 이어지고, 같은 경기 안에서 남은 팀들의 상대적 생존 조건을 비교하는 데 사용할 수 있다. 이를 통해 탈락 위험 순위와 누적 생존 점수 순위를 구성할 수 있다.

이로써 연구 문제 1에는 배틀로얄을 경기 단계, 생존 팀의 집합, 다음 단계 탈락 위험과 누적 생존 점수가 연결되는 과정으로 정식화할 수 있다고 답할 수 있다. 이어지는 장은 이 이론적 답변의 측정 가능성과 예측 타당성을 확인한다. 4장과 5장은 연구 문제 2에 따라 각 구성 요소를 PUBG 공식 경기 기록의 단계별 상태, 10초 간격의 연속 기록과 팀 관계로 표현한다. 6장과 7장은 연구 문제 3과 4에 따라 이 표현이 실제 탈락을 구분하는지, 어떤 모형이 적합한지, 단계별 위험을 경기 중 생존 평가로 사용할 수 있는지를 검증한다.

본 장의 적용 범위는 이후의 입력 자료와 실험이 따라야 할 문제 정의와 예측 시점의 정보 사용 원칙을 명확히 하는 데 있다. 배틀로얄 장르 전체의 분류, PUBG를 통한 장르 전체의 대표성 주장, 게임의 인과 구조 전체에 대한 증명은 본 장의 범위 밖에 둔다. 따라서 본 논문의 실험 결과는 PUBG 자료에 대한 검증으로 해석하며, 다른 배틀로얄 게임에 적용할 때는 해당 게임의 규칙, 단계 구조, 사건 기록 방식에 맞는 재구성이 필요하다.

Chapter 4

PUBG 공식 경기 기록과 분석 자료의 구성

4.1 연구 문제 2와 자료의 범위

본 연구는 2026년 3월 26일부터 2026년 6월 2일까지 PUBG 공식 API를 통해 수집한 경기 메타데이터와 텔레메트리 사건 기록을 사용한다. 최종 분석 자료는 지도, 시점, 팀 규모의 조합으로 구분한 13개 분석 집단의 17,943경기이다. 튜토리얼과 훈련장, 목표값 또는 팀 위치 기록이 결손된 경기, 표본이 충분하지 않은 지도와 모드 조합은 분석에서 제외하였다. 이 가운데 Erangel TPP 스쿼드 6,204경기를 대표 분석 집단으로 설정하고, 나머지 12개 분석 집단은 대표 집단에서 확인한 결과가 다른 경기 조건에서도 반복되는지 검토하는 데 사용하였다.

본 장은 연구 문제 2에 답하기 위한 첫 단계로, PUBG 공식 경기 기록이 3장에서 정의한 배틀로얄 생존 과정의 분석 단위로 어떻게 정리되었는지를 설명한다. PUBG 공식 기록에는 경기 중 위치, 안전 영역, 교전, 피해, 탈락, 아이템 사용, 최종 순위 등 다양한 사건이 포함된다. 그러나 이러한 원자료가 곧바로 모형의 입력 변수가 되는 것은 아니다. 본 연구는 공식 기록의 원래 의미를 보존한 저장 계층을 먼저 구성한 뒤, 이를 경기, 팀, 경기 단계, 10초 시점, 팀 간 관계 단위의 연구용 자료로 재구성하였다.

4.2 공식 기록의 구성과 저장

PUBG 공식 API에서 수집한 자료는 크게 세 유형으로 구분된다. 첫째, 경기 메타데이터는 경기 식별자, 지도, 게임 모드, 생성일, 경기 길이 등 경기 수준의 정보를 포함한다. 둘째, 팀 및 참가자 기록은 팀 구성, 참가자별 결과, 최종 순위와 같이 경기 종료 후 확정되는 정보를 제공한다. 셋째, 텔레메트리 사건 기록은 경기 진행

중 발생한 위치 변화, 안전 영역 변화, 피해, 처치, 기절, 아이템 획득과 사용, 경기 시작과 종료에 관한 시간순 사건을 포함한다.

수집한 원자료는 PostgreSQL에 저장하였다. 저장 단계에서는 공식 기록의 의미를 가능한 한 유지하면서도, 분석에 필요한 자료 결합이 가능하도록 경기, 팀, 플레이어, 사건 시점, 위치를 공통 식별 기준으로 정리하였다. 이후 연구용 자료를 구성하는 단계에서는 원천 사건을 경기 단계와 10초 단위 시점에 맞추어 다시 배열하였다. 이와 같이 저장 계층과 분석 계층을 구분한 이유는 공식 기록 자체와 본 논문에서 정의한 연구용 변수가 혼용되는 것을 피하기 위해서이다.

세 유형의 자료는 분석 과정에서 서로 다른 역할을 맡는다. 경기 메타데이터는 분석 집단을 구분하고 경기별 시간 기준을 설정하는 데 사용하였다. 팀 및 참가자 기록에서는 팀 구성과 최종 결과를 확인하였다. 텔레메트리 사건은 경기 단계, 10초 단위 팀 상태, 교전 관계와 자원 사용을 구성하는 원자료로 사용하였다. 개별 사건을 모형에 곧바로 입력하지 않고 분석 단위에 맞게 재구성했으며, 그 절차와 변수 계산 방법은 이어지는 절과 5장에서 설명한다.

4.3 분석 단위의 재구성

본 연구는 원천 사건을 단순히 시간순으로 나열하지 않고 두 종류의 분석 자료로 재구성하였다. 첫 번째 자료는 경기 단계별로 각 팀의 상태를 요약하고, 두 번째 자료는 각 팀의 상태를 10초 간격으로 기록한다. 두 자료는 같은 공식 기록에서 만들었지만, 서로 다른 질문에 답하기 위해 시간 단위를 달리하였다. 단계별 자료는 안전 영역의 갱신 전후처럼 생존 조건이 구조적으로 바뀌는 시점을 비교하고, 10초 자료는 한 단계 안에서 일어나는 이동과 체력 및 교전의 짧은 변화를 보존한다.

단계별 자료의 기본 단위는 경기 m , 팀 i , 경기 단계 k 의 조합이다. 각 행은 해당 단계 구간에서 관측한 팀 상태, 안전 영역의 변화, 이동, 교전, 자원 사용, 주변 팀과의 관계와 단계 종료 상태를 요약한다. 시간 처리를 포함한 모형은 $k+1$ 단계를 예측할 때 1단계부터 k 단계까지의 행을 순서대로 사용한다. 현재 단계의 요약값 한 행만 사용하는 기준선은 6장에서 따로 구분한다.

10초 단위 자료의 기본 단위는 경기 m , 팀 i , 시점 t 의 조합이다. 플레이어 위치는 10초 간격으로 정렬하고, 해당 시점에 생존한 팀원의 위치를 이용해 팀 중심점을 계산하였다. 같은 시점에 관측된 안전 영역, 교전 사건, 자원 사용, 주변 팀과의 관계도 함께 정렬하여 시점 t 까지의 관측 이력을 구성하였다. 이 자료는 경기 진행 중 다음 단계 탈락 위험을 예측하는 시계열 입력으로 사용한다.

4.4 전처리 절차

전처리는 네 단계로 수행하였다. 첫째, 공식 기록에서 경기, 팀, 참가자, 사건 시점을 공통 식별 기준에 맞추어 정리하였다. 둘째, 안전 영역 일정이 전환되는 시점을 기준으로 경기 단계를 정의하였다. 셋째, 플레이어 위치를 10초 간격으로 정렬한 뒤, 생존한 팀원을 기준으로 팀 중심점, 체력과 팀원 간 공간적 분산을 계산하였다. 넷째, 경기 단계 또는 10초 시점까지 관측된 정보만 사용하여 입력 변수와 목표값을 분리하였다.

경기 단계는 3장에서 정의한 분석 단위 k 를 자료에서 구체화한 것이다. 관측되는 단계 수는 경기마다 달라 본 자료에서는 최대 열 단계까지 나타나며, 일곱 단계 안팎이 가장 흔하다. 낙하와 착륙 직후 구간은 팀의 위치와 상태가 아직 안정적으로 관측되지 않으므로 분석 단위에서 제외한다. 단계 경계는 10초 격자 위에서 각 단계의 처음과 마지막 관측 시점으로 정의한다. 모형 입력은 단계 1부터 8까지로 제한하며, 예측의 시점은 그 안에서 다음 단계가 존재하는 단계 1부터 7까지로 한정한다. 여덟 번째 단계 이후의 예측 사례는 매우 드물어, 이에 따라 제외되는 사례는 위험 집합 전체의 약 0.3%이다. 단계 경계 사이의 짧은 전환 구간에서 발생한 사건은 어느 단계에도 집계하지 않는 보수적 처리를 따른다. 한편 10초 격자의 각 시점 값은 해당 시점에서 가장 가까운 원시 기록으로 정렬하므로, 시점 단위 관측에는 최대 ± 5 초의 정렬 불확실성이 존재한다.

팀 생존 판정은 다음 기준을 따른다. 기절 상태의 팀원은 아직 부활할 수 있으므로 생존으로 취급하며, 팀의 탈락 시점은 마지막 남은 팀원이 확정적으로 제거되어 팀 전체가 경기에서 빠지는 시점으로 정의한다. 이 판정은 텔레메트리의 처치와 탈락 사건 기록을 기준으로 하며, 3장의 팀 생존 정의를 자료 수준에서 구현한 것이다.

공간 정보는 동일 경기 내 좌표계를 기준으로 처리하였다. 플레이어 위치는 팀 중심점과 팀원 간 공간적 분산으로 요약하였고, 안전 영역은 중심과 반경이 시간에 따라 변하는 구역으로 정리하였다. 교전 사건은 공격 팀, 피해 팀, 사건 시점, 위치와 피해량을 기준으로 정리하였다. 팀 간 관계는 근접, 교전, 안전 구역 밖 동시 체류로 구분하였다. 이러한 관계 정보는 이후 실험에서 네트워크 요약 변수와 그래프 관계 정보로 사용된다.

4.5 분석 집단의 구성

배틀로얄 경기는 지도, 시점, 팀 규모에 따라 전개 양상이 달라질 수 있다. 따라서 본 연구는 모든 경기를 하나의 집단으로 합쳐 해석하지 않고, 지도, 인칭 시점, 팀 규모의 조합을 기준으로 분석 집단을 구분하였다. 여기서 TPP는 3인칭 시점, FPP는 1인칭 시점을 의미하며, 솔로, 듀오, 스쿼드는 각각 개인전, 2인 팀, 4인 팀 모드

를 가리킨다. 공식 자료에 기록되는 지도 식별자는 실제 지도 이름과 다르다. 예를 들어 Erangel은 자료에서 Baltic_Main으로, Taego는 Tiger_Main으로 기록된다. 혼동을 피하기 위해 표 4.1에 두 이름을 함께 표기하며, 본문에서는 실제 지도 이름을 사용한다.

Table 4.1: 주요 실험에 사용한 13개 분석 집단

지도	자료상 지도명	시점	팀 규모	경기 수
Erangel	Baltic_Main	TPP	스쿼드	6,204
Taego	Tiger_Main	TPP	스쿼드	4,159
Miramar	Desert_Main	TPP	스쿼드	1,543
Rondo	Neon_Main	TPP	스쿼드	1,039
Sanhok	Savage_Main	TPP	스쿼드	940
Erangel	Baltic_Main	TPP	솔로	800
Erangel	Baltic_Main	TPP	듀오	656
Taego	Tiger_Main	TPP	듀오	573
Vikendi	DihorOtok_Main	TPP	스쿼드	498
Taego	Tiger_Main	FPP	스쿼드	435
Erangel	Baltic_Main	FPP	스쿼드	430
Karakin	Summerland_Main	TPP	스쿼드	333
Paramo	Chimera_Main	TPP	스쿼드	333
전체				17,943

Erangel TPP 스쿼드는 가장 큰 표본을 가진 대표 분석 집단이다. 이후 실험 장에서는 이 집단을 중심으로 생존 요인별 추가 설명력을 검토하고, 나머지 분석 집단에서는 동일한 비교가 다른 경기 조건에서도 유지되는지 확인한다.

각 분석 집단은 경기 단위로 학습, 검증, 평가 집합으로 분할하였다. 같은 경기에서 파생된 단계별 팀 사례가 서로 다른 집합에 섞이면 평가가 낙관적으로 왜곡될 수 있으므로, 분할 단위는 개별 사례가 아니라 경기이다. 분할 비율은 8:1:1이고, 고정된 난수 시드(42)로 생성한 분할 정보를 파일로 저장하여 본 논문의 모든 실험이 동일한 분할을 재사용하도록 하였다. 예를 들어 대표 분석 집단인 Erangel TPP 스쿼드의 6,204경기는 학습 4,964경기, 검증 620경기, 평가 620경기로 나뉜다. 분할 정보에는 경기 식별자 목록과 생성 조건이 기록되며, 이후의 모든 재실행은 저장된 정보를 그대로 불러와 사용한다.

4.6 입력 변수와 목표값의 구분

PUBG 공식 기록에서 얻을 수 있는 정보는 직접 관측한 값, 관측값으로부터 계산한 값, 목표값, 간접 지표와 공식 기록에서 제공하지 않는 정보로 나눌 수 있다. 이 구분은 3장에서 정의한 생존 요인을 실제 자료로 옮길 때, 어떤 항목을 모형

입력으로 사용할 수 있고 어떤 항목을 평가에만 사용할 수 있는지 결정하는 기준이 된다.

Table 4.2: 공식 기록의 활용 구분

분류	의미
직접 관측한 값	위치, 체력, 생존 상태, 안전 영역, 블루존, 교전, 피해, 처치, 아이템 사건
계산한 값	이동량, 경계와의 거리, 구역 밖 체류 시간, 주변 팀 밀도, 팀 간 관계, 네트워크 통계
목표값 및 평가값	다음 단계 생존 및 탈락 여부, 최종 승리 여부, 최종 등수, 상위권 진입 여부
간접 지표	고도, 안전 영역을 기준으로 한 상대 위치, 주변 적 밀도처럼 전술적 유불리를 간접적으로 나타내는 값
공식 기록에서 제공하지 않는 정보	세밀한 지형 구조, 건물 내부 구조, 실제 시야선, 엄폐 여부, 플레이어의 의도

예측 입력에는 직접 관측한 값과 계산한 값 중 해당 예측 시점까지 확인된 정보만 포함하였다. 단계 k 에서는 그 단계가 끝날 때까지의 요약값과 10초 기록을 사용하고, 다음 단계 탈락 여부와 최종 순위, 승리 및 상위권 진입 여부는 목표값 또는 평가값으로만 사용하였다. 10초 기록에는 전처리 절차에서 설명한 최대 ± 5 초의 정렬 불확실성이 남는다.

4.7 실제 경기 상황과 수학적 표현의 대응

3장에서 정의한 기호가 실제 경기 기록으로 어떻게 채워지는지 보이기 위해 평가 집합의 Erangel TPP 스쿼드 경기에서 한 팀을 사례로 선택하였다. 자료에서 팀 18로 식별된 팀은 5단계가 끝날 때 한 명이 생존해 있었고, 해당 단계의 평균 체력은 82.4, 관측된 최저 체력은 34.0이었다. 이 팀은 5단계 중 60초, 즉 관측 시간의 37.5%를 안전 영역 밖에서 보냈으며 안전 영역 경계와의 거리는 평균 38.3m, 최소 0.3m였다. 이후 6단계에서 마지막 팀원이 탈락하였다. 이 사례는 모형의 예측 결과를 설명하기 위한 것이 아니라, 실제 경기 상황이 하나의 예측 사례로 구성되는 과정을 보이기 위한 것이다.

이 사례에서 $(m, 18, 5)$ 는 경기, 팀, 예측 단계를 가리킨다. 팀 18은 5단계가 끝날 때 생존해 있으므로 $\mathcal{R}_m(5)$ 에 포함된다. 이 시점까지의 기록은 관측 이력 $\mathcal{F}_{18}^m(5)$ 를 이루며, 1단계부터 5단계까지 생존 요인별로 구성한 값의 순서가 $\Phi_{18}^m(1:5)$ 이다. 표 4.3은 이 가운데 예측 직전인 5단계에서 각 생존 요인이 어떤 경기 상황 및 자료와 대응하는지를 보여 준다. 하나의 관측값이 개념적으로 둘 이상의 요인과 관련될 수 있으므로, 표에서는 5장의 실제 실험과 같은 기준을 적용하여 각 값을

한 요인에만 배정하였다.

Table 4.3: 실제 PUBG 사례에서 생존 요인과 경기 기록의 대응

3장의 기호	사례에서 관찰한 상황	자료로 옮긴 값
$U_m(5)$ (00)	Erangel에서 3인칭 스쿼드로 진행된 경기의 5단계	단계 번호, 단계 지속 시간과 팀 규모
$C_{18}^m(5)$ (01)	단계 종료 시 한 명 생존, 단계 평균 체력 82.4, 최저 체력 34.0	생존 인원, 평균 및 최저 체력, 체력 변화와 팀원 간 거리
$Z_m(5)$ (02)	5단계의 안전 영역, 구역 밖 60초 체류, 구역 밖 비율 37.5%, 경계와의 평균 거리 38.3m	생존 팀과 선수 수, 안전 영역과 블루존의 변화, 구역 밖 체류와 경계 거리
$B_{18}^m(5)$ (03)	팀 18의 중심점이 10초마다 이어져 형성한 5단계까지의 이동 경로	시점별 좌표, 속도, 이동 거리와 경로 변화
$E_{18}^m(5)$ (04)	5단계까지 주고받은 피해, 기절, 처치와 인근에서 발생한 교전	피해량과 사건 수, 교전한 상대 팀 수와 최근 교전 기록
$R_{18}^m(5)$ (05)	5단계까지 획득하거나 장착하고 사용한 장비, 회복 수단과 차량	아이템 획득 및 사용 횟수, 장비 종류, 차량 이용 비율
$G_{18}^m(5)$ (06)	팀 18의 이동 경로 주변에 있던 적과 다른 팀에 대한 상대적 높이	주변 적의 분포와 최근접 거리, 팀의 고도와 상대 팀과의 높이 차이
$Q_{18}^m(5)$ (07)	같은 시점에 가까이 있었거나 실제로 교전한 다른 팀들	거리별 주변 팀 수, 최근접 거리, 근접 관계와 교전 관계
$H_{18}^m(5)$	5단계의 안전 영역, 팀 18의 위치와 남은 팀의 배치를 함께 본 상황	생존 팀당 가용 면적, 안전 영역에 들어가는 데 필요한 이동, 주변 팀이 몰린 정도

표는 5단계의 값을 보여 주지만, 제안 모형의 입력이 5단계 한 행으로 한정되는 것은 아니다. 1단계부터 5단계까지의 요약값과 단계별 팀 관계를 순서대로 사용하고, 경기 시작부터 5단계 종료까지의 10초 기록을 함께 입력한다. 이 누적 관측으로 $\lambda_{18}^m(5)$, 즉 팀 18이 6단계 동안 탈락할 가능성을 추정한다. $Y_{18}^m(6) = 1$ 은 6단계에서 실제로 확인된 결과이므로 입력이 아니라 목표값이다. 따라서 모형에 제공하는 기록은 5단계 종료에서 끝나며, 6단계의 이동, 교전과 탈락 사건은 입력에 포함하지 않는다. 같은 절차를 모든 경기와 생존 팀에 적용하여 (m, i, k) 단위의 분석 자료를 구성하였다.

4.8 연구 문제 2에 대한 자료 구성 결과

앞 절에서 보인 대응은 여러 배틀로얄 게임에 공통으로 나타나는 생존 요인과 PUBG 고유 정보를 나누는 기준으로 사용된다. 경기 단계, 생존 팀 수, 안전 영역 축소, 이동, 교전 노출, 자원 사용과 팀 간 관계는 여러 게임에서 반복되는 공통 요인에 해당한다. 지도명, 인칭 시점, 레드존과 블랙존, PUBG의 아이템 분류, 차량과 고도 관련 변수는 PUBG의 규칙과 기록 형식을 반영한 정보로 구분한다. 이는 공통 생존 요인과 PUBG 자료에서 이를 측정할 변수를 혼동하지 않기 위한

전제이다. 이후의 입력 변수 추가 실험은 PUBG 자료 안에서 각 생존 요인에 대응하는 정보가 추가될 때의 변화를 검토한다. 그러므로 이 결과를 서로 다른 게임에 공통된 원자료 변수와 PUBG 고유 변수의 직접 비교로 해석하지 않는다.

연구 문제 2의 자료 구성 측면에서는 PUBG 공식 경기 기록을 경기와 팀, 경기 단계, 10초 시점과 팀 관계의 조합으로 재구성할 수 있다고 답할 수 있다. 또한 입력은 예측 시점까지의 관측으로 제한하고 이후의 생존 및 최종 결과는 목표값으로 분리할 수 있었다. 5장에서는 이 분석 단위에 어떤 관측값을 배치할 것인지 설명하여 연구 문제 2의 자료 표현을 완성하고, 이어지는 실험에서 같은 자료 분할을 유지한 채 표현과 모형을 비교한다.

Chapter 5

생존 과정의 자료 표현과 예측 모형

5.1 연구 문제 2와 자료 표현의 원칙

연구 문제 2는 3장의 생존 과정을 PUBG 공식 경기 기록에서 어떤 자료로 표현할 수 있는지를 묻는다. 이를 위해서는 팀의 현재 상태와 경기 단계에 따라 달라지는 환경을 함께 고려해야 한다. 안전 영역이 축소되면 이동할 수 있는 공간과 경로가 달라지고, 남아 있는 팀의 배치에 따라 같은 위치에서도 위험의 정도가 달라진다. 본 장에서는 이러한 변화를 팀 상태, 안전 영역의 변화, 이동, 위험 노출, 공간 조건과 팀 간 관계로 나누어 입력 변수를 구성하고, 이를 사용하는 예측 모형을 설명한다.

3장에서 정의한 생존 요인은 여러 배틀로얄 게임의 생존 조건을 비교하기 위한 분석 범주이다. 본 장에서는 이 요인들을 PUBG 공식 경기 기록에서 계산할 수 있는 변수로 구체화한다. 장르 차원의 요인과 PUBG에서 측정한 변수를 구분하여 설명하고, 두 수준의 대응 관계를 표로 제시한다. 모든 변수는 4장의 전처리 원칙에 따라 예측 시점까지 관측된 정보만으로 계산한다.

이러한 자료 표현은 연구 문제 3의 검증 대상으로 이어진다. 첫째, 팀 상태와 이동만으로 계산한 위험에 안전 영역의 변화와 주변 경쟁 상황을 더했을 때 새로운 예측 정보가 생기는지 확인한다. 둘째, 예측 직전의 상태만으로 충분한지, 그 시점까지의 이동과 체력 변화 순서를 함께 보아야 하는지 비교한다. 셋째, 개별 팀의 변수에 더하여 어느 팀과 가까웠고 교전했는지를 표현할 필요가 있는지 살펴본다. 단계별 변수 묶음, 10초 기록과 팀 관계 자료는 각각 이 세 질문을 검증할 수 있도록 구성하였다.

5.2 모형이 사용하는 자료

4장에서는 공식 경기 기록을 경기 단계와 10초 간격으로 나누었다. 본 장의 모형은 $k+1$ 단계를 예측할 때 1단계부터 k 단계까지의 단계별 자료와 경기 시작부터 k 단계

종료까지의 10초 기록을 사용한다. 표 5.1의 네 자료가 이 기간에 어떤 정보를 제공하는지 정리하였다. 단계별 팀 자료와 경기 자료는 각각 한 단계의 팀 상태와 공통 조건을 요약하며, 모형은 이 요약값을 1단계부터 현재 단계까지 순서대로 읽는다. 10초 단위 자료는 같은 기간의 이동과 체력 변화를 더 세밀한 순서로 보존하고, 팀 관계 자료는 단계마다 어느 팀들이 가까이 있었거나 서로 교전했는지를 나타낸다.

Table 5.1: 모형에 입력되는 네 가지 자료

자료	한 항목이 나타내는 것	사용하는 이유
단계별 팀 자료	한 팀의 한 경기 단계에 대한 생존 인원, 체력, 이동, 피해와 주변 상황	단계별로 달라진 팀 상태를 이어서 보기 위해 사용
단계별 경기 자료	단계 번호, 남은 팀 수, 안전 영역처럼 같은 단계의 모든 팀이 공유하는 조건	같은 팀 상태라도 경기 진행 상황에 따라 위험이 달라지는 점을 반영
10초 단위 팀 자료	경기 시작부터 예측 시점까지 10초마다 기록한 위치, 속도, 체력과 생존 인원	한 단계의 평균값만으로 사라지는 이동 순서와 짧은 변화를 보존
팀 관계 자료	단계별 또는 10초별 근접, 교전, 안전 구역 밖 동시 체류 관계	주변 팀의 수와 직접적인 상호 작용을 함께 고려

예를 들어 3단계가 끝난 시점에서 팀 12의 4단계 탈락 위험을 예측한다면, 모형은 팀 12의 1단계부터 3단계까지의 요약값, 각 단계의 안전 영역과 남은 팀 수, 경기 시작부터 3단계 종료까지의 10초 기록과 같은 기간에 확인된 다른 팀과의 관계를 사용한다. 4단계의 위치, 교전과 탈락 사건은 입력에 포함하지 않는다.

이제 위 자료를 수식에서 짧게 나타내기 위한 기호를 정의한다. 경기 m 의 단계별 팀 자료를 $\mathbf{X}_p^m$, 단계별 경기 자료를 $\mathbf{G}^m$ 으로 쓰면

$$\mathbf{X}_p^m \in \mathbb{R}^{8 \times 128 \times d_p}, \quad \mathbf{G}^m \in \mathbb{R}^{8 \times d_g} \quad (5.1)$$

로 나타낼 수 있다. 첫 번째 차원 8은 경기 단계, 두 번째 차원 128은 한 경기에서 확보한 최대 팀 자리 수다. d_p 와 d_g 는 각각 팀별 변수와 모든 팀이 공유하는 변수의 수다. 전체 변수를 사용할 때는 $d_p = 125$, $d_g = 25$ 이며, 변수를 차례로 추가하는 실험에서는 이 수가 달라진다.

단계별 팀 관계를 $\mathbf{A}_p^m$, 10초 단위 팀 자료와 관계를 각각 $\mathbf{X}_s^m$, $\mathbf{A}_s^m$ 으로 쓰면

$$\mathbf{A}_p^m \in \mathbb{R}^{8 \times 3 \times 128 \times 128}, \quad \mathbf{X}_s^m \in \mathbb{R}^{200 \times 128 \times 13}, \quad \mathbf{A}_s^m \in \mathbb{R}^{200 \times 2 \times 128 \times 128} \quad (5.2)$$

로 나타낼 수 있다. $\mathbf{A}_p^m$ 은 근접, 교전, 안전 구역 밖 동시 체류의 세 관계를, $\mathbf{A}_s^m$

은 근접과 교전의 두 관계를 포함한다. 200은 한 경기에서 사용한 최대 10초 관측 수다. 실제로 존재하지 않는 단계, 팀과 관측 시점은 0으로 채우고, 존재 여부를 나타내는 별도의 0과 1 표시값을 사용하여 계산에서 제외한다. 단계 k 의 종료 시점에서 예측할 때는 이 배열 가운데 1단계부터 k 단계까지의 자료와 그 시점까지의 10초 관측만 읽는다. $k + 1$ 단계 이후의 자리는 표시값으로 가리어 계산에 영향을 주지 않도록 했다.

연속형 변수 v 는 미리 정한 기준값 c 로 나눈 v/c 를 사용한다. 결측값과 무한대 등 계산할 수 없는 값은 0으로 대체한다. 경로 굴곡도에는 $\log(1 + \max(v, 0))$ 변환을 적용하고, 논리값은 0과 1로 변환한다. 신경망 입력에는 학습 자료의 평균과 분산을 다시 추정하는 표준화를 적용하지 않았다. 변수별 원자료와 정규화 기준값은 부록 A.3에 제시한다.

5.3 단계별 입력 변수

단계별 자료의 기본 단위는 경기 m , 팀 i , 경기 단계 k 의 조합이다. 각 행은 단계 k 구간에서 관측한 팀 상태와 변화, 단계 종료 시점의 경기 환경을 요약한다. 제안 모형은 $k + 1$ 단계를 예측할 때 이러한 행을 1단계부터 k 단계까지 순서대로 읽는다. 최종 순위와 상위권 진입을 보조 목표로 함께 학습할 때도 입력의 종료 시점은 동일하게 유지한다.

$Y_i^m(k + 1)$ 은 목표값이므로 입력 변수 수에서 제외하였다. 표 5.2의 150개 변수는 서로 겹치지 않도록 하나의 요인에만 배정하였다. 하나의 기록이 개념적으로 둘 이상의 요인과 관련될 수 있지만, 입력 변수를 추가하는 실험에서 같은 변수를 중복하여 세지 않기 위해 소속을 하나로 정하였다. 지도, 시점과 팀 규모는 분석 집단을 구분하는 기준이다. 각 집단에 별도의 모형을 학습했으므로 지도와 시점은 수치형 변수에 포함하지 않았다.

이와 같은 구분은 게임마다 기록의 종류와 측정 방식이 다를 수 있음을 전제로 한다. 안전 영역의 축소와 남은 경쟁자 수는 여러 배틀로얄 게임에서 반복되지만, PUBG에서는 고유한 사건명과 좌표 체계를 통해 관측된다. 차량, 기절, 회복과 부스트는 PUBG의 규칙에 따라 의미가 정해지는 변수이다. 본 연구는 이러한 PUBG 변수를 3장의 생존 요인에 대응시켜 분석하며, 서로 다른 게임의 원자료 항목이 동일하다고 가정하지 않는다.

5.4 10초 단위 시계열 변수

단계별 자료가 한 단계의 상태를 요약한다면, 10초 단위 자료는 경기 중 변화를 시간 순서대로 보존한다. 표 5.3의 13개 변수는 시계열 모형과 단계별 자료와 10초

Table 5.2: 생존 요인과 PUBG 입력 변수의 대응

기호	분석 요인	PUBG에서 사용한 변수	변수 수
$U_m(k)$	경기 조건	단계 번호, 단계 지속시간, 팀 규모	3
$C_i^m(k)$	팀 상태	생존 인원 4개, 체력 3개, 팀원 간 공간적 분산 2개	9
$Z_m(k)$	단계별 생존 조건	생존 팀 수, 플레이어 수, 안전 영역과 블루존의 변화를 나타내는 변수 10개, 안전 구역 이탈과 경계 거리 5개	15
$B_i^m(k)$	이동	이동 거리, 변위, 경로 굴곡도, 속도, 안전 영역 방향 및 진입 시점 3개	7
$E_i^m(k)$	위험 노출	최근 피해와 위험 구역 통과 2개, 피해, 기절 및 처치 기록 11개	13
$R_i^m(k)$	생존 자원	차량 이용 3개, 아이템 획득, 장착 및 사용 기록 13개	16
$G_i^m(k)$	공간 조건	주변 적 분포 3개, 고도 관련 변수 9개	12
$Q_i^m(k)$	팀 간 관계	교전 13개, 근접 10개, 안전 구역 밖 동시 체류 6개, 누적값 및 생존 팀 수 보정값 14개	43
$H_i^m(k)$	현재 위치와 주변 상황	가용 면적과 혼잡도 13개, 안전 영역 진입에 필요한 이동 12개, 주변 경쟁 상황 7개	32
$Y_i^m(k+1)$	예측 결과	다음 단계 탈락, 최종 순위, 최종 상위 5팀 및 상위 10팀	—

단위 자료를 결합한 모형에 공통으로 사용한다.

단계 k 에서 예측할 때는 경기 시작부터 해당 단계의 예측 시점까지 기록된 자료만 사용한다. 예측 이후의 위치와 상태는 0으로 바꾸고, 각 값이 실제 관측인지 나타내는 0과 1의 표시값을 함께 두어 계산에서 제외한다. 이 자료는 단계별 요약만으로는 사라질 수 있는 짧은 변화와 이동 순서를 보존하므로 시계열 모형의 입력과 누적 생존 점수의 변화 분석에 사용한다. 첫 관측의 속도처럼 직전 값이 없거나 다음 안전 영역이 아직 정해지지 않은 경우에는 0을 사용한다. 실제 팀과 관측 시점의 존재 여부는 별도의 표시값에 보존한다.

10초 기록은 시계열 모형과 단계별 자료를 결합한 모형의 입력으로 사용한다. 두 경우 모두 경기 시작부터 단계 k 종료까지의 기록을 순서대로 읽고 $k+1$ 단계 탈락 위험을 산출한다. 따라서 10초는 입력 기록의 간격이며, 본 논문의 예측과 평가는 경기 단계를 기준으로 수행한다.

5.5 팀 간 관계와 그래프 구성

한 팀의 위험은 주변 팀과의 관계에 따라서도 달라진다. 가까운 곳에 여러 팀이 있으면 이동 경로를 선택하기 어려워지고, 피해가 오간 관계는 단순한 근접보다

Table 5.3: 10초 단위 입력 변수의 정의와 정규화 기준

변수	저장 변수명	정의	기준값
팀 중심 x 좌표	pos_x	생존 팀원의 중심 x 좌표(m)	8,160
팀 중심 y 좌표	pos_y	생존 팀원의 중심 y 좌표(m)	8,160
팀 중심 고도	pos_z	생존 팀원의 중심 z 좌표(m)	400
안전 영역 내 상 대 x 위치	rel_zone_x	$(x - x_{\text{safe}})/r_{\text{safe}}$	1
안전 영역 내 상 대 y 위치	rel_zone_y	$(y - y_{\text{safe}})/r_{\text{safe}}$	1
직전 관측 이후 의 속도	speed_mps	직전 관측과의 평면 거리/경과 시간	40
안전 영역 경계 까지의 거리	dist_blue_boundary_m	영역 안은 양수, 밖은 음수로 표시한 경 계 거리(m)	8,160
안전 영역 내부 여부	inside_blue	내부 1, 외부 0	1
다음 안전 영역 중심까지의 거리	dist_target_center_m	다음 안전 영역 중심까지의 평면 거리 (m)	8,160
팀 평균 체력	mean_health	생존 팀원의 평균 체력	100
팀 최소 체력	min_health	생존 팀원의 최소 체력	100
생존 인원	alive_n	해당 시점의 생존 팀원 수	4
차량 탑승 비율	vehicle_ratio	차량에 탑승한 팀원의 비율	1

직접적인 위협을 나타낸다. 좁아지는 구역으로 여러 팀이 동시에 이동하는 경우에는 아직 교전이 발생하지 않았더라도 이후의 위협이 커질 수 있다. 이에 따라 근접 관계, 교전 관계와 안전 구역 밖 동시 체류 관계를 구분하였다.

관계 정보는 두 가지 형태로 사용한다. 먼저 근접한 팀의 수, 최근접 거리, 교전 상대, 주고받은 피해와 안전 구역 밖 동시 체류를 팀별 값으로 요약한다. 이 값은 표 5.2의 팀 간 관계 변수에 해당하며, 개별 변수명과 계산 방법은 부록 표 A.2에 제시한다. 매개 중심성, PageRank, 연결 요소, 공동체와 전체 그래프 밀도는 후보로 검토했으나 최종 입력에는 사용하지 않았다.

다음으로 각 팀을 노드로 두고 팀 사이의 관계를 행렬로 나타낸다. 단계 k 에서 팀 i 와 j 사이의 평균 거리를 $\bar{d}_{ij}(k)$ 라 하면, 근접 관계의 정규화 전 가중치는 다음과 같다.

$$w_{ij}^{\text{prox}}(k) = \exp\left(-\frac{\bar{d}_{ij}(k)}{200}\right). \quad (5.3)$$

교전 관계의 방향은 공격한 팀에서 피해를 받은 팀으로 정한다. 해당 단계의 피해량, 처치 수와 기절 유발 수를 각각 $D_{ij}(k)$, $K_{ij}(k)$, $N_{ij}(k)$ 로 두면 가중치는 다음과 같다.

$$w_{ij}^{\text{combat}}(k) = \log(1 + D_{ij}(k) + 100K_{ij}(k) + 50N_{ij}(k)). \quad (5.4)$$

안전 구역 밖 동시 체류 관계는 두 팀의 거리가 200m 이하이고, 두 팀이 모두 안전 영역 밖에 있거나 안전 영역의 경계로부터 150m 이내에 있을 때 성립한다. 단계 안에서 두 팀이 동시에 관측된 횟수를 $n_{ij}(k)$, 이 조건을 만족한 횟수를 $c_{ij}(k)$, 조건을 만족한 시점의 평균 거리를 $\bar{d}_{ij}^{\text{co}}(k)$ 라 하면 가중치는 다음과 같다.

$$w_{ij}^{\text{co}}(k) = \frac{c_{ij}(k)}{n_{ij}(k)} \exp \left(-\frac{\bar{d}_{ij}^{\text{co}}(k)}{200} \right). \quad (5.5)$$

각 행의 가중치 합이 1이 되도록 관계 행렬을 정규화한다. 근접 관계에는 생존 팀의 자기 연결을 가중치 1로 추가하고, 교전과 안전 구역 밖 동시 체류 관계에는 실제로 관측된 팀 사이의 연결만 남긴다. 10초 단위 관계에서는 현재 거리 $d_{ij}(t)$ 에 동일한 근접식을 적용한다. 교전 가중치는 $(t-10, t]$ 구간에 발생한 사건을 합산하여 계산한다. 이에 따라 단계별 관계 행렬 $\mathbf{A}_p^m$ 은 세 종류의 관계를, 10초 단위 관계 행렬 $\mathbf{A}_s^m$ 은 두 종류의 관계를 갖는다.

5.6 변수 묶음과 추가 순서

변수는 같은 대상을 관측하고 해석 방식이 비슷한 항목끼리 묶었다. 구분의 첫 번째 기준은 값을 계산할 때 필요한 관측 범위다. 경기 단계와 팀 규모처럼 모든 팀이 공유하는 조건, 한 팀만 보아도 계산할 수 있는 생존 인원과 체력, 이동 경로, 경기 환경과 팀 위치를 함께 보아야 하는 값, 두 팀 이상의 기록을 비교해야 하는 교전과 관계 정보는 계산에 필요한 자료가 서로 다르다. 두 번째 기준은 3장의 생존 요인과의 대응이다. 같은 요인을 설명하는 변수는 가능한 한 한 묶음에 배정하여, 하나의 변수가 여러 단계에서 중복되지 않게 하였다.

추가 순서는 관측 범위를 점차 넓히도록 정하였다. OM0은 경기의 공통 조건, OM1은 팀의 현재 상태, OM2는 그 팀의 이동을 담는다. OM3부터는 팀과 안전 영역 및 남은 경쟁자의 관계를 함께 보고, OM4는 실제 교전 사건, OM5는 여러 팀 사이의 관계를 요약한 값, OM6은 이동 경로 주변의 적 분포를 더한다. 이 순서는 경기에서 사건이 발생하는 시간 순서나 요인의 중요도 순위를 뜻하지 않는다. 앞 단계의 변수를 그대로 둔 채 관측 범위가 넓어질 때 추가되는 예측 정보를 구분하기 위한 실험 순서다.

차량과 아이템은 PUBG의 자원 규칙에 따라 의미가 달라지고, 고도는 공식 기록만으로 지형과 시야를 충분히 설명하기 어렵다. 따라서 두 항목은 OM0-OM6의 핵심 누적 비교에서 제외하고, 모든 변수를 사용하는 모형과 별도의 보충 분석에서만 사용하였다. 표 5.4은 직전 단계에 비해 어떤 측정값이 새로 들어가는지와 그 수를 보여준다. OM 번호는 실험 순서를 나타내며, 3장의 분석 요인 O0-O7과 일대일로 대응하는 번호는 아니다.

Table 5.4: OM0-OM6에서 새로 추가한 변수와 누적 변수 수

단계	직전 단계에서 새로 추가한 측정값	추가	누적
OM0	경기 단계 번호, 단계 지속시간, 팀 규모	3	3
OM1	단계 시작, 종료, 최소 및 평균 생존 인원 4개; 평균 및 최소 체력과 체력 변화 3개; 팀원 간 평균 및 최대 거리 2개	9	12
OM2	이동 거리, 변위, 경로 굴곡도, 평균 속도, 이동 시작 시점, 안전 영역 방향과 진입 시점	7	19
OM3	남은 팀과 플레이어 수 2개; 안전 영역과 블루존의 반경 및 중심 변화 8개; 안전 구역 밖 체류와 경계 거리 5개; 가용 면적과 혼잡도 13개; 안전 영역 진입 조건 12개; 주변 경쟁 상황 7개	47	66
OM4	최근 피해와 위험 지역 통과 2개; 가한 피해와 받은 피해, 피해 사건, 기절, 처치, 교전 상대와 선제 교전 여부 11개	13	79
OM5	교전 관계 13개, 근접 관계 10개, 안전 구역 밖 동시 체류 6개, 이전 단계까지의 누적 관계 10개, 남은 팀 수를 고려한 보정값 4개	43	122
OM6	100m 이내 적 밀도, 가장 가까운 적까지의 거리, 이동 경로에서 적과 가까웠던 비율	3	125
전체	차량 이용 3개, 아이템 획득 및 장착과 사용 13개, 고도 관련 변수 9개	25	150

표의 누적 수는 단계별 팀 자료와 단계별 경기 자료를 합한 값이다. 모든 OM 실험에는 10초 단위 변수 13개와 10초 단위 근접 및 교전 관계가 똑같이 들어가므로, 이 13개와 두 관계는 표의 수에 포함하지 않았다. 또한 OM 실험에서는 단계별 관계 행렬을 사용하지 않았다. 따라서 OM5는 43개의 관계 요약값을 변수로 더한 결과이며, 팀 연결 자체를 그래프 연산에 사용한 효과는 별도의 모형 비교와 관계 대조 실험에서 확인한다. 각 변수의 저장 이름과 계산식은 부록 A.3에 제시한다.

표 5.4은 변수의 정의를 다시 제시하기 위한 표가 아니라, 앞에서 설명한 변수가 실험에서 어떤 순서로 들어가는지 보여주는 표다. 각 조합에서 고정된 자료와 비교 절차는 6장에서 설명한다.

5.7 비교 모형의 기본 원리와 사용 목적

본 연구에서는 서로 다른 모형을 하나의 성능 순서로 나열하기보다, 예측에 필요한 정보가 어디에서 오는지 구분하기 위해 사용한다. 단계별 요약값을 사용하는 모형은 변수 사이의 선형 및 비선형 관계를 비교하고, 시계열 모형은 과거 10초 기록의 순서가 제공하는 정보를 확인한다. 그래프 모형은 한 팀의 상태만으로는 표현되지 않는 주변 팀과의 관계가 추가로 필요한지 살펴본다. 이 절에서는 각 모형의 일반적인 작동 원리와 본 연구에서의 역할을 설명하며, 실제 입력 수와 학습 설정은 6장에서 제시한다.

비교 모형은 가정이 적은 방법부터 정보 구조를 하나씩 더하는 순서로 선택하

였다. 로지스틱 회귀와 트리 모형은 한 단계의 변수만 사용하고, 시계열 모형은 여기에 과거 기록의 순서를, 그래프 모형은 주변 팀과의 연결을 추가한다. 따라서 복잡한 모형이 높은 성능을 보이더라도 그 차이가 비선형 관계, 이전 시점의 기록 또는 팀 관계 가운데 어디에서 나왔는지를 구분할 수 있다.

5.7.1 단계별 요약값을 사용하는 모형

로지스틱 회귀는 입력 변수의 가중합을 0과 1 사이의 확률로 바꾸는 모형이다. 단계 k 에서 팀 i 의 입력을 $\mathbf{x}_i(k)$ 라 하면 다음 단계 탈락 위험은

$$\hat{\lambda}_i(k) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i(k)), \quad \sigma(a) = \frac{1}{1 + e^{-a}} \quad (5.6)$$

로 나타낼 수 있다. 경기 단계를 이산 시간으로 보는 경우 이 식은 이산시간 위험 모형과 같은 형태가 된다 [3, 33]. 각 변수의 효과가 하나의 선형 결합으로 제한되므로, 복잡한 모형이 실제로 비선형 관계를 더 학습하는지 판단하는 기본 기준선으로 사용한다.

의사결정나무는 변수의 값을 기준으로 자료를 반복해서 나누고, 각 구간에서 탈락 확률을 추정한다. 랜덤 포레스트는 서로 다른 표본과 변수로 학습한 여러 나무의 결과를 평균하여 개별 나무의 불안정성을 줄인다 [6]. 그래디언트 부스팅은 앞선 나무가 잘 맞지 못한 사례에 다음 나무를 차례로 더한다. 이를 간단히 쓰면

$$F_M(\mathbf{x}) = F_0(\mathbf{x}) + \nu \sum_{m=1}^M f_m(\mathbf{x}) \quad (5.7)$$

이며, f_m 은 순서대로 추가되는 나무이고 ν 는 한 나무의 반영 정도를 정하는 학습률이다 [14]. 본 연구의 히스토그램 기반 그래디언트 부스팅은 연속값을 구간으로 묶어 이 계산을 효율화한다. XGBoost는 같은 부스팅 원리에 모형의 복잡도를 억제하는 항과 병렬 계산을 더한 구현이다 [7]. 이 모형들은 시간 순서와 팀 관계를 직접 처리하지 않으므로, 단계별 변수 자체의 예측력을 확인하는 기준선으로 사용한다.

다층 퍼셉트론은 선형 변환과 비선형 활성화함수를 여러 층으로 연결한 신경망이다 [29]. 트리 모형과 마찬가지로 한 단계의 변수 벡터를 입력받지만, 연속적인 은닉 표현을 학습한다. 따라서 단계 요약값에 신경망을 적용했을 때의 성능을 확인하되, 시간 처리나 그래프 연산의 효과와는 구분한다.

5.7.2 10초 기록을 사용하는 시계열 모형

예측 직전 한 시점만 사용하는 신경망은 13개 값을 다층 퍼셉트론에 넣는 가장 단순한 대조 모형이다. 이 모형과 과거 기록을 사용하는 모형의 차이는 최근 상태만으로 충분한지, 이전 이동과 체력 변화의 순서가 필요한지를 판단하는 근거가

된다.

시간 합성곱 신경망(TCN)은 현재 시점보다 앞선 값에만 합성곱을 적용한다. 층 ℓ 의 시점 t 표현은 일반적으로

$$\mathbf{h}_t^{(\ell)} = \phi \left(\sum_{r=0}^{K-1} \mathbf{w}_r^{(\ell)} \mathbf{h}_{t-r}^{(\ell-1)} + \mathbf{b}^{(\ell)} \right) \quad (5.8)$$

와 같이 계산한다 [4]. 오른쪽의 합이 t 이전 값만 포함하므로 예측 시점 이후의 기록은 참조하지 않는다. 본 연구에서는 가까운 시점에서 반복되는 이동과 체력 변화를 읽는 합성곱 기준선으로 사용한다.

GRU와 LSTM은 시점 t 의 입력과 직전 은닉 상태를 이용해 새 상태를 만드는 순환 신경망이다. 공통적인 갱신은

$$\mathbf{h}_t = f_{\theta}(\mathbf{x}_t, \mathbf{h}_{t-1}) \quad (5.9)$$

로 나타낼 수 있다. GRU는 업데이트 게이트와 리셋 게이트로 이전 정보를 얼마나 남길지 정하며 [8], LSTM은 별도의 셀 상태와 입력, 망각 및 출력 게이트를 사용해 더 긴 구간의 정보를 보존한다 [17]. 두 모형은 한 팀의 10초 기록을 차례로 읽어 각 단계 종료 시점의 은닉 상태에서 탈락 위험을 계산한다. 이 가운데 LSTM은 단계별 위험을 누적 생존 점수로 연결하는 주 시계열 모형으로도 사용한다.

Transformer는 모든 과거 시점 사이의 관련성을 주의집중으로 계산한다. 질의, 키와 값 행렬을 각각 $\mathbf{Q}$, $\mathbf{K}$, $\mathbf{V}$ 라 하면 기본 계산은

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d}} \right) \mathbf{V} \quad (5.10)$$

이다 [34]. 본 연구에서는 미래 시점을 가리는 인과 마스크를 적용하여 예측 시점까지의 기록만 서로 비교한다. 순환 구조 없이도 멀리 떨어진 시점의 정보를 직접 연결할 수 있는지가 비교 목적이다.

5.7.3 팀 관계를 사용하는 그래프 모형

그래프 모형에서 한 팀은 노드, 두 팀 사이의 근접과 교전 및 안전 구역 밖 동시 체류는 관계가 된다. GraphSAGE는 관계 종류를 하나로 합친 뒤 이웃 팀의 표현을 모아 현재 팀의 표현과 결합한다 [16]. 정규화된 연결 가중치를 $\tilde{a}_{ij}$ 라 하면 본 연구에서 사용한 평균 집계는

$$\mathbf{h}'_i = \phi \left(\mathbf{w} \left[\mathbf{h}_i \left\| \sum_j \tilde{a}_{ij} \mathbf{h}_j \right\| \right] \right) \quad (5.11)$$

로 나타낼 수 있다. 이 모형은 주변 팀의 정보가 필요한지 확인하는 단순한 그래프 기준선이다.

관계형 그래프 합성곱 신경망(R-GCN)은 관계 종류마다 다른 변환을 사용한다 [31]. 관계 집합을 $\mathcal{R}$, 관계 r 의 연결을 $\tilde{a}_{ij}^{(r)}$ 라 하면

$$\mathbf{h}'_i = \phi \left(\mathbf{W}_0 \mathbf{h}_i + \sum_{r \in \mathcal{R}} \alpha_r \mathbf{W}_r \sum_j \tilde{a}_{ij}^{(r)} \mathbf{h}_j \right) \quad (5.12)$$

와 같이 관계별 주변 팀 정보를 합친다. α_r 는 각 관계의 반영 정도다. 이를 통해 가까이 있는 관계와 실제 피해가 오간 관계를 같은 연결로 처리할 때와 구분한다.

ST-GNN-Mamba는 관계별 주변 팀 정보를 계산한 뒤, 경기 단계의 시간 변화에 선택적 상태 공간 모형을 적용한다. 상태 $\mathbf{s}_t$ 의 일반적인 갱신은

$$\mathbf{s}_t = \mathbf{A}_t \mathbf{s}_{t-1} + \mathbf{B}_t \mathbf{u}_t, \quad \mathbf{y}_t = \mathbf{C}_t \mathbf{s}_t + \mathbf{D}_t \mathbf{u}_t \quad (5.13)$$

로 나타낼 수 있으며, Mamba는 현재 입력에 따라 상태의 유지와 갱신 정도를 조절한다 [15]. 본 연구에서는 이 모형을 관계 처리 방식은 유지하면서 시간 합성곱을 다른 순차 연산으로 바꾼 비교 대상으로 사용한다.

5.8 제안 모형의 구성

단계별 요약값은 현재 안전 영역과 팀 상태를 비교하기에 적합하지만, 한 단계 안에서 어떤 순서로 이동하고 체력이 변했는지는 남기지 못한다. 반대로 10초 기록만 사용하면 경기 단계가 바뀌며 발생한 공간 제약과 단계 전체의 교전 및 자원 상태를 충분히 요약하기 어렵다. 또한 각 팀을 독립적으로 처리하면 같은 위치에 있더라도 주변 팀의 수와 실제 교전 상대에 따라 위험이 달라지는 점을 반영하기 어렵다.

따라서 제안 모형은 세 가지 정보를 한 팀의 현재 상황으로 종합하도록 구성하였다. 10초 기록은 그 팀의 위치와 체력이 어떤 순서로 변했는지를 알려 주고, 단계별 자료는 현재 안전 영역과 남은 팀 수를 알려 준다. 근접 및 교전 관계는 같은 위치에 있는 팀이 실제로 어떤 상대와 마주하고 있는지를 보충한다. 그림 5.1은 모형의 세부 연산에 앞서, 이 자료들이 어떤 예측으로 이어지는지를 나타낸다.

이 구성을 MR-FARNet으로 부른다. 영문 전체 명칭은 Multi-Resolution Fused Attention-Relational Network이다. MR은 단계별 자료와 10초 기록을 함께 사용하는 구성을 뜻한다. FAR은 경기 조건을 반영하고 관계 종류를 구분한 뒤, 같은 경기의 팀들을 서로 비교하는 처리 방식을 뜻한다. 구현에서는 10초 기록을 인과적 시간 합성곱으로 처리하고 단계별로 모은 뒤, 단계 요약값과 결합한다. 이 결합은 1단계부터 예측 단계 k 까지 반복되며, 인과적 단계 처리부가 순서대로 읽는다. 이후 근접, 교전과 안전 구역 밖 동시 체류 관계를 구분하여 주변 팀의 정보를 반영한다.




Figure 5.1: 1~k단계의 기록으로 $k + 1$ 단계 탈락 위험을 예측하는 과정

이 절차를 수식으로 나타내기 위해 경기 m 의 10초 기록을 $\mathbf{X}_s^m$, 같은 시점의 팀 관계를 $\mathbf{A}_s^m$ 이라 한다. 시간 처리부가 두 자료에서 만든 결과는 $\mathbf{H}_s^m = f_s(\mathbf{X}_s^m, \mathbf{A}_s^m)$ 로 표시한다. 여기서 t 는 10초 관측 시점, $p(t)$ 는 그 시점이 속한 경기 단계다. M_{ti}^m 은 팀 i 의 값이 시점 t 에 실제로 관측되었으면 1, 그렇지 않으면 0이다. 단계 k 의 10초 기록을 하나의 값으로 모으는 계산은 다음과 같다.

$$\bar{\mathbf{h}}_{s,i}^m(k) = \frac{\sum_{t:p(t)=k} M_{ti}^m \mathbf{H}_{s,ti}^m}{\max\left(1, \sum_{t:p(t)=k} M_{ti}^m\right)}. \quad (5.14)$$

이 식은 단계 k 에 속하면서 실제로 관측된 10초 기록만 골라 평균한다는 뜻이다. 다만 $\mathbf{H}_{s,ti}^m$ 는 해당 시점 t 까지의 10초 기록을 인과적으로 처리한 결과이므로, 예측 이후의 시점은 참조하지 않는다. 아직 경기 단계가 배정되지 않은 착륙 시점은 첫 단계에 포함한다. 이렇게 얻은 평균값과 같은 단계의 팀 변수를 나란히 붙여 다음 계산의 입력으로 사용한다.

$$\mathbf{X}_{p,i}^{m,*}(k) = [\mathbf{X}_{p,i}^m(k) \parallel \bar{\mathbf{h}}_{s,i}^m(k)]. \quad (5.15)$$

기호 $\parallel$ 는 두 값의 덧셈이 아니라 변수 열을 이어 붙이는 것을 뜻한다. 이어 붙인 자료에는 같은 단계의 경기 조건을 이용한 조정을 적용한다. 경기 조건의 은닉 표현을 $\mathbf{g}^m(k)$ 라 하고, 이로부터 계산한 두 변환을 γ 와 β 라 하면

$$\tilde{\mathbf{X}}_{p,i}^m(k) = \mathbf{X}_{p,i}^{m,*}(k) \odot [1 + \tanh(\gamma(\mathbf{g}^m(k)))] + \beta(\mathbf{g}^m(k)) \quad (5.16)$$

와 같이 팀 표현을 조정한다. 이 방식은 같은 위치와 체력을 가진 팀이라도 경기 단계와 남은 팀 수가 다르면 다른 표현을 갖게 한다. 이 계산을 1단계부터 k 단계까지 반복하여 단계별 표현의 순서를 만든다. 이 순서는 이전 단계만 참조하는 시간 연산과 근접, 교전, 안전 구역 밖 동시 체류를 구분하는 R-GCN 두 층을 통과한다. 따라서 k 단계의 최종 표현은 1단계부터 k 단계까지의 상태와 팀 관계를 누적해

반영한다. 이후 같은 경기와 단계에 남아 있는 팀을 주의집중으로 서로 비교한다. 모형 비교에서는 이 단계 처리부만 시간 합성곱, GraphSAGE, R-GCN 또는 선택적 상태 공간 연산으로 바꾸며, 앞선 10초 처리와 단계별 결합은 동일하게 유지한다. 모든 계산은 예측 시점보다 뒤의 상태를 참조하지 않는다.

모형의 주 출력은 1단계부터 k 단계까지의 기록을 종합한 k 단계 종료 표현에서 계산하는 $k + 1$ 단계 탈락 위험이다. 최종 순위, 최종 상위 5팀과 상위 10팀 진입 여부는 단계 표현을 보조하여 학습하는 출력이다. 모든 성능 비교와 3장의 누적 생존 점수 및 경기 내 생존 점수 비율은 단계별 탈락 위험을 기준으로 계산한다. 실제 구현에서는 10초 기록 처리부에 향후 30초 안의 탈락 여부를 이용한 보조 손실도 적용했으며, 해당 출력은 독립적인 예측 결과로 평가하지 않았다. 보조 손실의 정의와 가중치는 6장에서 설명한다.

MR-FARNet은 세 종류의 팀 관계를 따로 처리하고, 단계별 경기 조건에 따라 팀의 특징값을 조정하며, 같은 단계에 생존한 팀을 서로 비교한다. 최종 순위 손실에는 실제 순서가 다른 팀 쌍의 예측 순서가 맞도록 하는 항을 추가한다. 따라서 제안 모형의 비교 목적은 단순히 층을 더했을 때의 성능이 아니라, 경기 조건의 반영과 관계별 주변 팀 정보 및 팀 간 상대 비교가 단계별 위험과 최종 순위에 어떤 차이를 만드는지 확인하는 데 있다.

5.9 자료 표현과 검증의 연결

연구 문제 2에 대해서는 PUBG의 생존 과정을 세 종류의 상호 보완적인 자료로 표현할 수 있다고 정리할 수 있다. 단계별 자료는 안전 영역의 변화와 현재 팀 상태를 요약하고, 10초 단위 자료는 한 단계 안의 이동과 체력 변화 순서를 보존하며, 팀 관계 자료는 근접과 교전 및 안전 구역 밖 동시 체류를 나타낸다. 각 자료는 예측 시점까지 관측된 정보만 포함한다.

연구 문제 3은 이 표현이 실제 탈락을 구분하는지와 각 자료 구조에 어떤 모형이 적합한지를 묻는다. 변수 추가 실험은 단계별 표현의 예측 타당성을, 시계열 비교는 시간 이력의 필요성을, 그래프 모형 비교는 실제 연결 상대의 정보와 관계 처리 방식의 효과를 검토한다. 다음 장에서는 네 연구 문제와 세부 실험을 대응시키고, 입력, 경기 분할과 평가 지표를 고정한 뒤 이 질문들을 차례로 검증한다.

Chapter 6

연구 문제별 검증 설계

6.1 연구 문제와 세부 실험의 대응

본 장의 목적은 네 연구 문제를 실제 검증 절차와 대응시키는 데 있다. 연구 문제 1은 장르 정식화의 적용 범위를, 연구 문제 2는 PUBG 공식 기록에서 자료 표현의 구현 가능성을 묻는다. 연구 문제 3은 그 표현이 생존과 탈락을 구분하는지와 자료 구조에 적합한 모형을 평가하며, 연구 문제 4는 단계별 위험과 누적 생존 점수를 경기 중 상대적 생존 평가로 사용할 수 있는지를 확인한다.

이후의 설계와 결과를 같은 순서로 대응시키기 위해 개별 절차를 E1부터 E7까지로 표기한다. 실험은 다섯 단계로 이어진다. E1은 정식화의 적용 범위를 대표 게임 사례에서 검토한다. E2는 그 정식화를 PUBG 공식 경기 기록으로 구현할 수 있는지 확인한다. 이 두 절차를 통과해야 이후의 예측 결과를 개념과 자료가 연결된 실증으로 해석할 수 있다. E3은 본 논문의 핵심 설명인 안전 영역의 변화와 주변 경쟁 상황이 팀 상태 및 이동을 넘어서는 정보를 제공하는지 검증한다. E4는 E3의 개선이 단순히 변수 수가 늘었거나 특정 학습 모형을 사용했기 때문에 나타난 것인지 확인한다.

E5와 E6은 생존 과정이라는 해석을 더 세분화한다. E5는 과거 기록이 예측 직전의 상태보다 유용한지 비교하여 시간성의 근거를 확인하고, E6은 실제로 연결된 상대 팀의 정보가 개별 팀의 변수에 더해지는지 검토한다. E7은 앞의 모형이 산출한 값을 두 가지 순위로 연결한다. 현재 단계의 탈락 위험 순위는 다음 단계 탈락 팀을 찾는 데 사용하고, 단계별 위험을 누적한 생존 점수 순위는 경기 중 팀들의 상대적 위치가 어떻게 달라지는지 살피는 데 사용한다. 따라서 E1-E7은 병렬적인 모형 경진대회가 아니라, 앞 단계에서 남은 의문을 다음 단계에서 확인하는 순차적 검증으로 읽어야 한다.

그림 6.1은 각 단계가 답하려는 질문을 나타낸다. 앞 단계에서 확인한 개념과 자료를 뒤 단계의 공통 조건으로 사용하며, 각 실험에서는 한 번에 하나의 의문을

구분할 수 있도록 나머지 조건을 가능한 한 고정하였다.




Figure 6.1: 연구 문제와 세부 실험의 대응 관계

표 6.1은 각 연구 문제를 세부 실험과 판단 근거에 대응시킨 것이다. 표의 순서는 결과를 설명하는 7장에서도 그대로 유지한다.

Table 6.1: 연구 문제별 세부 실험과 판단 근거

연구 문제와 세부 실험	검증 방법과 판단 근거
E1 생존 요인이 다른 게임에도 적용되는가?	15개 게임의 규칙을 O0-O8에 대응시키고 별도 요인이 필요한 사례가 있는지 판단
E2 생존 요인을 예측 시점의 자료로 만들 수 있는가?	13개 분석 집단의 사례 수, 입력과 목표값의 분리, 예측 이후 기록 제거 검사를 확인
E3 팀 상태와 이동 외에 어떤 조건이 정보를 더하는가?	모형, 경기 분할과 10초 기록을 고정하고 OM0-OM6의 단계별 변수만 누적하여 AUC와 AP의 변화를 비교
E4 E3의 개선을 선행 점수나 특정 모형으로 설명할 수 있는가?	Sagong 등의 점수, 공식 원자료, 일반 상태 변수와 전체 변수 구성을 같은 목표값에서 비교
E5 최근 상태만으로 충분한가?	같은 13개 변수를 마지막 시점, 통계 요약, TCN, GRU, LSTM과 Transformer에 입력하여 AUC와 AP를 비교
E6 실제 팀 관계가 정보를 더하는가?	같은 결합 입력에서 시간 합성곱, GraphSAGE, R-GCN, MR-FARNet과 ST-GNN-Mamba를 비교하고 연결 상대를 바꾼 대조 실험을 수행
E7 단계별 위험을 경기 중 순위로 사용할 수 있는가?	공통 10,616개 경기-단계에서 탈락 위험 순위의 상위 적중률과 MRR, 누적 생존 점수 순위의 선두 변화와 최종 상위권 결과를 비교

6.2 연구 문제 1: 장르 정식화의 적용 범위(E1)

3장의 요인 구분이 PUBG 변수 목록에 머무르지 않는지 확인하기 위해 전투 중심 배틀로얄, 능력 및 시스템 변형, 총격전이 없는 탈락형 게임을 포함한 15개 사례를 검토한다. 사례는 장르 및 게임 목록 문서 [35, 36]를 출발점으로 선정하되, 각 요인의 분류에는 개발사, 퍼블리셔, 공식 상점의 설명을 사용한다. 검토 질문은 모든 사례가 같은 규칙을 갖는가가 아니라, O0-O8의 범주로 설명하기 어려워 별도의 생존 요인이 필요한 사례가 있는가이다. 이 절차는 요인 구분의 적용 범위를 점검하기 위한 것이며, 장르 전체에 대한 완전한 분류를 뜻하지 않는다.

E1에서 기존 범주로 설명하기 어려운 사례가 발견되면 3장의 요인 구분을 먼저 수정해야 한다. 반대로 여러 형태의 사례를 같은 질문으로 기술할 수 있다면, 그다음 단계에서는 이 질문을 실제 경기 기록에서 측정할 수 있는지 검토할 수 있다.

6.3 연구 문제 2: 공식 기록을 이용한 자료 표현(E2)

자료 구성 가능성은 4장에서 정리한 공식 기록과 전처리 결과를 바탕으로 확인한다. 각 분석 요인에 대응하는 값이 예측 시점까지의 기록으로 계산되는지, 다음 단계 탈락과 최종 결과가 입력에서 분리되는지, 경기와 팀 및 단계의 식별자가 일관되게 연결되는지를 점검한다. 최종 구성 규모와 제외 내역은 분석 집단별로 함께 보고한다.

E2는 단순한 자료 규모 보고가 아니다. E3 이후의 성능을 생존 조건에 대한 증거로 해석하려면 모든 입력이 실제 예측 시점에 이용 가능해야 하고, 목표값이 입력에 섞이지 않아야 한다. 이 조건을 충족한 자료에 한해서 변수와 모형 비교를 수행한다.

6.4 연구 문제 3과 4의 공통 평가 조건

E3-E7에서는 입력이나 모형 가운데 확인하려는 요소만 바꾸고, 자료 분할과 평가 절차는 공통으로 유지한다. 이를 통해 집단 구성이나 평가 표본의 차이가 실험 간 성능 차이로 해석되는 것을 줄였다.

6.4.1 분석 집단과 평가 절차

주 결과는 표본이 가장 큰 Erangel TPP 스퀘드에서 제시한다. 같은 절차를 지도, 시점, 팀 규모로 구분한 나머지 12개 분석 집단에서 독립적으로 반복하여, 대표 집단에서 관찰된 방향이 다른 경기 조건에서도 나타나는지 확인한다. 각 분석 집단은 별도로 학습하고 평가하며, 서로 다른 집단의 사례를 하나의 학습 자료로 합치지 않는다.

모든 실험은 4장에서 저장한 경기 단위 학습, 검증, 평가 분할을 재사용한다. 같은 경기에서 나온 팀과 단계가 서로 다른 분할에 들어가지 않도록 하며, 모형과 입력 조합이 달라져도 경기 식별자 목록은 바꾸지 않는다. 모형 선택에는 검증 집합만 사용하고, 평가 집합은 최종 성능을 산출할 때 한 번 사용한다. 기본 난수 시드는 42이며, 주요 신경망의 안정성 검토에는 13과 2026을 추가한다.

다음 단계 탈락 위험은 ROC 곡선 아래 면적(AUC)과 평균 정밀도(AP)로 평가한다. AUC는 탈락 사례가 생존 사례보다 높은 위험 점수를 받을 가능성을 요약

하고, AP는 탈락 사례의 비율이 낮은 조건에서 정밀도와 재현율을 함께 반영한다. 최종 순위 출력은 스피어만 순위상관과 정규화 순위의 평균 절대 오차로 평가한다. 상위 5팀과 상위 10팀 출력에는 AUC, AP, Brier 점수를 사용한다.

같은 경기에서 나온 사례들은 서로 독립이라고 보기 어렵다. 단계별 비교의 불확실성은 경기 단위로 표본을 다시 추출하는 2,000회 대응 부트스트랩으로 추정한다. 순위표 비교에서는 동일한 경기와 단계가 존재하는 교집합만 남기고, 경기-단계 단위의 대응 Wilcoxon 검정과 순위 이항 상관계수를 함께 확인한다.

6.4.2 예측 시점과 자료 제한

입력 자료의 종류와 변수 정의는 5장에서 확정하였다. 본 장에서는 그 정의를 반복하지 않고, 실험에서 자료를 어디까지 사용했는지만 설명한다. 단계 자료는 최대 8단계, 10초 기록은 최대 200개 시점으로 맞추었으며, 실제 예측은 다음 단계가 존재하는 단계 1부터 7까지 수행하였다. 존재하지 않는 단계와 시점은 0으로 채우고 실제 관측 여부를 나타내는 표시값으로 계산에서 제외하였다.

제안 모형과 시계열 모형은 $k+1$ 단계의 탈락을 예측할 때 1단계부터 k 단계까지의 단계별 기록과 경기 시작부터 k 단계 종료까지의 10초 기록을 사용하였다. 예를 들어 6단계 동안의 탈락 여부는 5단계 종료 시점에서 예측하며, 이때 1단계부터 5단계까지의 단계 자료와 경기 시작 이후의 10초 기록이 입력이 된다. 6단계에서 발생한 이동, 교전과 탈락 사건은 목표값을 정하는 데만 사용하고 입력에서 제외하였다.

이 누적 입력 원칙은 E3의 결합 모형, E5의 시계열 모형과 E6의 모형 비교에 해당한다. 비교를 위해 입력 범위를 달리한 기준선도 두었다. E4에서는 단계 k 의 요약값 한 행만 사용하고, E5의 마지막 시점 기준선에서는 k 단계 종료 직전의 10초 기록만 사용한다. 시계열 요약 기준선은 경기 시작부터 k 단계 종료까지의 10초 기록을 평균, 최솟값, 최댓값과 변화량 등으로 요약한다.

모든 비교는 같은 경기 단위 분할을 사용한다. 10초 기록을 비교하는 실험은 표 5.3의 13개 원자료를 공유하지만, 트리 모형은 이를 요약값으로 바꾸고 시계열 신경망은 시간 순서가 남은 기록을 사용한다. 두 입력 형태는 같은 원자료에서 출발하지만 모형에 전달되는 값까지 동일한 것은 아니다.

10초 자료를 입력으로 사용하는 것과 10초 단위 예측 성능을 평가하는 것은 구분한다. E5의 TCN, GRU, LSTM과 Transformer는 10초 기록을 읽지만, 표에 보고하는 다음 단계 탈락 위험은 경기 단계가 끝나는 시점에서 산출한다. 따라서 본 실험에서 10초는 입력 간격이며, 출력의 평가 간격은 경기 단계다.

6.4.3 학습 목표와 손실함수

5장에서 설명한 결합 모형의 주 목표는 다음 단계 탈락 위험 $\hat{\lambda}_i^m(k)$ 이다. 최종 순위, 최종 상위 5팀 및 상위 10팀 진입 여부와 다음 30초 안의 탈락 여부는 보조 목표로 함께 학습한다. 다음 30초 탈락 여부는 각 10초 시점에 생존한 팀이 이후 세 시점 안에 탈락했는지로 정하며, 해당 시점까지의 기록만 입력에 사용한다. 이 출력은 공통 처리부의 학습을 돕기 위한 손실 항으로만 사용하고 독립적인 성능 결과로 보고하지 않는다.

주 목표를 다음 단계 탈락으로 둔 이유는 3장의 생존 과정과 가장 직접적으로 대응하기 때문이다. 보조 목표는 같은 팀 표현이 가까운 시점의 위험과 경기 전체의 결과를 함께 학습하도록 사용한다. E3의 변수 조합과 E5의 시계열 모형 비교에서는 동일한 목표와 가중치를 유지하므로 성능 차이를 입력 또는 시간 처리 방식의 차이로 해석한다. 순위 쌍 손실이 추가되는 E6의 두 모형은 최종 순위 상관의 개선을 그래프 연산만의 효과로 해석하지 않는다.

$$\mathcal{L} = \alpha\mathcal{L}_{\text{haz}} + \beta\mathcal{L}_{\text{rank}} + \gamma\mathcal{L}_{\text{top}} + \delta\mathcal{L}_{\text{snap}} + \eta\mathcal{L}_{\text{pair}}. \quad (6.1)$$

$\mathcal{L}_{\text{haz}}$ 는 다음 단계 탈락의 이진 교차 엔트로피, $\mathcal{L}_{\text{rank}}$ 는 정규화 최종 순위의 절대 오차, $\mathcal{L}_{\text{top}}$ 은 상위 5팀과 상위 10팀 진입의 이진 교차 엔트로피, $\mathcal{L}_{\text{snap}}$ 은 다음 30초 탈락의 이진 교차 엔트로피다. 가중치는 $\alpha = 1.0$, $\beta = \gamma = \delta = 0.3$ 으로 둔다. MR-FARNet과 ST-GNN-Mamba에는 같은 경기 안에서 두 팀의 최종 순서를 비교하는 $\mathcal{L}_{\text{pair}}$ 를 $\eta = 0.1$ 로 추가하며, 나머지 구성에서는 $\eta = 0$ 으로 둔다. 검증 집합의 전체 손실이 가장 낮은 시점의 가중치를 선택한다.

6.5 연구 문제 3: 자료 표현의 타당성과 모형의 적합성

6.5.1 생존 요인의 표현이 더하는 정보(E3)

E2를 통해 자료를 구성할 수 있음을 확인하더라도, 3장에서 정의한 생존 요인이 실제 예측에 필요한지는 별도로 검증해야 한다. E3의 목적은 팀 상태와 이동에 더 넓은 경기 조건을 결합할 때 다음 단계 탈락 위험을 구분하는 정보가 늘어나는지 확인하는 것이다. 특히 같은 이동량이라도 안전 영역의 축소 방향과 현재 위치, 주변에 남은 팀의 배치에 따라 의미가 달라진다는 본 논문의 설명을 직접 검토한다.

OM0부터 OM6까지의 구분 기준과 각 단계의 변수는 5장 표 5.4에 제시하였다. 이 실험에서는 모형, 손실함수, 경기 분할, 10초 변수 13개와 10초 근접 및 교전 관계를 고정하고 단계별 변수만 차례로 추가한다. 단계별 관계 행렬은 사용하지 않으며, 단계 처리는 시간 합성곱으로 통일한다. 따라서 OM2에서 OM3로의 차이는 같은 결합 모형과 10초 기록을 유지하면서 안전 영역의 변화와 현재 위치 및 주변

상황을 나타내는 변수 47개만 더한 결과다.

핵심 판단은 OM2와 OM3 사이의 AUC 및 AP 변화와 그 방향이 13개 분석 집단에서 얼마나 일관되는가에 둔다. OM4 이후의 비교는 교전, 관계 요약과 주변적 분포가 추가로 제공하는 정보를 확인한다. 이 설계로 변수 묶음의 조건부 기여를 비교할 수 있지만, 변수 수가 늘어난 효과나 선행 방식과의 차이까지 한 번에 배제할 수는 없다. 이 남은 의문을 E4에서 확인한다.

6.5.2 선행 방식과 일반 기준선의 비교(E4)

E4는 E3에서 나타난 개선이 본 논문이 구성한 생존 조건 때문인지, 더 많은 변수를 사용했거나 특정 신경망을 선택했기 때문에 생긴 결과인지 검토한다. 이를 위해 한 팀의 한 경기 단계를 한 행으로 만든 자료에서 선행 점수, 공식 원자료와 본 연구의 변수를 같은 목표값과 경기 분할로 비교한다.

Sagong 등의 공격성과 활동성 점수 및 전략 유형별 생존율은 단계별 팀 예측에 맞게 조정하여 사용한다. 이 값은 원 연구를 그대로 재현한 결과가 아니라, 서로 다른 예측 단위를 고려하여 같은 순위표에서 비교할 수 있도록 만든 기준선이다. 공식 원자료의 기본 요약값, 팀 상태와 교전 및 자원으로 구성된 일반적인 상태 변수, 원자료에 안전 영역의 변화와 현재 위치 및 주변 상황을 더한 구성, 전체 변수도 같은 조건에서 학습한다.

주 비교 모형은 그래디언트 부스팅이다. 같은 변수에 로지스틱 회귀, 랜덤 포레스트 [6], XGBoost [7]와 다층 퍼셉트론 [29]도 적용하여 변수의 효과가 한 학습 방법에만 나타나는지 확인한다. 본 연구의 공간 및 주변 상황 변수가 선행 점수와 원자료 요약보다 여러 모형과 집단에서 높은 결과를 보인다면 E3의 해석을 지지하는 근거가 된다.

고도 변수는 핵심 누적 비교에 포함하지 않았다. 공식 기록의 수직 좌표만으로는 지형, 엄폐와 시야를 구분하기 어렵기 때문에, 고도 관련 9개 변수를 OM5에 별도로 더한 결과는 부록의 보충 분석으로만 보고한다.

6.5.3 이전 시점의 기록에 적합한 모형의 비교(E5)

E3과 E4는 한 경기 단계에서 계산한 요약값의 유용성을 확인하지만, 이것만으로 배틀로얄을 시간에 따라 갱신되는 과정으로 보아야 한다는 근거가 충분해지지 않는다. E5는 예측 직전의 상태 한 줄과 그 시점까지의 기록을 비교하여, 과거의 이동 및 체력 변화가 현재 상태에 포함되지 않은 정보를 제공하는지 확인한다.

가장 단순한 대조 모형은 예측 직전의 10초 기록 한 줄만 사용한다. 본문에서는 이를 “마지막 시점만 사용하는 모형”이라 부른다. 신경망에는 마지막 시점의 13개 값을 입력하고, 그래디언트 부스팅에는 단계와 관측 시각을 나타내는 4개 값을

더한 17개를 입력한다. 이 대조 모형을 두면 복잡한 시간 처리 방법의 결과가 과거 이력에서 나온 것인지, 가장 최근 상태만으로도 얻을 수 있는지 구분할 수 있다.

과거 기록은 두 방식으로 사용한다. 그래디언트 부스팅에는 13개 변수의 마지막값, 평균, 최솟값, 최댓값, 표준편차, 첫 관측 대비 변화와 현재 단계 평균을 계산하여 단계 및 관측 수 정보와 함께 총 99개를 입력한다. TCN, GRU, LSTM과 Transformer에는 같은 13개 값을 시간 순서대로 입력한다. 통계 요약과 시계열 신경망의 비교에는 입력 표현과 시간 처리 방식의 차이가 함께 들어가므로, 이전 시점 기록의 필요성은 각 방식이 마지막 시점 모형보다 개선되는지를 중심으로 판단한다. 네 시계열 신경망 사이에서는 입력을 같게 두고 시간 처리 방법만 비교한다. 누적 생존 점수가 한 경기에서 변하는 사례는 LSTM의 단계별 출력으로 구성한다. E7의 모형 간 비교에서는 LSTM뿐 아니라 두 그래디언트 부스팅 모형의 단계별 탈락 위험에도 같은 누적식을 적용하며, 평가는 단계 전환 시점에 수행한다.

6.5.4 팀 관계에 적합한 모형의 비교(E6)

이전 시점의 기록이 유용하더라도 개별 팀의 기록만으로 다중 에이전트 경쟁을 충분히 설명할 수 있는지는 남아 있다. E6은 단계별 변수 150개와 10초 변수 13개를 고정하고, 주변 팀의 관계를 사용하는 방식과 단계의 시간 처리 구조만 바꾸어 비교한다. 이 실험의 주요 목적은 제안 모형의 일괄적인 우위를 보이는 데 있지 않고, 실제 상대 팀의 정보가 개별 팀 변수에 더해지는지를 확인하는 데 있다.

시간 합성곱 모형은 단계별 팀 관계를 사용하지 않는 기준선이다. GraphSAGE는 세 관계를 하나로 합치고, R-GCN은 관계 종류를 구분한다. MR-FARNet은 R-GCN에 경기 조건 조정, 팀 간 주의집중과 순위 쌍 손실을 적용한다. ST-GNN-Mamba는 MR-FARNet과 같은 경기 조건 및 순위 구성을 유지하면서 단계의 시간 연산을 선택적 상태 공간 모형으로 바꾼다. 이 비교에서 입력 자료는 같고 관계 및 단계 처리 방식만 달라진다.

팀 관계 자체의 기여는 실제 연결을 사용한 결과와 연결 상대를 바꾼 결과로 추가 확인한다. 대조 자료는 관계의 수와 팀별 연결 수 분포를 유지하되 어떤 팀과 연결되는지만 바꾼다. 실제 관계가 대조 관계보다 일관되게 높다면 연결 상대의 정보가 존재한다고 볼 수 있다. 모형 간 성능 차이가 작거나 관계 대조의 개선이 제한적이면, 다중 에이전트 관계에 대한 결론도 그 범위에 맞추어 해석한다.

6.5.5 세부 실험별 모형과 실제 입력

앞의 실험은 서로 다른 질문을 다루므로 모든 모형을 하나의 성능 순서로 합치지 않는다. 표 6.2은 각 비교에서 실제로 모형에 전달한 값과 시간 범위를 정리한다. 모형의 일반적인 원리와 선택 이유는 5장의 비교 모형 절에서 설명하였다.

Table 6.2: 비교 실험별 모형과 실제 입력

비교	모형	모형에 전달한 값
변수 추가 E3	단계 관계가 없는 결합 모형	1- k 단계의 단계별 변수 3-125개, 경기 시작부터 k 단계 종료까지의 10초 변수 13개와 관계 2종
단계별 기준선 E4	로지스틱 회귀, 그래디언트 부스팅, 랜덤 포레스트, XGBoost, 다층 퍼셉트론	단계 k 의 행에서 선택한 변수 3-150개
마지막 시점 E5	신경망	단계 k 종료 직전의 10초 기록 13개 값
마지막 시점 E5	그래디언트 부스팅	단계와 관측 시각 4개 및 단계 k 종료 직전의 13개 값, 총 17개
이전 시점 기록 요약 E5	그래디언트 부스팅	경기 시작부터 k 단계 종료까지의 13개 변수를 요약한 값과 단계, 관측 시각 및 관측 수, 총 99개
시간 순서 E5	TCN, GRU, LSTM, Transformer	경기 시작부터 k 단계 종료까지 순서대로 배열한 13개 변수의 기록
두 자료 결합 E6	시간 합성곱 모형	1- k 단계의 단계별 변수 150개, 경기 시작부터 k 단계 종료까지의 10초 변수 13개와 관계 2종
두 자료와 관계 결합 E6	GraphSAGE, R-GCN, MR-FARNet, ST-GNN-Mamba	앞 행의 입력과 1- k 단계의 단계별 관계 3종

6.5.6 모형 학습과 구현 설정

결합 모형은 10초 기록 처리부의 은닉 크기를 48, 단계 처리부의 은닉 크기를 64로 두고 단계 처리 층 두 개를 사용한다. 관계 모형의 은닉 벡터 크기는 128이며 드롭아웃은 0.1이다. 10초 기록만 사용하는 신경망은 은닉 크기 48과 한 개의 시간 처리 층을 사용하고, Transformer는 네 개의 주의집중 머리를 사용한다. 신경망은 AdamW [24], 학습률 10^{-3} , 가중치 감쇠 10^{-4} , 코사인 학습률 감소 [23], 기울기 한계 5.0을 사용하여 12에포크 동안 배치 크기 8로 학습한다. 구현에는 PyTorch 2.7 [26]을 사용한다.

그래디언트 부스팅은 200회 반복과 학습률 0.06을 사용한다. XGBoost는 추정기 300개, 최대 깊이 4, 학습률 0.06으로 설정하고, 랜덤 포레스트는 추정기 300개를 사용한다. 다층 퍼셉트론은 크기 64와 32의 은닉층과 조기 종료를 사용한다. 이 모형들은 scikit-learn 1.7 [27]과 XGBoost 3.0 [7]으로 구현한다. 모든 모형은 시드 42로 비교하고, 대표 집단에서는 시간 합성곱 모형, MR-FARNet과 ST-GNN-Mamba를 시드 13과 2026으로 추가 반복한다.

6.6 연구 문제 4: 단계별 위험의 경기 중 활용(E7)

E3-E6은 다음 단계 탈락 위험의 예측 근거를 확인한다. 그러나 본 논문의 최종 목적은 이 위험을 한 시점의 분류값으로 남겨 두는 데 있지 않다. E7은 현재 단계의 위험으로 다음 단계 탈락 팀을 찾을 수 있는지 평가하고, 이어서 단계별 위험을 3장의 누적식에 대입한 생존 점수가 경기 진행에 따라 달라지는지 확인한다. 두 평가는 같은 모형의 출력에서 출발하지만 서로 다른 순위를 대상으로 한다.

각 단계에서 다음 단계 탈락 위험이 높은 순서로 탈락 위험 순위를 만들고, 누적 생존 점수의 경기 내 비율이 높은 순서로 누적 생존 점수 순위를 만든다. 탈락 위험 순위는 실제 다음 단계 탈락 팀에 대한 상위 1팀 및 상위 3팀 적중률과 평균 역순위(MRR)로 평가한다. 누적 생존 점수 순위는 1위 팀의 최종 상위 5팀 및 상위 10팀 진입률과 상위 5개 팀에 대한 순위 할인 누적 이득(NDCG)으로 평가한다. 인접한 단계에서 1위 팀이 바뀌는 비율도 함께 측정하여 점수가 경기 종료 후의 결과를 고정적으로 되풀이하는지 확인한다.

비교 대상은 무작위 순위, 생존 인원과 체력, 안전 영역까지의 거리, Sagong 등의 점수, 공식 원자료 기반 모형의 순위, 안전 영역의 변화와 현재 위치 및 주변 상황을 학습한 순위다. 학습 모형에는 단계별 위험을 누적인 생존 점수를 사용한다. 규칙 기반 방법에는 누적 확률을 정의할 수 없으므로, 각 점수를 생존에 유리한 방향으로 정렬한 순위를 비교 기준으로 사용한다. 모든 비교는 13개 집단에서 모든 방법의 팀별 점수가 공통으로 존재하는 10,616개 경기-단계 순위표를 사용한다. 다음 단계 탈락 팀이 없는 단계는 탈락 위험 순위의 분모에서 제외하고, 생존에 유리한 팀의 순위에는 남아 있는 팀이 둘 이상인 단계만 포함한다. 학습된 탈락 위험 순위가 규칙 기반 순위보다 다음 탈락 팀을 잘 찾는지, 누적 생존 점수의 선두가 단계에 따라 달라지는지, 그리고 그 선두가 최종 상위권 결과와 관련되는지를 각각 확인한다.

Chapter 7

연구 문제별 결과와 해석

7.1 연구 문제와 결과의 연결

6장의 E1-E7은 장르 정식화의 적용 가능성, PUBG 자료에서의 표현, 표현의 예측 타당성과 모형 비교, 경기 중 생존 평가의 순서로 이어진다. 표 7.1는 각 연구 문제에 사용한 실험과 핵심 결과의 의미를 먼저 제시한다. 뒤 절에서는 표의 판단 근거를 실험별로 설명한다.

이 장에서는 먼저 E1과 E2를 통해 장르 차원의 정식화를 PUBG 자료로 표현할 수 있는지 확인한다. 이어 E3과 E4에서 그 표현이 다음 단계의 생존과 탈락을 구분하는지 검토하고, E5와 E6에서는 이전 시점의 기록과 팀 관계를 다루는 모형의 적합성을 비교한다. 마지막으로 E7에서 단계별 위험을 경기 중 지표로 사용할 수 있는지 평가한다. 각 절의 마지막에는 해당 결과가 무엇을 확인했으며 다음 실험이 왜 필요한지를 함께 제시한다.

7.2 연구 문제 1: 생존 과정 정식화의 적용 범위(E1)

E1의 목적은 3장에서 정의한 생존 요인이 PUBG의 규칙을 다시 나열한 것인지, 다른 형태의 배틀로얄과 탈락 게임을 비교하는 데에도 사용할 수 있는지 확인하는 것이다. 6장의 선정 절차에 따라 전투 중심 배틀로얄, 능력 및 시스템 변형, 총격전이 없는 탈락형 게임을 포함한 15개 사례를 검토하였다. 사례별 분류 결과와 출처는 부록의 표 A.1에 제시한다. 검토의 초점은 각 게임이 PUBG와 같은 규칙을 갖는가가 아니라, 3장의 O0-O8 범주로 설명하기 어려운 별도의 생존 요인이 필요한가에 두었다.

전투 중심 사례에서는 안전 영역의 축소, 생존 자원의 획득, 교전, 최후 생존이라는 구조가 공통으로 나타났다. Fortnite의 건설은 경기 중 바뀌는 공간 조건으로, Apex Legends와 Warzone의 부활은 팀 상태와 탈락 시점의 변화로 표현할 수 있었

Table 7.1: 연구 문제별 실험과 결과의 의미

연구 문제와 검증 목적	핵심 결과와 해석
RQ1 (E1) 반복되는 생존 구조를 장르 차원에서 정식화할 수 있는지 검토	15개 사례에서 별도 요인을 추가할 필요는 없었다. O0-O8을 서로 다른 생존 조건을 비교하는 분석 범주로 사용할 수 있음을 보여준다.
RQ2 (E2) 정식화를 단계별 상태, 시간 변화와 팀 관계 자료로 표현할 수 있는지 확인	13개 집단의 17,943경기에서 1,033,471개 단계별 사례와 10초 단위 기록 및 팀 관계를 구성하였다. 정식화의 구성 요소를 PUBG 공식 경기 기록에서 측정할 수 있음을 보여준다.
RQ3 (E3-E6) 자료 표현의 예측 타당성과 자료 구조에 적합한 모형을 평가	안전 영역의 변화와 현재 위치 및 주변 상황을 포함할 때 가장 일관된 개선이 나타났고, 이전 시점의 기록도 최근 한 시점보다 유용했다. 단계별 위험에는 요약 통계 기반 트리 모형이 강했고, 그래프 모형 사이의 차이와 관계 정보의 추가 효과는 작았다.
RQ4 (E7) 단계별 위험과 누적 생존 점수가 상대적 생존 여건을 나타내는지 확인	학습된 위험 순위가 규칙 기반 순위보다 다음 단계 탈락 팀을 더 잘 찾았고, 생존 점수 1위도 경기 중 계속 바뀌었다. 이 점수는 관측에 따라 갱신되는 경기 내 지표로 해석할 수 있다.

다. Free Fire는 같은 구조를 더 짧은 시간 척도에서 구현한다. 따라서 이 사례들의 차이는 요인 자체보다 공간의 변화 방식과 탈락이 확정되는 시점에 있었다.

능력과 시스템이 다른 사례에서도 기존 요인의 의미를 조정하면 같은 틀을 적용할 수 있었다. NARAKA: BLADEPOINT의 입체 이동은 이동 반응의 범위를 넓히고, Eternal Return의 제작은 생존 자원을 세분화한다. Realm Royale Reforged의 부활 유예와 CS:GO Danger Zone의 정보 장비는 각각 탈락 판정과 관측 범위를 바꾸지만 별도의 생존 요인을 추가할 필요는 없었다.

충격전이 없는 사례는 원형 안전 영역이 없어도 시간과 공간의 변화가 생존 조건과 탈락 위험을 만들 수 있는지 살펴보기 위해 포함하였다. Fall Guys에서는 라운드별 통과 정원과 남은 시간이 생존 조건으로, Tetris 99에서는 보드 상태와 표적 공격이 공간 및 관계 조건으로, F-ZERO 99에서는 기체 에너지와 충돌이 팀 상태와 위험 노출로 대응되었다. 이 결과는 요인의 구체적인 측정값이 게임마다 달라질 수 있음을 보여준다.

15개 사례 모두 기존 범주로 설명할 수 있었으며, 별도의 생존 요인을 추가해야 하는 사례는 없었다. 다만 이 결과는 O0-O8이 장르의 보편 법칙임을 입증하는 것이 아니다. 대표 사례의 규칙을 비교할 때 사용할 수 있는 분석 범주라는 점을 뒷받침한다. 다른 게임에 적용하려면 단계 경계, 탈락의 확정 시점, 관측 가능한 사건을 해당 게임의 규칙에 맞게 다시 정의해야 한다. 따라서 E1은 요인 구분의 적용 가능성을 지지하지만, 배틀로얄 장르 전체에 동일한 측정 변수를 그대로 적용할 수

Table 7.2: 대표 게임 사례의 검토 결과

구분	주요 사례	확인된 차이
전투 중심	PUBG, Fortnite, Apex Legends, Warzone, Free Fire	공간 변화, 부활, 경기 시간
능력 및 시스템 변형	NARAKA, Eternal Return, Super Animal Royale 외 4종	이동, 제작, 정보, 탈락 유예
충격전 없는 탈락형 게임	Fall Guys, Tetris 99, F-ZERO 99	충격전 없는 환경의 생존 조건과 탈락 위험

Table 7.3: 분석 집단별 단계 예측 자료의 구성

지도	시점	팀 규모	경기 수	예측 사례 수	탈락률
Erangel	TPP	스쿼드	6,204	315,108	31.8%
Taego	TPP	스쿼드	4,159	213,401	29.1%
Miramar	TPP	스쿼드	1,543	87,810	28.6%
Rondo	TPP	스쿼드	1,039	51,984	28.8%
Sanhok	TPP	스쿼드	940	46,793	32.3%
Erangel	TPP	솔로	800	117,031	36.3%
Erangel	TPP	듀오	656	59,480	32.3%
Taego	TPP	듀오	573	48,036	32.6%
Vikendi	TPP	스쿼드	498	28,237	30.3%
Taego	FPP	스쿼드	435	22,702	33.3%
Erangel	FPP	스쿼드	430	20,974	31.4%
Karakin	TPP	스쿼드	333	12,243	35.6%
Paramo	TPP	스쿼드	333	9,672	34.2%
합계			17,943	1,033,471	

있음을 입증한 결과는 아니다.

이로써 여러 게임에 공통으로 물을 수 있는 생존 조건의 범주는 마련되었다. 다만 개념을 분류할 수 있다는 사실만으로 실제 예측이 가능해지는 것은 아니다. 다음 E2에서는 이 범주를 PUBG의 공식 경기 기록에서 예측 시점별 입력과 목표값으로 만들 수 있는지 확인한다.

7.3 연구 문제 2: PUBG 기록에서의 자료 표현(E2)

E2는 3장의 관측 단위와 목표값을 공식 경기 기록에서 실제로 만들 수 있는지 확인하는 절차다. 핵심 판단 기준은 자료의 양 자체가 아니라, 각 단계의 입력이 예측 시점까지의 기록만으로 계산되고 경기 종료 후의 결과와 분리되는지 여부다.

13개 분석 집단의 17,943경기에서 단계별 팀 입력과 목표값을 구성하였다. 다음 단계가 존재하는 단계 1부터 7까지 총 1,033,471개의 예측 사례가 만들어졌고, 집단별 탈락 사례의 비율은 28.6%에서 36.3% 사이였다. 단계 8 이후에 해당하는 약 0.3%의 희소한 사례는 분석에서 제외하였다.

입력 변수와 목표값의 분리는 자동 검사를 통해 확인하였다. 다음 단계 탈락, 최종 순위, 상위권 진입, 승리 여부는 목표값 또는 평가값으로만 존재하며 모형 입력에는 포함되지 않았다. 또한 예측 시점 이후의 사건을 제거한 자료를 다시 구성했을 때 입력 결과가 바뀌지 않는지 검사하였다. 이 검사는 10초 격자 정렬에 따르는 ± 5 초의 관측 불확실성을 없애지는 않지만, 경기 종료 후의 결과가 입력으로 들어가는 정보 누수를 방지한다. 이로써 연구 질문 2의 관측 단위와 목표값을 PUBG 공식 경기 기록에서 구현할 수 있음을 확인하였다.

E2의 결과는 이후 실험이 미래 결과를 미리 사용하지 않고 수행될 수 있음을 보장한다. 그러나 자료를 구성할 수 있다는 사실은 각 생존 요인이 예측에 유용하다는 뜻까지 포함하지 않는다. E3에서는 같은 자료와 모형을 유지한 채 변수 묶음만 차례로 더하여, 어떤 조건이 실제 탈락 위험을 구분하는지 검토한다.

7.4 연구 문제 3: 자료 표현의 타당성과 모형의 적합성

7.4.1 생존 요인의 표현이 더하는 정보(E3)

E3는 팀 상태와 이동만 사용한 경우에 비해 안전 영역, 교전과 주변 팀 정보가 각각 새로운 예측 정보를 제공하는지 확인한다. 10초 기록 처리부, 단계 관계를 사용하지 않는 결합 모형, 경기 분할과 학습 절차를 고정하고 단계별 변수 묶음만 차례로 확장하였다. 표 7.4는 단계별 입력을 OM0부터 OM6까지 확장한 결과다. Erangel TPP 스퀘드에서 가장 큰 단일 증가는 OM2에서 OM3으로 넘어갈 때 나타났다. 안전 영역의 변화와 현재 위치 및 주변 상황을 추가하자 AUC가 0.7836에서 0.7937로 0.0102 증가하였다. 같은 비교는 나머지 12개 집단에서도 모두 양의 방향이었고, 증가 폭은 0.0057에서 0.0211 사이였다.

Table 7.4: 대표 집단과 전체 집단을 요약한 입력 변수 추가 결과

조합	Erangel AUC	Erangel AP	AUC 중앙값	AP 중앙값
OM0 경기 맥락	0.7832	0.6658	0.7353	0.6103
OM1 팀 상태	0.7836	0.6652	0.7336	0.6186
OM2 이동과 회전	0.7836	0.6673	0.7397	0.6200
OM3 안전 영역 변화와 위치 및 주변 상황	0.7937	0.6801	0.7499	0.6338
OM4 교전과 위험 노출	0.7951	0.6838	0.7527	0.6364
OM5 팀 간 관계 요약	0.7944	0.6821	0.7530	0.6332
OM6 주변 적 분포	0.7948	0.6838	0.7540	0.6414

표 7.4은 대표 집단과 13개 집단의 중앙값을 요약한 것이다. 중앙값만으로 집단별 차이가 가려지지 않도록, 가장 큰 변화가 나타난 OM2와 OM3의 AUC 차이를 그림 7.1에 집단별로 제시하였다. 13개 집단 모두 양의 방향이었으며, 증가 폭은

Rondo TPP 스퀘드의 0.0057부터 Erangel TPP 솔로의 0.0211까지 분포하였다. 집단별 OM2와 OM3의 정확한 값은 부록 표 A.3에 제시한다.




Figure 7.1: 13개 분석 집단의 OM2 대비 OM3 다음 단계 탈락 예측 AUC 변화

OM3 이후에도 일부 지표는 조금 더 높아졌지만, 추가 폭은 집단과 지표에 따라 달랐다. 팀 관계 통계와 주변 적 분포를 모두 더한다고 해서 순위 상관이 계속 높아지는 형태도 나타나지 않았다. 따라서 이 결과는 가능한 변수를 많이 넣을수록 항상 좋다는 뜻보다, 이동 정보만으로는 드러나지 않던 안전 영역의 변화와 주변 상황을 함께 고려할 때 예측에 필요한 정보가 늘어난다는 근거로 해석하는 편이 타당하다. 즉 E3의 핵심 결과는 OM3이 항상 최적이라는 것이 아니라, 이동량의 의미를 안전 영역과 주변 경쟁 상황 안에서 해석해야 탈락 위험을 더 잘 구분할 수 있다는 점이다.

단계를 나눈 대응 부트스트랩에서도 이 해석이 유지되었다. 초반 단계 1-2에서는 OM2 대비 OM3의 위험 AUC, 최종 순위 상관, 상위 10팀 판별이 모두 신뢰구간의 지지를 받았다. 중반 단계 3-4에서는 순위 관련 지표의 개선이 확인되었다. 반면 OM0에서 OM1로 팀 상태를 추가한 비교는 같은 기준을 충족하지 못했다. 후반 단계는 남은 팀과 사건 수가 적어 추정 구간이 넓었으므로 방향만 참고하였다.

E3은 안전 영역의 변화와 현재 위치 및 주변 상황이 이동 정보에 더해질 때 가장 일관된 증가가 나타난다는 점을 확인하였다. 아직 두 가지 대안 설명이 남는다. 변수의 개수가 늘어난 효과일 수 있고, 이 결합 모형에서만 나타난 결과일 수도 있다. E4는 선행 점수와 공식 원자료, 여러 학습 모형을 비교하여 이 가능성을 검토한다.

7.4.2 선행 방식과 일반 기준선의 비교(E4)

E4는 E3의 개선이 복잡한 변수 수의 증가만으로 나타난 것인지, 선행연구의 점수와 공식 원자료를 단순 요약한 기준선보다 실제로 더 많은 정보를 제공하는지 확인한다. 표 7.5는 같은 경기 분할과 예측 시점에서 요약 통계 기반 모형을 비교한

결과다. Sagong 등의 방식을 단계별 팀 예측에 맞게 조정한 점수 기준선은 Erangel에서 AUC 0.6726이었다. 공식 원자료를 기본 변수로 요약한 모형은 0.7690, 일반적인 상태 변수 모형은 0.7625로 더 높았다. 원자료에 안전 영역의 변화와 현재 위치 및 주변 상황을 더한 구성은 0.7869로 상승하여 전체 변수를 사용한 결과와 비슷한 수준에 도달하였다.

Table 7.5: 선행 방식 및 요약 통계 기반 기준선 비교

입력 구성	Erangel AUC	Erangel AP	AUC 중앙값	AP 중앙값
Sagong 등의 방식에 따른 점수	0.6726	0.4734	0.6525	0.4480
일반적인 상태 변수	0.7625	0.6357	0.7458	0.6174
공식 원자료 요약 변수	0.7690	0.6462	0.7521	0.6307
원자료, 안전 영역 변화, 위치 및 주변 상황	0.7869	0.6714	0.7742	0.6566
전체 변수	0.7883	0.6728	0.7740	0.6586
상태, 공간, 관계, 위치 및 주변 상황 변수	0.7863	0.6687	0.7753	0.6577

13개 집단 중앙값에서도 같은 순서가 대체로 유지되었다. 상태, 공간, 관계, 위치 및 주변 상황 변수는 Sagong 등의 방식에 따른 점수보다 13개 집단 모두에서 높았고, 공식 원자료 요약 변수보다 12개 중 11개 보조 집단에서 높았다. Paramo에서는 공식 원자료 요약 변수가 0.0076 높았다. 같은 변수를 학습 알고리즘별로 비교한 중앙 AUC는 그래디언트 부스팅 0.7753, XGBoost 0.7717, 랜덤 포레스트 0.7631, 다층 퍼셉트론 0.7619, 로지스틱 회귀 0.7523이었다. 입력 변수의 효과가 한 알고리즘에만 나타난 것은 아니지만, 비선형 트리 모형이 가장 강한 단계 요약 기준선이었다. E4는 생존 요인에 따라 구성한 변수가 선행 점수와 원자료 요약보다 대체로 유용함을 보여주지만, Paramo의 예외처럼 모든 경기 조건에서 같은 폭의 우위를 보장하지는 않는다.

E4에서 공간 및 주변 상황 변수의 효과는 선행 점수와 공식 원자료를 기준으로 삼아도 대체로 유지되었고, 한 학습 알고리즘에만 한정되지 않았다. 이 결과는 E3의 해석을 강화한다. 다만 E3과 E4는 한 단계의 기록을 요약한 값으로도 높은 성능을 얻을 수 있음을 함께 보여준다. 배틀로얄을 시간에 따라 갱신되는 과정으로 해석하려면 과거 기록이 최근 상태보다 실제로 더 많은 정보를 제공하는지 별도로 확인해야 하므로, E5에서 이전 시점의 기록을 비교한다.

7.4.3 이전 시점의 기록에 적합한 모형(E5)

E5는 과거 10초 기록이 최근 상태 한 줄보다 실제로 더 유용한지, 그리고 같은 기록을 통계로 요약하는 방법과 시간 순서대로 처리하는 방법이 어떻게 다른지 확인한다. 시간 이력을 사용하는 모형은 예측 직전 한 시점만 사용하는 모형보다

대체로 높은 성능을 보였다. Erangel에서 시계열 통계를 사용한 그래디언트 부스팅의 AUC는 0.7733, LSTM은 0.7664, Transformer는 0.7674, GRU는 0.7658이었다. 마지막 시점만 사용한 신경망은 0.7281이었다. 13개 집단 중앙값에서는 시계열 통계 기반 그래디언트 부스팅이 0.7550으로 가장 높았고, Transformer는 0.7471, LSTM은 0.7441이었다.

Table 7.6: 같은 관측 변수와 예측 시점을 사용한 시계열 모형 비교

모형	Erangel AUC	Erangel AP	AUC 중앙값	AP 중앙값
시계열 통계와 그래디언트 부스팅	0.7733	0.6635	0.7550	0.6457
Transformer	0.7674	0.6596	0.7471	0.6249
LSTM	0.7664	0.6560	0.7441	0.6209
GRU	0.7658	0.6541	0.7355	0.6148
시계열 통계와 XGBoost	0.7620	0.6481	0.7530	0.6427
마지막 시점의 값과 그래디언트 부스팅	0.7485	0.6334	0.7411	0.6315
TCN	0.7436	0.6269	0.7325	0.6238
마지막 시점만 사용한 신경망	0.7281	0.6113	0.7213	0.6091

그림 7.2은 복잡한 개별 점 대신 각 모형의 전체 범위와 대표값을 보여준다. 가로선의 양 끝은 13개 집단의 최솟값과 최댓값, 검은 사각형은 중앙값, 파란 원은 대표 집단인 Erangel TPP 스쿼드다. 마지막 시점만 사용한 모형은 중앙값과 범위가 모두 이전 시점의 기록을 사용한 주요 모형보다 왼쪽에 놓였다. 집단별 정확한 수치는 부록 표 A.4에 제시한다.




Figure 7.2: 10초 기록을 이용한 다음 단계 탈락 예측의 13개 집단 AUC 분포

이 결과는 이전 시점 기록의 유용성과 모형의 우월성을 구분해서 볼 필요가 있음을 보여준다. LSTM은 마지막 시점만 사용한 신경망보다 12개 보조 집단 중 11개에서 높았으므로 이전 시점의 기록이 실제로 기여한다. Transformer의 중앙 AUC는 LSTM보다 0.0030 높았지만, 관측 이력을 구간별 통계로 요약한 트리 모형에는 미치지 못했다. 따라서 시계열 신경망의 역할은 가장 정확한 단계별 예측

모형을 대체하는 데 있기보다, 경기 진행에 따라 같은 팀의 위험과 누적 생존 점수가 어떻게 달라지는지 연속된 형태로 제공하는 데 있다.

E5는 예측 직전의 상태만 보는 것보다 과거 기록을 함께 사용하는 편이 유용하다는 근거를 제공한다. 동시에 이전 시점의 기록을 통계로 요약한 트리 모형이 가장 강한 기준선으로 남았으므로, 시간성의 근거와 특정 시계열 신경망의 우월성은 구분해서 해석해야 한다.

여기서 표 7.6와 그림 7.2의 AUC와 AP가 평가하는 시점도 구분할 필요가 있다. 시계열 모형은 경기 시작부터 예측 시점까지의 10초 기록을 입력으로 읽지만, 표의 예측값은 경기 단계가 끝나는 시점에서 산출한 다음 단계 탈락 위험이다. 따라서 이 결과는 10초 기록의 시간 순서가 단계별 예측에 도움이 된다는 근거다.

이 구분에 따라 E5가 뒷받침하는 결론은 이전 시점의 기록이 단계 전환 시점의 탈락 예측에 기여한다는 데 한정된다.

다음 E6에서는 입력을 고정한 뒤 팀 관계의 사용 여부를 바꾸어, 이전 시점의 기록 외에 실제 상대 팀의 정보가 추가로 필요한지 검토한다.

7.4.4 팀 관계에 적합한 모형(E6)

E6는 같은 단계별 자료와 10초 기록을 사용할 때 팀 관계와 단계 처리 구조가 추가로 제공하는 정보를 확인한다. 제안 모형의 일방적인 우위를 보이기 위한 비교가 아니라, 입력을 고정한 상태에서 관계를 합치는 방법과 시간 연산을 바꾸는 비교다. 단계 관계와 시간 처리 방식을 바꾸어 다섯 구성을 비교하였다. 표 7.7의 Erangel 결과에서 모형 간 위험 AUC 차이는 0.0013 이내였다. GraphSAGE의 AUC가 0.7973으로 가장 높았고, ST-GNN-Mamba의 AP가 0.6884로 가장 높았다. 최종 순위 상관관은 MR-FARNet이 0.6889로 가장 높았으며 ST-GNN-Mamba가 0.6886으로 뒤를 이었다.

Table 7.7: Erangel TPP 스크드의 단계별 및 10초 단위 자료 결합 모형 비교

모형	위험 AUC	위험 AP	최종 순위 상관
시간 합성곱 모형	0.7962	0.6845	0.6587
GraphSAGE	0.7973	0.6873	0.6573
R-GCN	0.7960	0.6836	0.6605
MR-FARNet	0.7967	0.6862	0.6889
ST-GNN-Mamba	0.7972	0.6884	0.6886

13개 집단 중앙 위험 AUC는 시간 합성곱 모형 0.7560, GraphSAGE 0.7639, R-GCN 0.7625, MR-FARNet 0.7599, ST-GNN-Mamba 0.7595였다. 집단별 최고 AUC는 GraphSAGE, R-GCN, MR-FARNet이 각각 3개 집단에서, 시간 합성곱 모형과 ST-GNN-Mamba가 각각 2개 집단에서 기록하였다. 최종 순위 상관관의 중앙

값은 MR-FARNet 0.6503, ST-GNN-Mamba 0.6562로 시간 합성곱 모형의 0.6144보다 높았다. 위험 예측에서는 하나의 구조가 일관되게 우세하지 않았지만, 팀 간 비교와 순위 손실을 포함한 구성은 최종 순서의 학습에 도움이 되었다.

대표 집단에서 세 난수 시드를 사용한 반복 결과는 표 7.8과 같다. 세 모형의 표준편차는 모든 지표에서 0.0012 이하였으므로, 대표 집단의 차이가 특정 초기값 하나에서만 나타난 결과라고 보기는 어렵다. 다만 이 반복은 대표 집단에 한정되므로 13개 집단의 구조적 우열을 대신하지 않는다.

Table 7.8: 대표 집단의 세 난수 시드 반복 결과 (평균과 표준편차)

모형	위험 AUC	위험 AP	최종 순위 상관
시간 합성곱 모형	0.7955 ± 0.0007	0.6839 ± 0.0008	0.6578 ± 0.0012
MR-FARNet	0.7963 ± 0.0004	0.6862 ± 0.0008	0.6892 ± 0.0012
ST-GNN-Mamba	0.7972 ± 0.0002	0.6884 ± 0.0001	0.6884 ± 0.0009

관계 입력이 실제 상대의 정보를 담는지 확인하기 위해, MR-FARNet의 연결 수는 유지하면서 연결 상대만 바꾼 대조 실험을 수행하였다. 실제 관계를 사용한 위험 AUC는 13개 집단 모두에서 더 높았으나 증가 폭의 중앙값은 0.0023이었고, 95% 신뢰구간의 하한이 0보다 큰 집단은 6개였다. 최종 순위 상관도 13개 중 9개 집단에서 양의 방향을 보였다. 따라서 관계 정보에는 무작위 연결로 설명되지 않는 신호가 일부 있지만, 그 크기는 안전 영역 및 주변 상황 변수의 효과보다 작았다. 단계 구간별 결과는 부록 표 A.6에 제시한다. 따라서 E6은 특정 그래프 모형의 우위를 확정하기보다, 실제 관계에 작은 추가 정보가 존재하되 위험 예측의 주된 근거는 입력 변수와 이전 시점의 기록에 있음을 보여준다.

따라서 E6은 다중 에이전트 관계가 전혀 무관하다는 결론보다, 현재 자료에서 확인된 추가 정보의 크기가 작다는 결론을 지지한다. 본 논문의 주된 실증 근거는 E3-E5에서 확인한 생존 조건과 이전 시점의 기록에 두며, 그래프 구조는 이를 보완하는 결과로 해석한다. E7에서는 이 범위 안에서 학습된 탈락 위험이 경기 중 갱신되는 순위로도 의미를 갖는지 확인한다.

7.5 연구 문제 4: 단계별 위험의 경기 중 활용(E7)

E7은 같은 모형 출력에서 서로 다른 두 순위를 구성하여 평가한다. 현재 단계의 탈락 위험 순위는 다음 단계에 탈락할 팀을 얼마나 잘 찾는지 평가하고, 단계별 위험을 누적한 생존 점수 순위는 경기 중 선두가 어떻게 달라지며 최종 상위권 결과와 어떤 관련이 있는지 살핀다. LSTM이 산출한 단계별 탈락 위험에 3장의 누적식을 적용하여 팀별 누적 생존 점수와 경기 내 생존 점수 비율을 계산하였다. 그림 7.3는 한 경기에서 상위 팀들의 생존 점수 비율과 다음 단계 탈락 위험이 함께 변하

는 사례다. 한 번 높아진 팀의 점수가 그대로 유지되는 것이 아니라, 안전 영역의 축소와 교전 상황에 따라 팀 사이의 순서가 바뀐다.




Figure 7.3: 한 경기에서 단계별로 갱신된 팀별 생존 점수 비율의 예

LSTM 결과가 존재하는 13개 집단의 10,616개 경기별 단계 순위표에서 인접한 단계 사이에 누적 생존 점수 1위 팀이 바뀐 비율의 평균은 0.4214였다. 이는 경기당 0.42회 바뀌었다는 뜻이 아니라, 비교 가능한 단계 전환의 약 42.1%에서 1위 팀이 달라졌다는 뜻이다. 누적 생존 점수가 경기 종료 후의 고정 순위를 다시 표현한 값이 아니라, 관측이 추가될 때마다 달라지는 경기 내 지표임을 보여준다.

그림 7.4은 다음 단계에 탈락한 팀을 첫 번째로 찾은 비율의 전체 범위와 대표값을 비교한다. 가로선은 13개 집단의 최솟값과 최댓값, 검은 사각형은 중앙값, 파란 원은 대표 집단이다. 학습 기반 세 방식의 중앙값과 범위는 규칙 기반 방식보다 오른쪽에 놓였다. 집단별 정확한 값은 부록 표 A.5에 제시한다. 모형과 기준 점수를 공정하게 비교하기 위해 모든 방법에서 같은 팀의 점수가 존재하는 경기-단계만 남겼으며, 이 조건을 만족한 순위표는 10,616개였다. 표 7.9는 각 집단에서 지표를 먼저 계산한 뒤 13개 집단의 중앙값을 제시한다. 앞의 세 지표는 탈락 위험 순위의 평가값이고, 마지막 지표는 생존에 유리한 팀의 순위에서 1위 팀이 최종 상위 10팀에 든 비율이다. 학습 모형 세 행의 마지막 지표에는 단계별 위험을 누적한 생존 점수를 사용하였다.

Erangel TPP 스쿼드에서 LSTM 탈락 위험 순위의 상위 1팀 적중률은 0.7292, 안전 영역 변화, 위치 및 주변 상황 기반 순위는 0.7188이었다. 보조 집단에서는 두 방식의 순서가 달라졌으며, 단계별 요약 변수 기반 모형의 탈락 위험 순위가 8개 집단에서, LSTM 탈락 위험 순위가 4개 집단에서 높았다. 따라서 LSTM을 가장 정확한 예측 모형으로 보기보다 시간에 따라 변하는 출력을 만드는 모형으로 해석한다. 단계별 요약 변수를 사용하는 트리 모형은 현재 예측 시점의 위험을 평가하는 강한 기준선이다.




Figure 7.4: 순위 구성 방법별 상위 1팀 적중률의 13개 집단 범위, 중앙값 및 대표 집단

Table 7.9: 탈락 위험 순위와 생존에 유리한 팀의 순위 비교: 13개 집단의 중앙값

구성 방법	탈락 위험 순위			생존에 유리한 팀의 순위 1위 팀의 최종 상위 10팀 진입률
	상위 1팀	상위 3팀	MRR	
안전 영역 변화, 위치 및 주변 상황 기반 모형	0.7188	0.9359	0.8296	0.9514
LSTM	0.7004	0.9172	0.8121	0.9490
공식 원자료 기반 모형	0.6952	0.9252	0.8113	0.9473
생존 인원과 체력	0.5094	0.8349	0.6853	0.9184
Sagong 등의 점수	0.4897	0.8385	0.6756	0.9042
안전 영역 거리	0.4240	0.7599	0.6117	0.8926
무작위 순위	0.3868	0.7564	0.6008	0.8742

누적 생존 점수 순위 1위 팀의 최종 상위 10팀 진입률은 학습 기반 세 방식에서 0.95 안팎으로 비슷했다. LSTM의 경우 최종 상위 5팀 진입률의 집단 중앙값은 0.7863, 최종 상위 10팀을 기준으로 한 상위 5개 팀의 NDCG 중앙값은 0.9389였다. 그러나 무작위로 만든 생존 순위도 최종 상위 10팀 진입률이 0.8742, NDCG가 0.8717로 높았다. 경기 후반에는 남아 있는 팀 다수가 이미 최종 상위권에 가까워지기 때문에 이 지표의 절대값만으로 예측력을 판단하기 어렵다. 반면 다음 단계 탈락 팀을 찾는 상위 1팀 적중률과 MRR에서는 학습 기반 방식과 무작위 기준의 차이가 컸다. 현재 자료는 최종 결과와의 관련성보다 다음 단계의 탈락 위험을 식별하는 능력을 더 강하게 뒷받침한다. 따라서 E7에서 누적 생존 점수는 예측된 승률이 아니라, 현재까지의 단계별 위험을 반영하여 팀들의 상대적 위치를 계속 갱신하는 기술적 지표로 해석한다.

7.6 연구 문제별 답변

7.6.1 연구 문제 1에 대한 답변

대표 게임 15종을 검토한 결과, 경기 조건, 팀 상태, 이동, 위험 노출, 생존 자원, 공간 조건과 팀 관계라는 범주로 서로 다른 규칙의 생존 조건을 기술할 수 있었다. 따라서 배틀로얄은 경기 단계마다 생존 조건이 갱신되고 아직 탈락하지 않은 팀들의 다음 단계 위험이 누적되는 다중 에이전트 생존 과정으로 정식화할 수 있다. 이 답변은 장르의 보편 법칙을 확정한 결과보다, 서로 다른 게임을 비교할 분석 범주를 제시한 결과로 해석한다.

7.6.2 연구 문제 2에 대한 답변

PUBG 공식 경기 기록에서는 이 생존 과정을 단계별 상태, 10초 간격의 연속 기록과 팀 관계로 표현할 수 있었다. 13개 분석 집단의 17,943경기에서 1,033,471개의 단계별 예측 사례를 구성했으며, 입력은 예측 시점까지의 관측으로 제한하고 이후의 탈락과 최종 결과는 목표값으로 분리하였다. 따라서 3장의 정식화는 PUBG 기록에서 측정 가능한 분석 자료로 구현할 수 있다.

7.6.3 연구 문제 3에 대한 답변

자료 표현의 예측 타당성은 안전 영역의 변화와 현재 위치 및 주변 상황을 추가했을 때 가장 일관되게 확인되었다. 이 효과는 선행 점수와 공식 원자료 요약에 기준으로 삼아도 대체로 유지되었고, 과거 기록도 예측 직전 한 시점보다 유용했다. 단계 전환 시점의 위험을 평가할 때에는 요약 통계를 사용한 그래디언트 부스팅이 가장 강한 기준선이었고, 시간에 따른 출력의 변화를 보존하는 데에는 LSTM과 같은

시계열 모형이 유용했다. 그래프 모형 사이의 차이와 실제 관계의 추가 효과는 작았으므로, 관계 구조는 현재 자료에서 보충적인 표현으로 판단한다.

7.6.4 연구 문제 4에 대한 답변

학습된 탈락 위험 순위는 규칙 기반 순위보다 다음 단계 탈락 팀을 더 잘 식별했으며, 누적 생존 점수의 선두도 단계 전환에 따라 바뀌었다. 전자의 예측 근거는 비교적 분명했지만, 후자는 최종 상위권과의 관련성에서 무작위 기준도 높았다. 따라서 누적 생존 점수는 최종 우승 확률보다 관측이 추가될 때 팀들의 상대적 위치를 갱신하는 기술적 지표로 해석하는 것이 타당하다. 종합하면 PUBG 자료에서는 배틀로얄의 결과를 단계마다 갱신되는 생존 조건과 탈락 위험의 누적으로 분석할 수 있었으며, 다른 게임으로의 예측 성능 일반화는 후속 검증의 범위로 남는다.

Chapter 8

연구 문제별 논의와 한계

8.1 연구 문제별 종합 해석

본 연구는 장르 정식화, PUBG 기록에서의 자료 표현, 표현의 예측 타당성과 모형의 적합성, 경기 중 상대적 생존 평가라는 네 연구 문제를 순서대로 다루었다. 이 구조는 가장 높은 성능을 기록한 모형 하나보다, 배틀로얄의 생존 과정을 어떤 개념과 자료로 표현하고 그 표현을 어떤 근거로 검증했는지를 중심에 둔다.

이 증거의 강도는 실험마다 다르다. 안전 영역의 변화와 현재 위치 및 주변 상황을 추가한 E3과 기준선 비교 E4, 이전 시점의 기록을 비교한 E5, 다음 단계 탈락 순위를 평가한 E7은 연구 주장을 직접 뒷받침한다. E1과 E2는 정식화와 자료 구성의 전제를 확인하며, E6의 관계 효과는 크기가 작아 보충적인 근거로 해석한다. 따라서 본 연구의 결론은 특정 그래프 신경망의 우월성보다, 변화하는 공간과 주변 경쟁 상황 및 과거 기록을 함께 보아야 다음 단계 탈락 위험을 더 잘 설명할 수 있다는 데 무게를 둔다.

8.2 생존 과정 정식화의 의미(연구 문제 1)

본 연구는 배틀로얄 결과를 경기 종료 시점의 순위 하나로 다루는 대신, 아직 탈락하지 않은 팀들의 조건이 단계마다 달라지는 생존 과정으로 구성하였다. 이 관점에서는 같은 팀도 안전 영역의 크기와 위치, 남은 팀의 배치, 이동 반응에 따라 서로 다른 위험에 놓인다. 다음 단계 탈락 위험은 이 변화를 가까운 시간 범위에서 측정하고, 누적 생존 점수는 여러 단계의 변화를 한 경기 안에서 비교할 수 있는 형태로 연결한다.

15개 게임 사례를 검토한 결과, 3장의 생존 요인은 PUBG 이외의 게임에도 적용할 수 있었다. 안전 영역이 없는 게임에서는 시간 제한이나 통과 인원이 단계별 생존 조건에 해당하고, 총격이 없는 게임에서는 충돌이나 표적 공격이 위험 노출에

해당하였다. 이 사례 검토는 장르 전체의 규칙을 빠짐없이 분류하기보다, 서로 다른 게임의 생존 조건을 비교하고 자료에서 측정할 항목을 정하는 분석 범주로서의 적용 가능성을 뒷받침한다.

8.3 자료 표현의 의미(연구 문제 2)

PUBG 공식 경기 기록은 생존 과정을 세 가지 시간 및 관계 수준으로 표현할 수 있게 하였다. 단계별 자료는 안전 영역의 변화와 팀 상태를 구조적 전환 시점마다 요약하고, 10초 단위 자료는 한 단계 안의 이동과 체력 변화 순서를 보존한다. 팀 관계 자료는 어느 팀들이 가까이 있었고 실제로 교전했는지를 나타낸다. 이 세 자료는 같은 경기를 서로 다른 해상도에서 설명하며, 한 종류의 요약값에서 사라지는 정보를 보완한다.

입력은 예측 시점까지의 관측으로 제한하고 이후의 탈락과 최종 결과는 목표값으로 분리하였다. 이 구분은 자료 표현이 실제 경기 중 이용 가능한 정보에 근거하도록 한다. 다만 공식 기록의 좌표는 경사, 엄폐, 건물 내부 구조와 시야선을 제공하지 않으므로, 공간 조건의 일부는 거리와 밀도 같은 간접 지표로 표현되었다. 또한 모든 관측값은 PUBG 기록에서 계산되었으므로 다른 게임에서는 단계와 사건 기록 방식에 맞춘 재구성이 필요하다.

8.4 표현의 타당성과 모형의 적합성(연구 문제 3)

생존 요인을 단계적으로 추가한 실험에서는 이동 정보에 안전 영역의 변화와 현재 위치 및 주변 상황을 더했을 때 가장 일관된 개선이 나타났다. 이는 팀의 이동을 이동량만으로 표현하기보다, 줄어드는 공간과 남은 경쟁자의 배치 속에서 해석해야 함을 보여준다. 교전, 관계 요약과 주변 적 분포를 추가한 효과는 상대적으로 작았으며, 고도 관련 변수도 일관된 개선으로 이어지지 않았다. 따라서 현재 자료에서 가장 분명하게 확인된 표현은 안전 영역의 변화와 현재 위치 및 주변 경쟁 상황의 결합이다.

요약 통계 기반 트리 모형은 다음 단계 탈락 위험에서 가장 강한 기준선이었다. 10초 단위 시계열을 통계값으로 요약한 그래디언트 부스팅은 LSTM, GRU, TCN보다 높은 중앙 AUC를 기록하였다. 반면 LSTM은 단계가 바뀔 때마다 같은 팀의 위험과 누적 생존 점수가 달라지는 과정을 직접 산출한다. 두 결과는 서로 경쟁하는 결론이라기보다 예측 목적의 차이를 보여준다. 한 시점의 위험을 정확히 채점하는 데에는 트리 모형이 유리했고, 경기 중 변화의 순서를 보존하는 데에는 시계열 모형이 유용했다.

이 비교에서 “10초 단위 시계열”은 입력 기록의 간격을 뜻한다. 본문에 보고한

성능은 단계 전환 시점의 다음 단계 탈락 위험에 대한 값이다. 따라서 현재 결과의 해석도 이전 시점 기록이 단계별 예측에 기여하는지에 한정한다.

단계별 자료와 10초 단위 자료를 결합한 모형에서도 하나의 구조가 모든 분석 집단에서 우세하지 않았다. GraphSAGE, R-GCN, MR-FARNet, ST-GNN-Mamba 사이의 위험 AUC 차이는 작았고, 집단별 최고 모형도 나뉘었다. MR-FARNet과 ST-GNN-Mamba는 최종 순위 상관에서 시간 합성곱 모형보다 높은 값을 보였지만, 이 차이에는 팀 간 주의 집중과 순위 쌍 손실의 영향이 함께 들어 있다. 그러므로 결과를 그래프 연산 하나의 효과로 귀속하지 않는다.

관측된 관계를 사용한 모형은 연결 상대를 바꾼 대조 모형보다 대체로 높은 값을 보였으나 차이는 작았다. 관계 정보에 무작위 연결만으로 설명되지 않는 정보가 있다는 보조 근거는 얻었지만, 그래프 구조를 본 연구의 핵심 근거로 보기는 어렵다. 현재 결과에서는 안전 영역의 변화와 현재 위치 및 주변 상황을 입력한 효과가 모형 구조의 세부 차이보다 더 일관되게 나타났다.

8.5 경기 중 상대적 생존 평가(연구 문제 4)

학습된 위험 순위는 무작위, 안전 영역 거리, 생존 인원과 체력, Sagong 등의 방식에 따른 점수보다 다음 단계 탈락 팀을 더 잘 식별하였다. 또한 누적 생존 점수의 1위 팀은 경기 단계가 바뀌는 동안 자주 교체되었다. 이는 경기 중 관측이 추가될 때 팀의 상대적 위치가 실제로 갱신된다는 점을 보여준다.

누적 생존 점수 순위 1위 팀의 최종 상위 10팀 진입률은 높았지만, 이 지표는 무작위 기준도 상대적으로 높았다. 경기 후반에는 남아 있는 팀 자체가 이미 상위 10팀에 가까워지기 때문이다. 따라서 본 연구의 순위 결과는 최종 우승팀을 조기에 확정하는 능력보다, 각 단계에서 곧 탈락할 가능성이 높은 팀과 상대적으로 유리한 팀을 구분하는 용도로 해석한다. 다음 단계 탈락 위험을 식별한 결과가 최종 결과와의 관련성보다 더 뚜렷했다.

8.6 자료와 평가의 한계

첫째, 실증 자료는 PUBG 한 게임에서 수집되었다. 지도, 시점, 팀 규모가 다른 13개 집단에서 실험을 반복하여 PUBG 내부의 재현성을 확인했지만, 다른 게임에서 같은 결과가 나타나는지는 검증하지 못했다. 여러 배틀로얄 게임에 공통으로 나타나는 요인의 일반화 가능성은 공식 경기 기록과 단계별 결과를 함께 제공하는 다른 게임의 자료에서 확인해야 한다.

둘째, 단계 경계와 10초 격자는 연속적인 경기 흐름을 분석 가능한 단위로 바꾸기 위한 선택이다. 단계 경계 사이의 짧은 사건은 보수적으로 제외되며, 가장

가까운 원시 기록을 격자에 맞추는 과정에는 최대 ± 5 초의 불확실성이 있다. 구 현상 향후 30초 탈락 여부를 이용한 보조 손실을 적용했지만, 해당 출력에 대한 독립적인 성능 평가와 실제 운영 환경의 지연 및 계산 비용 평가는 수행하지 않았다. 따라서 본 연구가 검증한 범위는 단계 전환 시점의 다음 단계 탈락 예측으로 한정된다.

셋째, 단계별 자료와 10초 단위 자료를 결합한 모형은 다음 단계 탈락뿐 아니라 최종 순위와 상위권 진입을 보조 목표로 함께 학습한다. 이 설정은 공통 처리부의 학습을 안정화하고 여러 결과를 동시에 평가할 수 있게 하지만, 위험 AUC의 변화가 위험 손실만으로 학습한 모형의 결과와 같다고 볼 수는 없다. 모든 입력 변수 추가 단계와 구조 비교에 같은 손실과 가중치를 적용해 비교의 조건은 유지했으며, 향후에는 보조 손실을 하나씩 제거하는 분석으로 각 목표의 영향을 더 분명히 구분할 수 있다.

넷째, 본 연구의 결과는 관측 자료에 기반한 예측 관계다. 안전 영역의 변화, 이동, 교전, 관계 변수가 탈락 위험과 연관된다는 사실이 특정 행동의 인과 효과를 의미하지 않는다. 강한 팀이 더 유리한 위치를 먼저 선택하거나 교전을 회피하는 선택 편향이 남을 수 있다. 전술 개입의 효과를 논하려면 반복 측정된 팀의 실력과 선택 과정을 별도로 통제하는 설계가 필요하다.

8.7 향후 연구

후속 연구에서는 여러 게임에 공통으로 나타나는 요인과 게임 고유 측정값을 명시적으로 나눈 입력 조합을 구성하고, 다른 배틀로얄 게임에서 같은 요인을 어떤 변수로 측정할 수 있는지 비교할 수 있다. 지형 표면과 건물 구조가 제공되는 자료에서는 경사, 엄폐, 시야선, 통과 가능한 경로를 계산하여 O6의 공간 조건을 더 직접적으로 검증할 필요가 있다.

모형 측면에서는 보조 목표 손실의 제거 실험, 관계별 간선의 시간 변화, 팀 실력의 사전 분포를 함께 고려한 계층 모형이 유용하다. 이러한 확장은 본 연구에서 제시한 단계별 위험 집합과 관측 시점의 원칙을 유지하면서, 적용 범위와 인과 해석을 차례로 넓히는 방향으로 진행할 수 있다.

Chapter 9

결론

본 연구는 배틀로얄의 최종 결과를 경기 종료 후의 순위 하나로 설명할 때 사라지는 경기 중 생존 조건의 변화를 분석하기 위해 네 연구 문제를 설정하였다. 장르의 생존 과정 정식화에서 시작하여 PUBG 기록에서의 자료 표현, 표현의 예측 타당성과 모형의 적합성, 경기 중 상대적 생존 평가의 순서로 검증하였다.

9.1 연구 문제별 결론

9.1.1 생존 과정의 정식화(연구 문제 1)

배틀로얄은 경기 단계마다 생존 조건이 갱신되고 아직 탈락하지 않은 팀들의 다음 단계 탈락 위험이 누적되는 다중 에이전트 생존 과정으로 정식화할 수 있다. 대표 게임 15종은 경기 조건, 팀 상태, 이동, 위험 노출, 생존 자원, 공간 조건과 팀 관계로 기술할 수 있었다. 이 범주는 장르의 모든 규칙을 확정하는 분류표보다, 서로 다른 게임의 생존 조건을 비교하는 분석 틀로 의미가 있다.

9.1.2 PUBG 기록에서의 자료 표현(연구 문제 2)

이 생존 과정은 PUBG 공식 경기 기록에서 단계별 상태, 10초 간격의 연속 기록과 팀 관계로 표현할 수 있다. 2026년 3월 26일부터 6월 2일까지 수집한 13개 분석 집단의 17,943경기에서 1,033,471개의 단계별 예측 사례를 구성하였다. 입력은 예측 시점까지의 관측으로 제한하고 이후의 탈락 및 최종 결과와 분리하였다. 이로써 정식화의 구성 요소를 실제 경기 기록에서 측정할 수 있는 분석 자료로 구현하였다.

9.1.3 표현의 타당성과 모형의 적합성(연구 문제 3)

이동 정보에 안전 영역의 변화와 현재 위치 및 주변 상황을 더했을 때 대표 집단의 다음 단계 탈락 AUC는 0.7836에서 0.7937로 증가했고, 같은 방향이 나머지 12개 집단에서도 유지되었다. 과거 기록도 예측 직전 한 시점보다 유용했다. 따라서 생존 조건의 표현은 이동량만이 아니라 줄어드는 공간과 남은 경쟁자의 배치를 함께 포함할 때 다음 단계의 생존과 탈락을 더 잘 구분한다.

모형의 적합성은 사용 목적에 따라 달랐다. 요약 통계를 사용한 그래디언트 부스팅은 단계 전환 시점의 위험을 평가하는 강한 기준선이었고, LSTM은 시간에 따라 위험과 누적 생존 점수가 달라지는 과정을 보존하는 데 유용했다. 그래프 모형 사이의 위험 예측 차이와 실제 관계의 추가 효과는 작아 보충적인 근거로 해석하였다. 모든 성능 결론은 단계 전환 시점의 다음 단계 탈락 예측에 한정한다.

9.1.4 경기 중 상대적 생존 평가(연구 문제 4)

학습된 위험 순위는 규칙 기반 순위와 Sagong 등의 방식에 따른 점수보다 다음 단계 탈락 팀을 더 잘 식별하였다. 누적 생존 점수의 선두 팀도 단계가 바뀌면서 교체되었다. 다만 누적 점수 1위 팀의 최종 상위 10팀 진입률은 무작위 기준도 높았으므로, 이를 우승 확률로 해석할 근거는 충분하지 않았다. 단계별 탈락 위험은 곧 탈락할 가능성이 높은 팀을 찾는 데 사용하고, 누적 생존 점수는 현재까지의 관측을 반영하여 팀들의 상대적 위치가 바뀌는 과정을 나타내는 기술적 지표로 구분하여 해석한다.

9.2 종합 결론과 기여

본 논문의 기여는 네 연구 문제에 대한 답변을 하나의 분석 과정으로 연결한 데 있다. 장르 수준의 생존 과정을 정식화하고, 이를 PUBG의 단계별 상태, 10초 간격의 연속 기록과 팀 관계로 표현했으며, 표현의 예측 타당성과 자료 구조별 모형의 적합성을 검토하였다. 마지막으로 단계별 위험을 누적 생존 점수와 경기 내 순위로 확장하였다. 이를 통해 PUBG 자료에서는 배틀로얄의 결과를 단계마다 갱신되는 생존 조건과 탈락 위험의 누적으로 분석할 수 있음을 보였다. 다른 게임에 대한 직접적인 예측 검증과 세밀한 지형 정보의 반영은 후속 과제로 남는다.

Bibliography

- [1] África Periañez, Alain Saas, Anna Guitart, and Colin Magne. Churn Prediction in Mobile Social Games: Towards a Complete Assessment Using Survival Ensembles. In *2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, pages 564–573, 2016.
- [2] Kodirjon Akhmedov and Anh Huy Phan. Machine Learning Models for DOTA 2 Outcomes Prediction. arXiv preprint, 2021. arXiv:2106.01782, <https://arxiv.org/abs/2106.01782>.
- [3] Paul D. Allison. Discrete-Time Methods for the Analysis of Event Histories. *Sociological Methodology*, 13:61–98, 1982.
- [4] Shaojie Bai, J. Zico Kolter, and Vladlen Koltun. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv preprint, 2018. arXiv:1803.01271.
- [5] Alexander J. Bisberg and Emilio Ferrara. GCN-WP: Semi-Supervised Graph Convolutional Networks for Win Prediction in Esports. arXiv preprint, 2022. arXiv:2207.13191, <https://arxiv.org/abs/2207.13191>.
- [6] Leo Breiman. Random Forests. *Machine Learning*, 45(1):5–32, 2001.
- [7] Tianqi Chen and Carlos Guestrin. XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [8] Kyunghyun Cho, Bart van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734, 2014.

- [9] David R. Cox. Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–202, 1972.
- [10] Arman Dehpanah, Muheeb Faizan Ghori, Jonathan Gemmell, and Bamshad Mobasher. The Evaluation of Rating Systems in Online Free-for-All Games. arXiv preprint, 2020. arXiv:2008.06787, <https://arxiv.org/abs/2008.06787>.
- [11] Arman Dehpanah, Muheeb Faizan Ghori, Jonathan Gemmell, and Bamshad Mobasher. Player Modeling Using Behavioral Signals in Competitive Online Games. arXiv preprint, 2021. arXiv:2112.04379, <https://arxiv.org/abs/2112.04379>.
- [12] Arman Dehpanah, Muheeb Faizan Ghori, Jonathan Gemmell, and Bamshad Mobasher. The Evaluation of Rating Systems in Team-Based Battle Royale Games. arXiv preprint, 2021. arXiv:2105.14069, <https://arxiv.org/abs/2105.14069>.
- [13] Tiffany D. Do, Seong Ioi Wang, Dylan S. Yu, Matthew G. McMillian, and Ryan P. McMahan. Using Machine Learning to Predict Game Outcomes Based on Player-Champion Experience in League of Legends. In *Proceedings of the 16th International Conference on the Foundations of Digital Games*, 2021.
- [14] Jerome H. Friedman. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [15] Albert Gu and Tri Dao. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. In *First Conference on Language Modeling (COLM)*, 2024. arXiv:2312.00752.
- [16] William L. Hamilton, Rex Ying, and Jure Leskovec. Inductive Representation Learning on Large Graphs. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 1024–1034, 2017.
- [17] Sepp Hochreiter and Jürgen Schmidhuber. Long Short-Term Memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [18] Victoria Hodge, Sam Devlin, Nick Sephton, Florian Block, Anders Drachen, and Peter Cowling. Win Prediction in Esports: Mixed-Rank Match Prediction in Multi-player Online Battle Arena Games. arXiv preprint, 2017. arXiv:1711.06498, <https://arxiv.org/abs/1711.06498>.

- [19] Andrzej Janusz, Maciej Swiechowski, and Tomasz Tajmayer. Helping AI to Play Hearthstone: AAIA’17 Data Mining Challenge. arXiv preprint, 2017. arXiv:1708.00730, <https://arxiv.org/abs/1708.00730>.
- [20] Jailson B. S. Junior and Claudio E. C. Campelo. League of Legends: Real-Time Result Prediction. arXiv preprint, 2023. arXiv:2309.02449, <https://arxiv.org/abs/2309.02449>.
- [21] Kaggle. PUBG Finish Placement Prediction. Online competition dataset, 2018. <https://www.kaggle.com/c/pubg-finish-placement-prediction>.
- [22] Adam Katona, Ryan Spick, Victoria Hodge, Simon Demediuk, Florian Block, Anders Drachen, and James Alfred Walker. Time to Die: Death Prediction in Dota 2 using Deep Learning. arXiv preprint, 2019. arXiv:1906.03939, <https://arxiv.org/abs/1906.03939>.
- [23] Ilya Loshchilov and Frank Hutter. SGDR: Stochastic Gradient Descent with Warm Restarts. In *International Conference on Learning Representations (ICLR)*, 2017.
- [24] Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [25] David Melhart, Daniele Gravina, and Georgios N. Yannakakis. Moment-to-Moment Engagement Prediction through the Eyes of the Observer: PUBG Streaming on Twitch. arXiv preprint, 2020. arXiv:2008.07207, <https://arxiv.org/abs/2008.07207>.
- [26] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems 32 (NeurIPS)*, pages 8024–8035, 2019.
- [27] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-

- learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [28] Brij Rokad, Tushar Karumudi, Omkar Acharya, and Akshay Jagtap. Survival of the Fittest in PlayerUnknown BattleGround. arXiv preprint, 2019. arXiv:1905.06052, <https://arxiv.org/abs/1905.06052>.
 - [29] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning Representations by Back-propagating Errors. *Nature*, 323:533–536, 1986.
 - [30] Chaeyeon Sagong, Ji Young Woo, and Huy Kang Kim. Are You a Hunter or Camper? A Phase-Based Framework for Real-Time Survival Prediction in Battle Royale Using FightScore and ActiveScore. *Entertainment Computing*, 55:101040, 2025.
 - [31] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling Relational Data with Graph Convolutional Networks. In *The Semantic Web: 15th International Conference (ESWC)*, pages 593–607, 2018.
 - [32] Diptakshi Sen, Rupam Kumar Roy, Ritajit Majumdar, Kingshuk Chatterjee, and Debayan Ganguly. Prediction of the Final Rank of Players in PUBG with the Optimal Number of Features. arXiv preprint, 2021. arXiv:2107.09016, <https://arxiv.org/abs/2107.09016>.
 - [33] Judith D. Singer and John B. Willett. It’s About Time: Using Discrete-Time Survival Analysis to Study Duration and the Timing of Events. *Journal of Educational Statistics*, 18(2):155–195, 1993.
 - [34] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 5998–6008, 2017.
 - [35] Wikipedia contributors. Battle royale game. https://en.wikipedia.org/wiki/Battle_royale_game, 2026. Accessed 2026-07-06.
 - [36] Wikipedia contributors. List of battle royale games. https://en.wikipedia.org/wiki/List_of_battle_royale_games, 2026. Accessed 2026-07-06.

- [37] Wikipedia contributors. PUBG: Battlegrounds. https://en.wikipedia.org/wiki/PUBG:_Battlegrounds, 2026. Accessed 2026-07-06.
- [38] Peter Xenopoulos, Harish Doraiswamy, and Claudio Silva. Valuing Player Actions in Counter-Strike: Global Offensive. arXiv preprint, 2020. arXiv:2011.01324, <https://arxiv.org/abs/2011.01324>.
- [39] Zelong Yang, Zhufeng Pan, Yan Wang, Deng Cai, Xiaojiang Liu, Shuming Shi, and Shao-Lun Huang. Interpretable Real-Time Win Prediction for Honor of Kings, a Popular Mobile MOBA Esport. arXiv preprint, 2020. arXiv:2008.06313, <https://arxiv.org/abs/2008.06313>.

Appendix A

부록

A.1 부록의 구성

부록에는 대표 게임의 분류 근거, 입력 변수의 세부 정의, 분석 집단별 결과와 보충 분석을 제시한다. 본문에서는 연구 질문과 직접 관련된 비교와 결과의 분포를 설명하고, 여기서는 그 해석을 확인할 수 있도록 개별 변수와 13개 집단의 수치를 제공한다.

A.2 대표 게임의 사례 분류

표 A.1은 7장의 대표 게임 사례 검토에서 요약한 전체 분류 결과이다. 사례의 선정 출처와 포함 기준은 6장의 절차를 따른다 [35, 36]. 각 행은 공식 개발사 또는 퍼블리셔가 통제하는 페이지를 근거로 분류하였으며, 열람 시점은 2026년 7월 4일이다. 서비스 상태는 열람 시점 기준이다.

A.3 입력 변수의 정의와 산출 방법

이 절에서는 5장의 생존 요인과 모형에 사용한 변수를 대응시킨다. 표에서 화살표의 왼쪽은 모형에 입력한 변수명이고, 오른쪽은 PostgreSQL에 저장된 원자료 또는 파생 변수명이다. 슬래시 뒤의 값은 정규화에 사용한 기준값을 뜻한다. 두 변수명이 같으면 화살표를 생략하였고, 기준값이 1이면 저장된 값을 그대로 사용하였다. 결측값과 무한대 등 계산할 수 없는 값은 0으로 대체하였다. 경로 굴곡도에는 $\log(1 + \max(v, 0))$ 변환을 적용하였다. 표의 17개 변수군은 서로 겹치지 않으며, 전체 단계별 입력 변수 150개를 이룬다.

Table A.1: 대표 배틀로얄 및 배틀로얄형 게임 15종의 분류 결과

게임/모드	유형	공간 형태	출처 및 상태	상	주요 생존 요인과의 대응
PUBG	전투 중심	3차원	공식, 운영 중	낙하, 자원 확보, 안전 영역 축소와 최후 생존	
Fortnite	전투 중심	3차원	스토어, 운영 중	건설 여부에 따른 공간 조건과 자원 이용의 변화	
Apex Legends	전투 중심	3차원	공식, 운영 중	영웅 능력에 따른 팀 상태와 생존 자원의 변화	
Call of Duty: Warzone	전투 중심	3차원	공식, 운영 중	재배치와 계약 임무에 따른 팀 상태와 자원의 변화	
Garena Free Fire	전투 중심	3차원	공식, 운영 중	짧은 경기 시간에 나타나는 안전 영역 축소와 탈락	
Super Animal Royale	능력 및 시스템 변형	시스 평면 2D	공식, 운영 중	2차원 지형에서도 공간 요인 성립	
Brawl Stars 다운	능력 및 시스템 변형	시스 평면 2D	공식, 운영 중	소규모 로비 단시간 탈락전(출처 서술은 개괄적)	
NARAKA: BLADEPOINT	능력 및 시스템 변형	시스 3차원	스토어, 운영 중	입체 이동과 근접 전투에 따른 이동 및 위험 노출	
Eternal Return	능력 및 시스템 변형	시스 2.5차원	스토어, 운영 중	제작과 성장 요소가 결합된 생존 탈락전	
Battlerite Royale	능력 및 시스템 변형	시스 평면 2D	스토어, 상태 불명	탑다운 스킬 대전형 축소 구역 생존	
Realm Royale Reforged	능력 및 시스템 변형	시스 3차원	스토어, 서비스 종료	직업, 제작과 부활에 따른 상태 및 자원 변화	
CS:GO Danger Zone	능력 및 시스템 변형	시스 3차원	공식, 모드 제거	정보 장비, 위험 노출과 확인된 상대와의 관계	
Fall Guys	충격전 탈락형 게임	없는 단계별 기장	스토어, 운영 중	통과 인원과 남은 시간에 따른 단계별 탈락	
Tetris 99	충격전 탈락형 게임	없는 2차원 자	공식, 운영 중	보드 상태와 표적 공격에 따른 공간 및 관계 조건	
F-ZERO 99	충격전 탈락형 게임	없는 트랙	공식, 운영 중	레이싱 소모전이 충격 없는 위협으로 작동	

Table A.2: 단계별 입력 변수 150개의 산출 방법

변수군	입력 변수 $\leftarrow$ 저장 변수/정규화 기준값	변수 수
OM0 경기 정보	$\text{phase_idx_norm} \leftarrow \text{phase_idx}/8;$ $\text{phase_duration_10min} \leftarrow \text{phase_duration_s}/600;$ $\text{team_size_norm} \leftarrow \text{team_size}/4$	3
O1 팀 상태	$\text{alive_players_start_norm} \leftarrow \text{alive_players_start}/4;$ $\text{alive_players_end_norm} \leftarrow \text{alive_players_end}/4;$ $\text{alive_players_min_norm} \leftarrow \text{alive_players_min}/4;$ $\text{alive_players_avg_norm} \leftarrow \text{alive_players_avg}/4;$ $\text{mean_health_avg_norm} \leftarrow \text{mean_health_avg}/100;$ $\text{min_health_min_norm} \leftarrow \text{min_health_min}/100;$ $\text{health_slope_norm} \leftarrow \text{health_slope}/10;$ $\text{team_spread_avg_norm} \leftarrow \text{team_spread_avg_m}/1,000;$ $\text{team_spread_max_norm} \leftarrow \text{team_spread_max_m}/1,000$	9
O3 이동 반응	$\text{path_length_norm} \leftarrow \text{path_length_m}/5,000;$ $\text{displacement_norm} \leftarrow \text{displacement_m}/5,000;$ $\text{log1p_sinuosity} \leftarrow \log(1 + \max(\text{sinuosity}, 0));$ $\text{avg_speed_norm} \leftarrow \text{avg_speed_mps}/40;$ $\text{rotation_timing} \leftarrow \text{rotation_timing}/1;$ $\text{safe_alignment} \leftarrow \text{safe_alignment}/1;$ $\text{zone_entry_time} \leftarrow \text{zone_entry_time}/1$	7
O2 남은 경쟁자와 구역 변화	$\text{avg_alive_teams_norm} \leftarrow \text{avg_alive_teams}/100;$ $\text{avg_alive_players_norm} \leftarrow \text{avg_alive_players}/100;$ $\text{safe_radius_start_norm} \leftarrow \text{safe_radius_start_m}/8,160;$ $\text{safe_radius_end_norm} \leftarrow \text{safe_radius_end_m}/8,160;$ $\text{safe_radius_delta_norm} \leftarrow \text{safe_radius_delta_m}/8,160;$ $\text{safe_center_shift_norm} \leftarrow \text{safe_center_shift_m}/8,160;$ $\text{poison_radius_start_norm} \leftarrow \text{poison_radius_start_m}/8,160;$ $\text{poison_radius_end_norm} \leftarrow \text{poison_radius_end_m}/8,160;$ $\text{zone_gap_start_norm} \leftarrow \text{zone_gap_start_m}/8,160;$ $\text{zone_gap_end_norm} \leftarrow \text{zone_gap_end_m}/8,160$	10
O2 안전 구역 이탈과 경계 거리	$\text{outside_safe_duration_10min} \leftarrow \text{outside_safe_duration_s}/600;$ $\text{boundary_distance_slope_norm} \leftarrow \text{boundary_distance_slope}/100;$ $\text{mean_dist_to_boundary_norm} \leftarrow \text{mean_dist_to_boundary_m}/8,160;$ $\text{min_dist_to_boundary_norm} \leftarrow \text{min_dist_to_boundary_m}/8,160;$ $\text{outside_safe_ratio} \leftarrow \text{outside_safe_ratio}/1$	5
H 단계별 공간 여건	$\text{hab_safe_area_start_m2}/50,000,000;$ $\text{hab_safe_area_end_m2}/50,000,000;$ $\text{hab_safe_area_delta_m2}/50,000,000;$ $\text{hab_loss_ratio}/1;$ $\text{hab_shrink_rate_m2ps}/100,000;$ $\text{hab_alive_teams}/100;$ $\text{hab_safe_area_per_alive_team}/5,000,000;$ $\text{hab_crowding_pressure}/10^{-6};$ $\text{hab_center_shift_m}/8,160;$ $\text{hab_center_shift_per_radius}/1;$ $\text{hab_zone_gap_start_m}/8,160;$ $\text{hab_zone_gap_end_m}/8,160;$ $\text{hab_zone_gap_pressure}/1$	13

다음 쪽에 계속

표 A.2 계속

변수군	입력 변수 $\leftarrow$ 저장 변수/정규화 기준값	변수 수
H 안전 영역 진입 조건	$hab_dist_to_safe_boundary_start_m/8,160;$ $hab_dist_to_safe_boundary_end_m/8,160;$ $hab_signed_boundary_distance_start_m/8,160;$ $hab_signed_boundary_distance_end_m/8,160;$ $hab_distance_to_target_safe_m/8,160;$ $hab_required_speed_to_safe_mps/40;$ $hab_observed_speed_mps/40;$ $hab_migration_deficit_mps/40;$ $hab_outside_safe_ratio/1;$ $hab_edge_pressure_ratio/1;$ $hab_rotation_delay_ratio/1;$ $hab_safe_alignment_to_target/1$	12
H 주변 경쟁 상황	$hab_local_enemy_count_100m/20;$ $hab_local_enemy_count_200m/20;$ $hab_local_enemy_count_500m/20;$ $hab_local_enemy_density_200m/160;$ $hab_safe_entry_enemy_count_200m/20;$ $hab_safe_entry_congestion/20;$ $hab_refuge_scarcity_simple/10^{-6}$	7
O4 위협 노출	$recent_damage_taken_norm \leftarrow recent_damage_taken/1,000;$ $combat_zone_pass_count_norm \leftarrow combat_zone_pass_count/50;$ $damage_dealt_norm \leftarrow damage_dealt/1,000;$ $damage_taken_norm \leftarrow damage_taken/1,000;$ $damage_events_dealt_norm \leftarrow damage_events_dealt/50;$ $damage_events_taken_norm \leftarrow damage_events_taken/50;$ $groggy_dealt_norm \leftarrow groggy_dealt/10;$ $groggy_taken_norm \leftarrow groggy_taken/10;$ $kills_dealt_norm \leftarrow kills_dealt/10;$ $kills_taken_norm \leftarrow kills_taken/10;$ $distinct_opponents_damaged_norm \leftarrow distinct_opponents_damaged/10;$ $distinct_opponents_damaged_by_norm \leftarrow distinct_opponents_damaged_by/10;$ $combat_initiated \leftarrow \text{논리값 } 0 \text{ 또는 } 1$	13
O7 교전 관계	$net_combat_out_degree/20;$ $net_combat_in_degree/20;$ $net_combat_total_degree/20;$ $net_combat_out_strength/50;$ $net_combat_in_strength/50;$ $net_combat_total_strength/50;$ $net_combat_balance/1;$ $net_combat_unique_targets/20;$ $net_combat_unique_attackers/20;$ $net_combat_reciprocal_pairs/20;$ $net_combat_reciprocity_ratio/1;$ $net_combat_out_strength_per_min/10;$ $net_combat_in_strength_per_min/10$	13

다음 쪽에 계속

표 A.2 계속

변수군	입력 변수 $\leftarrow$ 저장 변수/정규화 기준값	변수 수
O7 근접 관계	<code>net_prox_degree_100m/20;</code> <code>net_prox_degree_200m/20;</code> <code>net_prox_degree_500m/20;</code> <code>net_prox_strength_decay/5;</code> <code>net_prox_mean_distance_m/8,160;</code> <code>net_prox_min_distance_m/8,160;</code> <code>net_prox_top1_weight/1;</code> <code>net_prox_top3_strength/3;</code> <code>net_prox_isolation_m/8,160;</code> <code>net_prox_neighbor_entropy/3</code>	10
O7 안전 구역 밖 동시 체류	<code>net_copress_degree/20;</code> <code>net_copress_strength/5;</code> <code>net_copress_max_weight/1;</code> <code>net_copress_mean_ratio/1;</code> <code>net_copress_shared_pressure_count/50;</code> <code>net_copress_top1_weight/1</code>	6
O7 누적 관계	<code>cum_combat_out_degree/50;</code> <code>cum_combat_in_degree/50;</code> <code>cum_combat_out_strength/200;</code> <code>cum_combat_in_strength/200;</code> <code>cum_combat_total_strength/200;</code> <code>cum_combat_reciprocal_pairs/20;</code> <code>cum_unique_targets/20;</code> <code>cum_unique_attackers/20;</code> <code>cum_copress_strength/20;</code> <code>cum_prox_close_exposure_200m/50</code>	10
O7 생존 팀 수 보정	<code>net_combat_out_strength_per_alive_team/5;</code> <code>net_combat_in_strength_per_alive_team/5;</code> <code>net_prox_degree_200m_per_alive_team/1;</code> <code>net_copress_degree_per_alive_team/1</code>	4
O6 주변 적 분 포	<code>avg_enemy_density_100m_norm $\leftarrow$ avg_enemy_density_100m/10;</code> <code>min_nearest_enemy_norm $\leftarrow$ min_nearest_enemy_m/8,160;</code> <code>path_near_enemy_ratio $\leftarrow$ path_near_enemy_ratio/1</code>	3
O5 생존 자원	<code>vehicle_ratio/1;</code> <code>vehicle_speed_mean_norm $\leftarrow$ vehicle_speed_mean/40;</code> <code>vehicle_speed_max_norm $\leftarrow$ vehicle_speed_max/40;</code> <code>pickup_count_norm $\leftarrow$ pickup_count/100;</code> <code>equip_count_norm $\leftarrow$ equip_count/50;</code> <code>use_count_norm $\leftarrow$ use_count/50;</code> <code>unique_item_count_norm $\leftarrow$ unique_item_count/100;</code> <code>weapon_pickup_count_norm $\leftarrow$ weapon_pickup_count/20;</code> <code>weapon_equip_count_norm $\leftarrow$ weapon_equip_count/20;</code> <code>ammo_pickup_count_norm $\leftarrow$ ammo_pickup_count/50;</code> <code>armor_pickup_count_norm $\leftarrow$ armor_pickup_count/20;</code> <code>throwable_pickup_count_norm $\leftarrow$ throwable_pickup_count/20;</code> <code>heal_use_count_norm $\leftarrow$ heal_use_count/20;</code> <code>boost_use_count_norm $\leftarrow$ boost_use_count/20;</code> <code>carepackage_pickup_count_norm $\leftarrow$ carepackage_pickup_count/5;</code> <code>lootbox_pickup_count_norm $\leftarrow$ lootbox_pickup_count/20</code>	16

다음 쪽에 계속

표 A.2 계속

변수군	입력 변수 $\leftarrow$ 저장 변수/정규화 기준값	변수 수
O6Z 고도 관련 변수	$\text{team.z.mean.norm} \leftarrow \text{team.z.mean.m}/400;$ $\text{team.z.percentile.alive}/1;$ $\text{team.z.range.norm} \leftarrow \text{team.z.range.m}/200;$ $\text{contact.delta.z.mean.norm} \leftarrow \text{contact.delta.z.mean.m}/100;$ $\text{contact.delta.z.positive.ratio}/1;$ $\text{high.ground.contact.advantage}/1;$ $\text{high.ground.x.boundary.pressure}/1;$ $\text{z.percentile.x.hab.crowding.pressure}/10^{-6};$ $\text{contact.delta.z.x.outside.safe.ratio}/100$	9

OM0-OM6은 위 표에서 O5와 O6Z를 제외한 변수군을 순서대로 누적한다. 단계별 자료와 10초 단위 자료를 결합한 모형은 17개 변수군을 모두 사용한다. O6Z 민감도 분석은 OM5까지의 122개 변수에 고도 관련 변수 9개만 더한 131개를 사용한다. 이는 OM6의 주변 적 분포 변수 3개와 O5의 자원 변수 16개를 함께 사용하는 150개 전체 입력과 구분된다.

A.4 분석 집단별 주요 결과

A.4.1 안전 영역과 주변 상황 변수를 추가한 결과

표 A.3는 이동 변수까지 사용한 OM2와 안전 영역의 변화, 현재 위치 및 주변 상황을 더한 OM3의 다음 단계 탈락 예측 AUC를 집단별로 제시한다. 본문 그림 7.1은 마지막 열의 차이를 시각화한 것이다.

Table A.3: 분석 집단별 OM2와 OM3의 다음 단계 탈락 예측 AUC

분석 집단	OM2	OM3	차이
Erangel FPP 스쿼드	0.7341	0.7452	0.0110
Erangel TPP 듀오	0.7112	0.7274	0.0162
Erangel TPP 솔로	0.7458	0.7669	0.0211
Erangel TPP 스쿼드	0.7836	0.7937	0.0102
Karakin TPP 스쿼드	0.6872	0.6962	0.0090
Miramar TPP 스쿼드	0.7660	0.7745	0.0085
Paramo TPP 스쿼드	0.7120	0.7212	0.0092
Rondo TPP 스쿼드	0.7538	0.7594	0.0057
Sanhok TPP 스쿼드	0.7575	0.7687	0.0112
Taego FPP 스쿼드	0.7272	0.7427	0.0155
Taego TPP 듀오	0.7230	0.7407	0.0178
Taego TPP 스쿼드	0.7851	0.7937	0.0086
Vikendi TPP 스쿼드	0.7397	0.7499	0.0103

A.4.2 10초 기록을 사용한 모형 비교

표 A.4는 본문 그림 7.2에 표시한 값을 제시한다. 시계열 통계 기반 그래디언트 부스팅은 10초 기록을 구간별 통계로 요약한 모형이며, 마지막 시점 모형은 예측 직전의 13개 값만 사용한 신경망이다.

Table A.4: 분석 집단별 10초 기록 모형의 다음 단계 탈락 예측 AUC

분석 집단	통계 기반 GB	Transformer	LSTM	GRU	TCN	마지막 시점
Erangel FPP 스쿼드	0.7615	0.7528	0.7447	0.7294	0.7325	0.7202
Erangel TPP 듀오	0.7316	0.7136	0.7145	0.7133	0.7148	0.7016
Erangel TPP 솔로	0.7590	0.7471	0.7428	0.7355	0.7268	0.7138
Erangel TPP 스쿼드	0.7733	0.7674	0.7664	0.7658	0.7436	0.7281
Karakin TPP 스쿼드	0.6991	0.6970	0.7017	0.7042	0.7037	0.7107
Miramar TPP 스쿼드	0.7719	0.7620	0.7549	0.7524	0.7494	0.7386
Paramo TPP 스쿼드	0.7034	0.7155	0.7093	0.7095	0.7140	0.7091
Rondo TPP 스쿼드	0.7626	0.7483	0.7462	0.7468	0.7456	0.7377
Sanhok TPP 스쿼드	0.7550	0.7489	0.7441	0.7417	0.7425	0.7407
Taego FPP 스쿼드	0.7484	0.7365	0.7253	0.7146	0.7160	0.7096
Taego TPP 듀오	0.7444	0.7321	0.7344	0.7309	0.7265	0.7213
Taego TPP 스쿼드	0.7803	0.7714	0.7645	0.7623	0.7592	0.7465
Vikendi TPP 스쿼드	0.7465	0.7470	0.7445	0.7423	0.7367	0.7255

A.4.3 단계별 순위 비교

표 A.5는 다음 단계에 탈락한 팀을 위험 순위의 첫 번째로 찾은 비율이다. 본문 그림 7.4은 이 값을 집단별 분포로 나타낸다.

Table A.5: 분석 집단별 다음 단계 탈락 팀의 상위 1팀 적중률

분석 집단	공간 모형	LSTM	원자료 모형	인원 및 체력	Sagong 점수	영역 거리	무작위
Erangel FPP 스쿼드	0.7123	0.6934	0.5943	0.5094	0.5000	0.5000	0.3868
Erangel TPP 듀오	0.7513	0.7462	0.7205	0.5256	0.4846	0.4154	0.4128
Erangel TPP 솔로	0.8442	0.8358	0.8147	0.5916	0.5579	0.4842	0.4211
Erangel TPP 스쿼드	0.7188	0.7292	0.7054	0.4972	0.5119	0.4080	0.3951
Karakin TPP 스쿼드	0.7669	0.7485	0.6626	0.5215	0.5215	0.4847	0.3558
Miramar TPP 스쿼드	0.6761	0.6832	0.6572	0.4594	0.4335	0.4087	0.3781
Paramo TPP 스쿼드	0.7241	0.6897	0.6966	0.5448	0.4897	0.4759	0.4000
Rondo TPP 스쿼드	0.6599	0.6952	0.6952	0.4944	0.4461	0.4182	0.3550
Sanhok TPP 스쿼드	0.7490	0.7110	0.7053	0.5437	0.5038	0.4240	0.4030
Taego FPP 스쿼드	0.7182	0.6682	0.6773	0.5273	0.5182	0.4955	0.3773
Taego TPP 듀오	0.7221	0.7507	0.7335	0.5072	0.4785	0.4040	0.3983
Taego TPP 스쿼드	0.7077	0.6940	0.6757	0.4938	0.4693	0.3972	0.3599
Vikendi TPP 스쿼드	0.6679	0.7004	0.6931	0.4585	0.4729	0.4296	0.3430

A.5 보충 분석

A.5.1 팀 관계를 바꾼 대조 실험

관계 모형이 연결 수 자체가 아니라 실제 상대의 정보를 사용하는지 확인하기 위해, 팀별 연결 수 분포를 유지하면서 연결 상대만 바꾼 결과와 비교하였다. 표 A.6의 차이는 실제 관계를 사용한 AUC에서 대조 모형의 AUC를 뺀 값이다.

Table A.6: 실제 팀 관계와 연결 상대를 바꾼 대조 실험의 비교

평가 범위	AUC가 증가한 집단	95% 신뢰구간 하한이 0 보다 큰 집단	AUC 차이 중앙값
전체 단계	13/13	6/13	0.0023
초반 단계 1-2	12/13	4/13	0.0027
중반 단계 3-4	8/13	3/13	0.0007

A.5.2 고도 관련 변수

공식 기록의 수직 좌표로 계산한 고도 관련 변수 9개를 OM5에 더한 결과도 별도로 확인하였다. 다음 단계 탈락 예측 AUC는 OM5보다 중앙값 기준 0.0012 낮았고, 양의 방향을 보인 집단은 13개 중 4개였다. 최종 순위 상관의 중앙 변화는 (-0.0034), 상위 10팀 판별 AUC의 중앙 변화는 (-0.0007)이었다. 초반 단계의 탈락 예측 AUC는 중앙값 기준 0.0004 높았으나, 증가한 집단이 7개여서 사전에 정한 지지 기준을 충족하지 못했다.

이 결과는 고지대의 전술적 의미가 없다는 뜻으로 해석할 수 없다. 수직 좌표만으로는 경사, 건물 내부 구조, 엄폐와 시야선을 구분할 수 없으므로, 현재 자료로 계산한 변수가 세밀한 지형 조건을 충분히 측정하지 못했을 가능성이 크다. 이에 따라 고도 관련 변수는 핵심 입력 변수 추가 결과가 아니라 공간 자료의 측정 한계를 확인하는 보충 분석으로 제시하였다.

Abstract

Battle Royale placement accumulates as the safe zone, remaining teams, movement, combat, and resources change. This thesis formulates the genre as a multi-agent survival process with conditions updated at each match phase. It estimates next-phase elimination risk and connects phase-wise risks to a cumulative survival score and an in-match ranking.

The formulation was examined using 15 representative games and then instantiated with official PUBG records. Phase-level team records and 10-second sequences from 17,943 matches in 13 cohorts yielded 1,033,471 prediction cases. Inputs were restricted to information observable by each prediction time.

The experiments examined conceptual scope, data construction, input variables, temporal history, inter-team relations, and in-match ranking in sequence. Adding changes in the safe zone, current position, and nearby competition to movement variables increased next-phase elimination AUC from 0.7836 to 0.7937 in the representative cohort, with the same direction in the other 12 cohorts. This input set generally outperformed a prior behavior-score baseline and summaries of official raw records. Models using past 10-second records also generally outperformed those using only the latest observation. Differences among graph models and the additional effect of team relations were small and were treated as supporting evidence. Rankings derived from learned risks identified teams eliminated in the next phase more accurately than rule-based rankings, while the leading team under the cumulative survival score changed as the match progressed. The score is therefore interpreted as an updated measure of relative survival conditions rather than an early declaration of the eventual winner. These results show that PUBG outcomes can be analyzed as an accumulation of phase-wise survival conditions and elimination risks. Direct validation in other Battle Royale games remains future work.

Keywords: Battle Royale, survival analysis, PUBG, official match records, elimination risk, time series, multi-agent systems